

Bases de données
documentaires et distribuées,
<http://b3d.bdpedia.fr>

Qu'est-ce que la normalisation

La **normalisation** relationnelle consiste à élaborer un schéma de données avec deux propriétés fondamentales :

- Il n'y a **aucune** redondance, et donc aucun risque **d'incohérence**
- Il n'y a aucune perte d'information

Note

Essentiel en général, avec des exceptions, notamment les données historisées servant à l'analyse.

Pourquoi pas une unique table ?

date	nom	âge	département	région	pathologie
12/01/23	Philippe R.	63	Paris	IdF	Diabète
05/10/24	Amélie A.	32	Var	PACA	Cancer
31/03/22	Julien S.	16	Manche	Normandie	Cardio
14/01/24	François J.	52	Orne	Normndie	Neurologique
02/07/21	Sonia T.	38	Paris	Ile de F.	Diabète
25/06/22	Philippe R.	25	Cantal	ARA	Respiratoires
03/12/24	Joëlle B.	72			Cardiologiques
27/04/22	Sonia T.	89	Var	PACA	Epilepsie

Enumérons les **anomalies** (insertion, modification, suppression) et **incohérences**.

Petit résumé

Une liste (non exhaustive) des problèmes soulevés par une modélisation bâclée.

- Impossible d'identifier des patients, régions ou pathologies
- Pas de regroupement possible, pas d'agrégation fiable
- Pas de nomenclature des pathologies sans patient – pas de répertoire des patients sans pathologie
- Un même patient peut voir ses propriétés varier – deux patients distincts peuvent être indiscernables
- etc.

Qu'est-ce que normaliser ?


La normalisation consiste à

- distinguer des “entités”
- les identifier
- leur affecter une table spécifique
- lier ces tables pour ne pas perdre d'information

Note

Il existe des propriétés formelles pour dire qu'un schéma est normalisé

La modélisation du schéma



Nos tables

- Patient (**id**, nom, prénom, sexe, néLe)
- Pathologie (**code**, intitulé, sousTypeDe)
- Région (**code**, nom)
- Dépt (**code**, nom, *codeRégion*)
- Cas (**id**, date, *idPatient*, *codePathologie*, *codeDépt*)

En **gras** les **clés primaires**, en *italiques* les **clés étrangères**.

Le mécanisme des clés primaires et étrangères

code	nom
paca	Provence, Alpes, Côte d'azur
ara	Auvergne, Rhône Alpes
nmd	Normandie
occ	Occitanie

La table des régions

code	nom	codeRégion
15	Cantal	ara
50	Manche	nmd
30	Gard	occ
61	Orne	nmd

La table des départements

Contraintes

- la valeur d'une clé primaire est unique
- La valeur d'une clé étrangère est **toujours** celle d'une clé de la table référencée.

Suite et fin des exemples

id	prénom	sexe	néLe
10	Philippe	M	18/09/1987
20	Amélie	F	12/01/1963
30	Julien	M	2/11/2002
40	François	M	30/03/1993
50	Joëlle	F	18/02/1997
60	Sonia	F	29/07/1976

table des patients

code	intitulé	sousTypeDe
dia	Diabètes	
neur	Neurologies	
canc	Cancers	
epi	Epislespie	neur
csein	Cancer du sein	canc
psy	Psychiatrie	

La table des pathologies

id	date	idPatient	codePathologie	codeDépt
1000	08/12/2021	10	epi	30
2000	24/05/2024	40	dia	15
3000	30/03/2021	50	epi	30
4000	18/07/2022	10	neur	61
5000	06/10/2021	20	csein	61
6000	20/07/2023	60	dia	50

La table des cas

À retenir

Un modèle relationnel normalisé évite les **anomalies de mise à jour** et les **incohérences** consécutives aux redondances.

Caractéristique :

- La base est constitué de plusieurs (souvent, beaucoup) de tables contenant des données élémentaires
- Les liens sont basés sur les partages de valeur (clés primaire et étrangère)
- L'ajout d'une information (un cas par exemple) peut nécessiter plusieurs écritures
- La recherche d'une information peut nécessiter plusieurs lectures

A-t-on perdu de l'information ? Comment reconstituer la table “universelle” avant décomposition ? À venir.