

Examen NFE204 - Session 1

03 février 2015

Consignes

Durée de l'examen : 3h00

Documents non autorisés ; Calculatrice autorisée

Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.

Ce sujet contient 2 pages.

Important : nous n'évaluons pas les réponses par la syntaxe. Ne vous inquiétez pas d'utiliser un point-virgule à la place d'un point d'exclamation ou autres détails mineurs

Première partie : recherche d'information (8 pts)

Voici quelques extraits d'un discours politique célèbre (un peu modifié pour les besoins de la cause). Chaque extrait correspond à un document, numéroté a_i .

(a1) Moi, président de la République, je ne serai pas le chef de la majorité, je ne recevrai pas les parlementaires de la majorité à l'Elysée.

(a2) Moi, président de la République, je ne traiterai pas mon Premier ministre de collaborateur.

(a3) Moi, président de la République, les ministres de la majorité ne pourraient pas cumuler leurs fonctions avec un mandat parlementaire ou local.

(a4) Moi, président de la République, il y aura un code de déontologie pour les ministres et parlementaires qui ne pourraient pas rentrer dans un conflit d'intérêt.

1. Rappeler la notion de *stop word* (ou "mot vide") et donner la liste de ceux que vous choisiriez dans les textes ci-dessus.

Solution : Mot très fréquents et peu porteurs de sens pour l'interprétation d'un contenu : le, de, la, ne, pas, un, etc.

2. Outre ces mots vides, pouvez-vous identifier certains mots dont l'idf tend vers 0 (en appliquant le logarithme) ? Lesquels ?

Solution : Moi, président, république : cas particuliers pour ce corpus, il apparaissent dans chaque document.

3. Présentez la matrice d'incidence pour le vocabulaire suivant : "majorité, ministre, déontologie, parlementaire". Vous indiquerez l'idf pour chaque terme (sans logarithme), et le tf pour chaque paire (terme, document).

Solution :

	a1	a2	a3	a4
majorité (2)	2	0	1	0
ministre (4/3)	0	1	1	1
déontologie (4)	0	0	0	1
parlementaire (4/3)	1	0	1	1

4. Donner les résultats classés par similarité cosinus basée sur les tf (on ignore l'idf) pour les requêtes suivantes.
- majorité ; expliquez le classement ;
 - ministre ; expliquez le classement du premier document ;
 - déontologie et ministre ; qu'est-ce qui changerait si on prenait en compte l'idf ?
 - majorité et ministre ; qu'obtiendrait-t-on avec une requête Booléenne ? Commentaire ?

Solution : Les normes

$$- \|a1\| = \sqrt{4+1} ; \|a2\| = \sqrt{1} ; \|a3\| = \sqrt{3} ; \|a4\| = \sqrt{3}$$

Les cosinus (requête non normalisée).

- majorité : $a1 : \frac{2}{\sqrt{5}} ; a3 : \frac{1}{\sqrt{3}} ; a1$ est premier car majorité apparaît 2 fois.
 - ministre : $a2 : \frac{1}{\sqrt{1}} ; a3 : \frac{1}{\sqrt{3}} ; a4 : \frac{1}{\sqrt{3}} ;$ le document a2 ne parle que de ministre, et rien d'autre.
 - déontologie et ministre : $a2 : \frac{1}{\sqrt{1}} ; a3 : \frac{1}{\sqrt{3}} ; a4 : \frac{2}{\sqrt{3}} ;$ déontologie ayant un idf supérieur à ministre, a3 serait classé avant a2,
 - majorité et ministre : $a1 : \frac{2}{\sqrt{5}} ; a2 : \frac{1}{\sqrt{1}} ; a3 : \frac{2}{\sqrt{3}} ; a4 : \frac{1}{\sqrt{3}} ;$ avec une requête Booléenne, a1 n'apparaîtrait pas du tout !
5. Calculez la similarité entre a3 et a4 ; puis entre a3 et a1. Qui est le plus proche de a3 ?

Solution : Il s'agit toujours de la similarité cosinus. La similarité par fonction Euclidienne sur les vecteurs *normalisés* fonctionne aussi.

$$- \cos(a3, a4) = \frac{1+1}{\sqrt{3} \times \sqrt{3}} ;$$

$$- \cos(a3, a1) = \frac{2+1}{\sqrt{5} \times \sqrt{3}}.$$

a1 est plus proche de a3.

Seconde partie : Pig et MapReduce (6 pts)

Un système d'observation spatial capte des signaux en provenance de planètes situées dans de lointaines galaxies. Ces signaux sont stockés dans une collection *Signaux* de la forme

Signaux (idPlanète, date, contenu)

Le but est de déterminer si ces signaux peuvent être émis par une intelligence extra-terrestre. Pour cela les scientifiques ont mis au point les fonctions suivantes :

- *Fonction de structure* : $f_S(c) : Bool$, prend un contenu en entrée, et renvoie `true` si le contenu présente une certaine structure, `false` sinon.
- *Fonction de détecteur d'Aliens* : $f_D(< c >) : real$, prend une liste de contenus *structurés* en entrée, et renvoie un indicateur entre 0 et 1 indiquant la probabilité que ces contenus soient écrits en langage extra-terrestre, et donc la *présence d'Aliens* !

Bien entendu, il y a beaucoup de signaux : c'est du Big Data.

Questions.

1. Ecrire un programme Pig latin qui produit, pour chaque planète, l'indicateur de présence d'Aliens par analyse des contenus provenant de la planète.
2. Donner un programme MapReduce qui permettrait d'exécuter ce programme Pig en distribué (indiquez la fonction de Map, la fonction de Reduce, dans le langage ou pseudo-code qui vous convient).
3. Ecrire un programme Pig latin qui produit, pour chaque planète et pour chaque jour, le rapport entre contenus structurés et non structurés reçus de cette planète.

Solution :

1. À la syntaxe près :

```
// On ne prend que les signaux avec contenu structuré
structurés = filter Signaux by fS(contenu) = true;
// On le regroupe par planète
signauxPlanete = group structurés by idPlanete;
// Maintenant, dans signauxPlanete, on a une liste de contenus structurés
// par planète: on applique le détecteur à cette liste
présenceAliens = foreach signauxPlanete generate group,
                        fD(signauxPlanete) as indicateur;
```

2. La fonction de Map émet les signaux pour lesquels $f_S(s) = true$. La clé des paires intermédiaires est celle sur laquelle on veut effectuer le regroupement, soit `idPlanète`.

```
function map(signal)
{
  if (fS(signal.contenu) == true) {
    emit (signal.idPlanète, signal.contenu)
  }
}
```

La fonction de Reduce reçoit l'id d'une planète, et la liste des contenus structurés. On applique `fD` à cette liste.

```
function reduce(idPlanète, [contenus])
{
  return (idPlanète, fD(contenus));
}
```

3. Un poil plus compliqué : on constitue la liste des contenus structurés, la liste des contenus non structurés, on les regroupe (`cogroup` va très bien pour ça) par planète et date, et on calcule le ratio.

```
structurés = filter Signaux by fS(contenu) == true;
nonstructurés = filter Signaux by fS(contenu) == false;
signauxClassés = cogroup structurés by (idPlanete,date),
                    nonstructurés by (idPlanete, date);
ratioStructurés = foreach signauxClassés
                    generate group, count(structurés) / count(nonstructurés) ;
```

Troisième partie : questions de cours (6 pts)

1. En recherche d'information, qu'est-ce que le rappel ? qu'est-ce que la précision ?
2. Deux techniques fondamentales vues en cours sont la réplication et le partitionnement. Rappelez brièvement leur définition, et indiquez leurs rôles respectifs. Sont-elles complémentaires ? Redondantes ?
3. Qu'est-ce qu'une architecture multi-nœuds, quels sont ses avantages et inconvénients ?
4. Vous avez 500 TOs de données, et vous pouvez acheter des serveurs pour votre *cloud* avec chacun 32 GO de mémoire et 10 TOs de disque. Le coût unitaire d'un serveur est de 500 Euros.
Quelle est la configuration de votre grappe de serveurs la moins coûteuse (financièrement) et combien de temps prend au minimum la lecture complète de la collection avec cette solution ?

Solution : Il faut au minimum 50 serveurs, soit 25 000 Euros. La lecture en parallèle de disques de 10 TO prend (à 100 MO/s) plus de 20 heures.

On peut ajouter la réplication (facteur 2 ou 3) au calcul.

5. Même situation : quelle est la configuration qui assure le maximum d'efficacité, et quel est son coût financier ?

Solution : L'idéal est de tout stocker en RAM. mais là il faut $\frac{500000}{32} = 15625$ serveurs au minimum.

6. Rappelez le principe de l'éclatement d'un fragment dans le partitionnement par intervalle.