

Examen NFE204 - Session 2

14 avril 2015

Consignes

Durée de l'examen : 3h00

Documents non autorisés ; Calculatrice autorisée

Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.

Ce sujet contient 2 pages.

Important : nous n'évaluons pas les réponses par la syntaxe. Ne vous inquiétez pas d'utiliser un point-virgule à la place d'un point d'exclamation ou autres détails mineurs

Première partie : recherche d'information (8 pts)

d_1 Le loup et les trois petits cochons.

d_2 Spider Cochon, Spider Cochon, il peut marcher au plafond. Est-ce qu'il peut faire une toile ? Bien sûr que non, c'est un cochon.

d_3 Un loup a mangé un mouton, les autres moutons sont restés dans la bergerie.

d_4 Il y a trois moutons dans le pré, et un autre dans la gueule du loup.

d_5 L'histoire extraordinaire des trois petits loups et du grand méchant cochon.

On va se limiter au vocabulaire loup, mouton, cochon.

1. Donnez la matrice d'incidence *booléenne* (seulement 0 ou 1) avec les termes en ligne (NB : on suppose une phase préalable de normalisation qui élimine les pluriels, majuscules, etc.)

Solution :

	d1	d2	d3	d4	d5
loup	1	0	1	1	1
mouton	0	0	1	1	0
cochon	1	1	0	0	1

2. Expliquez par quelle technique, avec cette matrice d'incidence, on peut répondre à la requête booléenne "loup et cochon mais pas mouton". Quel est le résultat ?

Solution : On fait un AND logique sur les vecteurs "loup" et "cochon" et sur la négation du vecteur "mouton".

3. Maintenant donnez une matrice d'incidence contenant les tf, et un tableau donnant les idf (sans le log), pour les trois termes précédents.

Solution :

	d1	d2	d3	d4	d5
loup 5/4	1	0	1	1	1
mouton 5/2	0	0	2	1	0
cochon 5/3	1	3	0	0	1

4. Donner les résultats classés par similarité cosinus basée sur les tf (on ignore l'idf) pour les requêtes suivantes.
- cochon ;
 - loup et mouton ;
 - loup et cochon.

Solution : Les normes

$$\|d_1\| = \sqrt{1+1}; \|d_2\| = \sqrt{3^2}; \|d_3\| = \sqrt{1+4}; \|d_4\| = \sqrt{1+1}, \|d_5\| = \sqrt{1+1}$$

Les cosinus (requête non normalisée).

$$\text{– cochon : } d1 : \frac{1}{\sqrt{2}}; d2 : \frac{3}{3}; d5 : \frac{1}{\sqrt{2}};$$

d2 est premier : il ne parle que de cochons. d1 et d5 sont à égalité.

– loup et mouton :

$$d1 : \frac{1}{\sqrt{2}}; d3 : \frac{1+2}{\sqrt{5}}; d4 : \frac{1+1}{\sqrt{2}}; d5 : \frac{1}{\sqrt{2}};$$

d4 est premier : il a le même équilibre entre les deux termes que la requête. d3 est plus orienté mouton que loup, les deux derniers ne parlent pas de mouton.

– loup et cochon

$$d1 : \frac{1+1}{\sqrt{2}}; d2 : \frac{3}{3}; d3 : \frac{1}{\sqrt{5}}; d4 : \frac{1}{\sqrt{2}}; d5 : \frac{1+1}{\sqrt{2}};$$

d1 et d5 sont en tête à égalité, devant d2, d4 et d3.

5. On ajoute le document d_6 : "Shaun le mouton : une nuit de cochon".

Quel est son score pour la requête "loup et mouton", quel autre document a le même score et qu'est-ce qui change si on prend en compte l'idf ?

Solution : d_6 obtient le même score que d_1 , mais l'emporte si on considère l'idf de "mouton" qui est plus élevé (5/3 en comptant d_6) que celui de "loup".

6. Pour la requête "loup et cochon" et les documents d_1 et d_5 , qu'est-ce qui change si on ne met pas de restriction sur le vocabulaire (tous les mots sont indexés) ?

Solution : Dans ce cas le plus petit document (d_1) l'emporte car sa norme est plus petite. Intuitivement : il parle plus *spécifiquement* de loup et de cochon que d_5 .

Seconde partie : Pig et MapReduce (6 pts)

Une organisation terroriste, le Spectre, envisage de commettre un attentat dans une station de métro. Heureusement, le MI5 dispose d'une base de données d'échanges téléphoniques et ses experts ont mis au point un décryptage qui identifie la probabilité qu'un message provienne du Spectre d'une part, et fasse référence à une station de métro d'autre part.

Après décryptage, les messages obtenus ont la forme suivante :

```
{
  "id": "x1970897",
  "émetteur": "Joe Shark",
  "contenu": "Hmm hmm hmmm",
  "probaSpectre": 0.6,
```

```
"station": "Covent Garden"  
}
```

Il y en a des milliards : vous avez quelques heures pour trouver la solution.

Questions.

1. Spécifier les deux fonctions du programme MapReduce qui va identifier la station-cible la plus probable. Ce programme doit sélectionner les messages émis par le Spectre avec une probabilité de plus de 70%, et produire, pour chaque station le nombre de tels messages où elle est mentionnée.
2. Quel est le programme Pig qui exprime ce traitement MapReduce ?
3. On veut connaître les 5 mots les plus couramment employés par chaque émetteur dans le contenu de ses messages. Expliquez, avec la formalisation de votre choix, comment obtenir cette information (vous avez le droit d'utiliser un opérateur de tri).

Solution :

- 1.

Troisième partie : questions de cours (6 pts)

1. En recherche d'information, que signifient les termes "faux positifs" et "faux négatifs" ?
2. Je soumetts une requête $t_1, t_2, \dots, t_n$. Quel est le poids de chaque terme dans le vecteur représentant cette requête ? La normalisation de ce vecteur est elle importante pour le classement (justifier) ?
3. Donnez trois bonnes raisons de choisir un système relationnel plutôt qu'un système NoSQL pour gérer vos données.
4. Donnez trois bonnes raisons de choisir un système NoSQL plutôt qu'un système relationnel pour gérer vos données.
5. Rappeler la règle du quorum (majorité des votants) en cas de partitionnement de réseau, et justifiez-la.
6. Dans un traitement MapReduce, peut-on toujours se contenter d'un seul *reducer* ? Avantages ? Inconvénients ?