

Sujet d'examen UE NFE204 - FOD Session 1

Année universitaire 2014-2015

Examen première session : 15 juin 2015

Consignes

Durée de l'examen : 3h00 ; Documents non autorisés ; Calculatrice autorisée

Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.

Ce sujet contient 2 pages.

Important : nous n'évaluons pas les réponses par la syntaxe. Ne vous inquiétez pas d'utiliser un point-virgule à la place d'un point d'exclamation ou autres détails mineurs

Première partie : documents structurés (6 pts)

Une application s'abonne à un flux de nouvelles dont voici un échantillon.

```
<?xml version="1.0" encoding="UTF-8" ?>

<myrss version="2.0">
  <channel>
    <item>
      <title>Angela et nous</title>
      <description>Un nouveau sommet entre la France et l'Allemagne
        est prévu en Allemagne la semaine prochaine pour relancer l'UE.
      </description>
      <links>
        <link>lemonde.fr</link>
        <link>lesechos.fr</link>
      </links>
    </item>
    <item>
      <title>L'Union en crise</title>
      <description> L'Allemagne, la France, l'Italie doivent à nouveau se
        réunir pour étudier les demandes de la Grèce.
      </description>
      <links>
        <link>lefigaro.fr</link>
      </links>
    </item>
    <item>
      <title>Alexis à l'action</title>
      <description>Le nouveau premier ministre de la Grèce
        a prononcé son discours d'investiture.
      </description>
      <links>
        <link>libe.fr</link>
      </links>
    </item>
    <item>
      <title>Nos cousins transalpins</title>
      <description>La France et l'Italie partagent plus qu'une frontière
        commune: le point de vue de l'Italie.
      </description>
      <links>
```

```

</myrss>
  </channel>
    </item>
      </links>
        <link>courrier.org</link>

```

Chaque nouvelle (`item`) résume donc un sujet et propose des liens vers des médias où le sujet est développé. Les quatre éléments `item` seront désignés respectivement par d1, d2, d3 et d4.

1. Donnez la forme arborescente de ce document (ne recopiez pas tous les textes : la structure du document suffit).
2. Proposez un format JSON pour représenter le même contenu (idem : la structure suffit).
3. Dans une base relationnelle, comment modéliser l'information contenue dans ce document ?
4. Quelle est l'expression XPath pour obtenir tous les éléments `link` ?
5. Quelle est l'expression XPath pour obtenir les titres des items dont l'un des `link` est `lemonde.fr` ?

Deuxième partie : recherche d'information (6 pts)

On veut indexer les nouvelles reçues de manière à pouvoir les rechercher en fonction d'un pays. Le vocabulaire auquel on se restreint est donc celui des noms de pays (Allemagne, France, Grèce, Italie).

1. Donnez une matrice d'incidence contenant les tf pour les quatre pays, et un tableau donnant les idf (sans appliquer le log). Mettez les noms de pays en ligne, et les documents en colonne.

Solution :

	d1	d2	d3	d4
Allemagne (2)	2	1	0	0
France (4/3)	1	1	0	1
Grèce (2)	0	1	1	0
Italie (2)	0	1	0	2

2. Donner les résultats classés par similarité cosinus basée sur les tf (on ignore l'idf) pour les requêtes suivantes. Expliquez brièvement le classement.
 - Italie ;
 - Allemagne et France ;
 - France et Grèce.

Solution : Les normes

– $\|d_1\| = \sqrt{4+1} = \sqrt{5}$; $\|d_2\| = \sqrt{1+1+1+1} = 2$; $\|d_3\| = \sqrt{1}$; $\|d_4\| = \sqrt{1+4} = \sqrt{5}$.

Les cosinus (requête non normalisée).

– Italie : $d_2 : \frac{1}{2} = 0,5$; $d_4 : \frac{2}{\sqrt{5}} \approx 0,89$

d4 est premier car il mentionne deux fois l'Italie.

– Allemagne et France

$d_1 : \frac{2+1}{\sqrt{5}}$; $d_2 : \frac{1+1}{2}$; $d_4 : \frac{1}{\sqrt{5}}$;

d1 est premier comme on pouvait s'y attendre : il parle exclusivement de la France et de l'Allemagne. Viennent ensuite d2 puis d4.

– France et Grèce.

$d_1 : \frac{1}{\sqrt{5}}$; $d_2 : \frac{2}{2}$; $d_3 : \frac{1}{1}$; $d_4 : \frac{1}{\sqrt{5}}$

d2 et d3 arrivent à égalité. Intuitivement, il parlent tous les deux "à moitié" de France et de Grèce. d1 et d4 parlent de France *ou* de Grèce et aussi des autres pays.

- Solution :** La Grèce a un idf plus élevé : d3 serait donc considéré come plus pertinent, car plus spécifique au besoin exprimé par la requête.