

Sujet d'examen UE NFE204 - FOD Session 1

Année universitaire 2014-2015

Examen première session : 15 juin 2015

Consignes

Durée de l'examen : 3h00 ; Documents non autorisés ; Calculatrice autorisée

Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.

Ce sujet contient 3 pages.

Important : nous n'évaluons pas les réponses par la syntaxe. Ne vous inquiétez pas d'utiliser un point-virgule à la place d'un point d'exclamation ou autres détails mineurs

Première partie : documents structurés (6 pts)

Une application s'abonne à un flux de nouvelles dont voici un échantillon.

```
<?xml version="1.0" encoding="UTF-8" ?>

<myrss version="2.0">
  <channel>
    <item>
      <title>Angela et nous</title>
      <description>Un nouveau sommet entre la France et l'Allemagne
        est prévu en Allemagne la semaine prochaine pour relancer l'UE.
      </description>
      <links>
        <link>lemonde.fr</link>
        <link>lesechos.fr</link>
      </links>
    </item>
    <item>
      <title>L'Union en crise</title>
      <description> L'Allemagne, la France, l'Italie doivent à nouveau se
        réunir pour étudier les demandes de la Grèce.
      </description>
      <links>
        <link>lefigaro.fr</link>
      </links>
    </item>
    <item>
      <title>Alexis à l'action</title>
      <description>Le nouveau premier ministre de la Grèce
        a prononcé son discours d'investiture.
      </description>
      <links>
        <link>libe.fr</link>
      </links>
    </item>
    <item>
      <title>Nos cousins transalpins</title>
      <description>La France et l'Italie partagent plus qu'une frontière
        commune: le point de vue de l'Italie.
      </description>
      <links>
```

```

</myrss>
  </channel>
    </item>
      </links>
        <link>courrier.org</link>

```

Chaque nouvelle (`item`) résume donc un sujet et propose des liens vers des médias où le sujet est développé. Les quatre éléments `item` seront désignés respectivement par d1, d2, d3 et d4.

1. Donnez la forme arborescente de ce document (ne recopiez pas tous les textes : la structure du document suffit).
2. Proposez un format JSON pour représenter le même contenu (idem : la structure suffit).
3. Dans une base relationnelle, comment modéliser l'information contenue dans ce document ?
4. Quelle est l'expression XPath pour obtenir tous les éléments `link` ?
5. Quelle est l'expression XPath pour obtenir les titres des items dont l'un des `link` est `lemonde.fr` ?

Deuxième partie : recherche d'information (6 pts)

On veut indexer les nouvelles reçues de manière à pouvoir les rechercher en fonction d'un pays. Le vocabulaire auquel on se restreint est donc celui des noms de pays (Allemagne, France, Grèce, Italie).

1. Donnez une matrice d'incidence contenant les tf pour les quatre pays, et un tableau donnant les idf (sans appliquer le log). Mettez les noms de pays en ligne, et les documents en colonne.
2. Donner les résultats classés par similarité cosinus basée sur les tf (on ignore l'idf) pour les requêtes suivantes. Expliquez brièvement le classement.
 - Italie ;
 - Allemagne et France ;
 - France et Grèce.
3. Reprenons la dernière requête, "France et Grèce" et les documents d2 et d3. Qu'est-ce que la prise en compte de l'idf changerait au classement ?

Troisième partie : MapReduce (4 pts)

Voici quelques analyses à exprimer avec MapReduce et Pig.

1. On veut compter le nombre de nouvelles consacrées à la Grèce publiées par chaque média. Décrivez le programme MapReduce (fonctions de Map et de Reduce) qui produit le résultat souhaité. Donnez le pseudo-code de chaque fonction, ou indiquez par un texte clair son déroulement. Vous disposez d'une fonction `contains($texte, $mot)` qui renvoie vrai si `$texte` contient `$mot`.
2. Quel est le programme Pig qui exprime ce traitement MapReduce ?

Quatrième partie : questions de cours (4 pts)

1. Expliquez les rôles de la réplication dans un système distribué. Quel est le plus important ?
2. Dans un traitement MapReduce, à quoi correspond l'opération dite de *shuffle* ?
3. Expliquez ce qui caractérise un système "analytique" d'une part, un système "temps réel" d'autre part. Donnez des exemples de chaque type de système.
4. Qu'est-ce qui peut amener à choisir XML ou JSON pour la représentation de documents structurés ? Citez, pour chaque format, 2 ou 3 spécificités.