

Sujet d'examen UE NFE204 - FOD Session 2

Année universitaire 2014-2015

Examen seconde session : 10 septembre 2015

Consignes

Durée de l'examen : 3h00 ; Documents non autorisés ; Calculatrice autorisée
Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.
Ce sujet contient 3 pages.
Important : nous n'évaluons pas les réponses par la syntaxe. Ne vous inquiétez pas d'utiliser un point-virgule à la place d'un point d'exclamation ou autres détails mineurs

Première partie : recherche d'information (8 pts)

Quelques extraits de recettes de cuisine.

- d_1 Mélanger le lait et trois œufs
- d_2 Assembler deux jaunes d'œuf et trois blancs d'œufs, battre vigoureusement et verser l'assemblage des œufs dans le moule
- d_3 Verser la moitié du sucre dans le lait, réserver l'autre moitié dans un bol.
- d_4 Faire caraméliser le sucre et le recouvrir ensuite avec le lait.
- d_5 Le pain perdu se fait aisément à base d'œufs et de lait.

On va se limiter au vocabulaire lait, sucre, œuf.

1. Donnez la matrice d'incidence *booléenne* (seulement 0 ou 1) avec les termes en ligne (NB : on suppose une phase préalable de normalisation qui élimine les pluriels, majuscules, etc.)

Solution :

	d1	d2	d3	d4	d5
lait	1	0	1	1	1
sucré	0	0	1	1	0
œuf	1	1	0	0	1

2. Expliquez par quelle technique, avec cette matrice d'incidence, on peut répondre à la requête booléenne "lait et œuf mais pas sucre". Quel est le résultat ?

Solution : On fait un AND logique sur les vecteurs "lait" et "œuf" et sur la négation du vecteur "sucre".

3. Maintenant donnez une matrice d'incidence contenant les tf, et un tableau donnant les idf (sans le log), pour les trois termes précédents.

Solution :

	d1	d2	d3	d4	d5
lait 5/4	1	0	1	1	1
sucré 5/2	0	0	2	1	0
œuf 5/3	1	3	0	0	1

4. Donner les résultats classés par similarité cosinus basée sur les tf (on ignore l'idf) pour les requêtes suivantes.
- œuf ;
 - lait et sucre ;
 - lait et œuf.

Solution : Les normes

– $\|d_1\| = \sqrt{1+1}$; $\|d_2\| = \sqrt{3^2}$; $\|d_3\| = \sqrt{1+4}$; $\|d_4\| = \sqrt{1+1}$, $\|d_5\| = \sqrt{1+1}$
 Les cosinus (requête non normalisée).

– œuf : $d_1 : \frac{1}{\sqrt{2}}$; $d_2 : \frac{3}{3}$; $d_5 : \frac{1}{\sqrt{2}}$;

d_2 est premier : il ne parle que de œufs. d_1 et d_5 sont à égalité.

– lait et sucre :

$d_1 : \frac{1}{\sqrt{2}}$; $d_3 : \frac{1+2}{\sqrt{5}}$; $d_4 : \frac{1+1}{\sqrt{2}}$; $d_5 : \frac{1}{\sqrt{2}}$;

d_4 est premier : il a le même équilibre entre les deux termes que la requête. d_3 est plus orienté sucre que lait, les deux derniers ne parlent pas de sucre.

– lait et œuf

$d_1 : \frac{1+1}{\sqrt{2}}$; $d_2 : \frac{3}{3}$; $d_3 : \frac{1}{\sqrt{5}}$; $d_4 : \frac{1}{\sqrt{2}}$; $d_5 : \frac{1+1}{\sqrt{2}}$;

d_1 et d_5 sont en tête à égalité, devant d_2 , d_4 et d_3 .

5. On ajoute le document d_6 : "Une recette sans sucre ni œuf".

Quel est son score pour la requête "lait et sucre", quel autre document a le même score et qu'est-ce qui change si on prend en compte l'idf ?

Solution : d_6 obtient le même score que d_1 , mais l'emporte si on considère l'idf de "sucre" qui est plus élevé (6/3 en comptant d_6) que celui de "lait" (6/4 en comptant d_6).

6. Pour la requête "lait et œuf" et les documents d_1 et d_5 , qu'est-ce qui change si on ne met pas de restriction sur le vocabulaire (tous les mots sont indexés) ?

Solution : Dans ce cas le plus petit document (d_1) l'emporte car sa norme est plus petite. Intuitivement : il parle plus *spécifiquement* de lait et de œuf que d_5 .

Seconde partie : MapReduce (6 pts)

On veut étudier les températures à partir de relevés géo-localisés effectués par des capteurs répartis sur un territoire. Ces capteurs transmettent des relevés de température qui ont la forme suivante :

Relevé (idCapteur, loc, date, température)

Où loc est la localisation du capteur. Les relevés sont stockés dans un très gros entrepôt de données. On vous demande de concevoir les traitements suivants avec une approche MapReduce. Donnez la spécification des fonctions de Map et de Reduce ou, à défaut, la description la plus rigoureuse possible.

Questions.

1. Produire la moyenne des températures par capteur pour une période *per* données (on suppose une fonction booléenne $f(date, per)$ qui renvoie vrai ssi $date \in per$).
2. Produire la moyenne des températures par mois pour l'ensemble des capteurs (on suppose une fonction $f(d) : m$ qui prend en entrée une date et fournit en sortie le mois).

3. On suppose maintenant connue une table *Région(nom, zone)* qui donne la zone géographique couverte par une région. Cette table est suffisamment petite pour tenir en mémoire RAM d'un serveur.

Comment obtenir la moyenne des températures sur une région avec MapReduce ? De quelle fonction avez-vous besoin ? Comment faut-il gérer la table *Région* dans le protocole de distribution ? Indiquez le plus précisément possible comment vous effectueriez ce calcul distribué.

Solution :

- 1.

Troisième partie : questions de cours (6 pts)

1. En recherche d'information, qu'est-ce que le rappel ? qu'est-ce que la précision ?
2. Rappeler la règle du quorum (majorité des votants) en cas de partitionnement de réseau, et justifiez-là.
3. Expliquez les rôles de la réplication dans un système distribué. Quel est le plus important ?
4. Dans un traitement MapReduce, à quoi correspond l'opération dite de *shuffle* ?
5. Qu'est-ce qu'une architecture multi-nœuds, quels sont ses avantages et inconvénients ?
6. Rappelez le principe de l'éclatement d'un fragment dans le partitionnement par *consistent hashing*.