

Sujet d'examen UE NFE204

Année universitaire 2015-2016

Examen première session : 2 février 2016

Consignes

Durée de l'examen : 3h00 ; Documents non autorisés ; Calculatrice autorisée

Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.

Ce sujet contient 3 pages.

Important : nous n'évaluons pas les réponses par la syntaxe. Ne vous inquiétez pas d'utiliser un point-virgule à la place d'un point d'exclamation ou autres détails mineurs

Première partie : documents structurés (6 pts)

Nous gérons un site de commerce électronique qui recense des restaurants et permet à des internautes de les noter. Pour l'instant nous utilisons un système relationnel, dont voici le schéma (très simplifié).

- Restaurant (**id**, nom)
- Internaute (**id**, nom)
- Notation (*idRestau*, *idInternaute*, note, commentaire)

Voici également un tout petit échantillon de la base.

id	nom	id	nom	<i>idRestau</i>	<i>idInternaute</i>	note	commentaire
20	Aux délices	100	Marie	20	100	1	Nul
21	Le régal	101	Adrien	20	101	5	Parfait
				21	101	3	Moyen

La table *Restaurant* La table *Internaute* La table *Notation*

On décide de remplacer la base relationnelle par une base NoSQL.

1. Donnez une représentation de l'échantillon ci-dessus en XML ou en JSON, au choix. Nous l'appellerons représentation A.
2. Proposez une autre représentation, différente de la première. Nous l'appellerons représentation B.
3. On veut mener une analyse du comportement de chaque utilisateur : quelle est la représentation la plus adaptée parmi les deux que vous avez proposées, et pourquoi ?
4. Est-il possible de passer de la représentation A à la représentation B par un traitement Map Reduce ? Expliquez comment, en indiquant ce que font les fonctions de Map et de Reduce.

Deuxième partie : recherche d'information (8 pts)

Les documents sont les commentaires sur les restaurants ("document" et "commentaire" sont synonymes dans ce qui suit). On va travailler sur l'échantillon suivant.

- c_1 Plats médiocres, bonne carte des vins, accueil cordial.
- c_2 Le vin est moyen, les desserts sont mauvais, mais le décor est agréable.
- c_3 En général, le vin est trop cher au restaurant, mais ici la carte des vins est complète et de qualité.
- c_4 Passons sur le décor d'un goût douteux. Les plats et desserts sont délicieux, c'est tout ce qui compte après tout.
- c_5 Plat, dessert et un verre de vin pour un prix correct. Le plat du jour est toujours intéressant.

On va se limiter au vocabulaire (vin, plat, décor, dessert). (NB : on suppose une phase préalable de normalisation qui élimine les pluriels, majuscules, etc.)

1. Donnez une matrice d'incidence contenant les tf, et un tableau donnant les idf (sans le log), pour les termes précédents. Placez les termes en ligne, les commentaires en colonne.

Solution :

	c1	c2	c3	c4	c5
vin 5/4	1	1	2	0	1
plat 5/3	1	0	0	1	2
décor 5/2	0	1	0	1	0
dessert 5/3	0	1	0	1	1

2. Donnez les normes des vecteurs représentant ces commentaires.

Solution : Les normes

– $\|c_1\| = \sqrt{1+1}$; $\|c_2\| = \sqrt{3}$; $\|c_3\| = \sqrt{4}$; $\|c_4\| = \sqrt{3}$, $\|c_5\| = \sqrt{6}$

3. Donner les résultats classés par similarité cosinus basée sur les tf (on ignore l'idf) pour les requêtes suivantes. Expliquez brièvement la raison du classement pour le premier document.

- plat;
- décor et dessert;
- vin et plat.

Solution : Les cosinus (requête non normalisée).

- plat : $c_1 : \frac{1}{\sqrt{2}}$; $c_4 : \frac{1}{\sqrt{3}}$; $c_5 : \frac{2}{\sqrt{6}}$;
- décor et dessert :
 $c_2 : \frac{1+1}{\sqrt{3}}$; $c_4 : \frac{1+1}{\sqrt{3}}$ $c_5 : \frac{1}{\sqrt{6}}$;
- vin et plat
 $c_1 : \frac{1+1}{\sqrt{2}}$; $c_2 : \frac{1}{\sqrt{3}}$; $c_3 : \frac{2}{\sqrt{3}}$ $c_4 : \frac{1}{\sqrt{3}}$ $c_5 : \frac{1+2}{\sqrt{6}}$;

4. Pour la dernière requête, "vin et plat", on constate que deux documents sont à égalité. Est-ce que cela change si on prend en compte l'idf, comment et pourquoi ?

Solution : Plat est un peu moins présent que vin dans la collection, ce qui amène à classer c4 avant c2.

5. Pour la requête "décor et dessert", et les documents c2 et c4, qu'est-ce qui change si on ne met pas de restriction sur le vocabulaire (tous les mots sont indexés) ?

Solution : Dans ce cas le plus petit document (c2) l'emporte car sa norme est plus petite. Intuitivement : il parle plus *spécifiquement* de décor et de dessert que c4.

6. On voudrait pouvoir mesurer les co-occurrences de termes, autrement dit produire un indicateur représentant la probabilité que deux termes apparaissent ensembles dans un même commentaire. Proposez une formule estimant cette probabilité et s'appuyant sur les informations présentes dans la matrice d'incidence.

Troisième partie : MapReduce (3 pts)

Nous recevons un flux de notes données à des restaurants dans un fichier `restaus.csv`. Il contient le nom du restaurant, de l'utilisateur, la note et le commentaire. Voici le début.

```
1,Le bougnat,100,4,"Plats médiocres ..."
2,Délices de Saïgon,100,2,"Desserts nuls..."
3,Le régat,101,4,"venez pour le décor"
..
```

Utilisant Pig latin, on charge cette collection avec la commande suivante :

```
restaus = LOAD 'restaus.csv' as (id,nom,internaute,note,commentaire);
```

Et on exécute le script Pig suivant :

```
coll1 = filter restaus by contains(commentaire, "dessert")
coll2 = group coll1 by internaute;
coll3 = foreach coll2 generate group, AVG(coll1.note);
```

1. Expliquez le résultat produit par ce script.
2. Comment ce script peut-il être traduit en MapReduce ? Donnez la fonction de Map et la fonction de Reduce, sous la forme de votre choix.

Solution :

Quatrième partie : questions de cours (3 pts)

Répondez à trois questions au choix parmi les suivantes.

1. En recherche d'information, que signifient les termes "faux positifs" et "faux négatifs" ?
2. Je soumetts une requête $t_1, t_2, \dots, t_n$. Quel est le poids de chaque terme dans le vecteur représentant cette requête ? La normalisation de ce vecteur est elle importante pour le classement (justifier) ?
3. Dans un traitement MapReduce, à quoi correspond l'opération dite de *shuffle* ?
4. Dans quelle architecture peut-on aboutir à des écritures conflictuelles ? Donnez un exemple.
5. Dans un système distribué avec partitionnement, je décide de partitionner ma collection de films sur le genre. Discuter des avantages et inconvénients de ce choix.
6. Dans un système distribué avec partitionnement, une structure de routage indexe les fragments. Pourquoi ne pas indexer directement les documents eux-mêmes ?