

Sujet d'examen UE NFE204

Année universitaire 2015-2016

Examen seconde session FOD : vendredi 9 septembre 2016

Consignes

Durée de l'examen : 3h00 ; Documents non autorisés ; Calculatrice autorisée

Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.

Ce sujet contient 3 pages.

Important : nous n'évaluons pas les réponses par la syntaxe. Ne vous inquiétez pas d'utiliser un point-virgule à la place d'un point d'exclamation ou autres détails mineurs

Première partie : documents structurés (6 pts)

Nous gérons un site de commerce électronique qui propose des services de co-voiturage. Nous commençons avec des objectifs modestes (quelques milliers de clients) et la base relationnelle suivante :

- Conducteur (**id**, nom)
- Client (**id**, nom)
- Trajet (*idConducteur*, *idClient*, tarif)

Voici également un tout petit échantillon de la base.

id	nom	id	nom	<i>idConducteur</i>	<i>idClient</i>	tarif
1	Albert	100	Berthe	20	100	1
2	Aline	101	Eugène	20	101	5
				21	101	3

La table *Conducteur* La table *Client* La table *Trajet*

L'application est un très grand succès, avec des millions de clients. On décide de remplacer la base relationnelle par une base NoSQL. Plusieurs modélisations sont alors envisagables.

1. Donnez une première représentation de l'échantillon ci-dessus dans laquelle chaque document représente une entité "client". Nous l'appellerons représentation A.
2. Proposez une autre représentation, toujours en JSON, centrée non plus sur les clients mais sur les entités "conducteur". Nous l'appellerons représentation B.
3. On veut calculer par un traitement MapReduce le tarif moyen des trajets par conducteur. Choisissez la représentation (A ou B) la plus adaptée du point de vue des performances, et donnez les fonctions de Map et de Reduce dans la syntaxe de votre choix.
4. Justifiez le choix de la représentation, A ou B, pour le calcul précédent. Indiquez en particulier où se situe le gain de performance attendue pour la représentation choisie : au niveau du Map ? du Reduce ? Autre ?
5. Est-il possible de passer de la représentation A à la représentation B par un traitement Map Reduce ? Expliquez comment, en indiquant ce que font les fonctions de Map et de Reduce.

Deuxième partie : recherche d'information (8 pts)

L'application enregistre des commentaires déposés par les clients sur les conducteurs, et réciproquement. Voici un échantillon.

- c_1 Conduite dangereuse, et conducteur bavard. À éviter.
- c_2 Pour la conduite ça ne va pas : le conducteur (sympa par ailleurs) réussit à être à la fois lent et dangereux
- c_3 Trop dangereux ! Je veux bien payer pour un co-voiturage, mais pas avec un conducteur dangereux.
- c_4 Sympa, mais le conducteur est très bavard et lent.
- c_5 Il est vraiment bavard de chez bavard. Heureusement, sympa et rien de dangereux dans sa conduite.

On va se limiter au vocabulaire (dangereux, bavard, lent, sympa). (NB : on suppose une phase préalable de normalisation qui élimine les pluriels, majuscules, trouve que “sympa” et “sympathique”, “dangereux” et “dangereuse”, sont les mêmes mots, etc.)

1. Donnez une matrice d'incidence contenant les tf, et un tableau donnant les idf (sans le log), pour les termes précédents. Placez les termes en ligne, les commentaires en colonne.

Solution :

	c1	c2	c3	c4	c5
dangereux 5/4	1	1	2	0	1
bavard 5/3	1	0	0	1	2
lent 5/2	0	1	0	1	0
sympa 5/3	0	1	0	1	1

2. Donnez les normes des vecteurs représentant ces commentaires.

Solution : Les normes

$$- \|c_1\| = \sqrt{1+1}; \|c_2\| = \sqrt{3}; \|c_3\| = \sqrt{4}; \|c_4\| = \sqrt{3}, \|c_5\| = \sqrt{6}$$

3. Donner les résultats classés par similarité cosinus basée sur les tf (on ignore l'idf) pour les requêtes suivantes. Expliquez brièvement la raison du classement pour le premier document.

- bavard ;
- lent et sympa ;
- dangereux et bavard.

Solution : Les cosinus (requête non normalisée).

$$- \text{bavard} : c_1 : \frac{1}{\sqrt{2}}; c_4 : \frac{1}{\sqrt{3}}; c_5 : \frac{2}{\sqrt{6}};$$

- lent et sympa :

$$c_2 : \frac{1+1}{\sqrt{3}}; c_4 : \frac{1+1}{\sqrt{3}}; c_5 : \frac{1}{\sqrt{6}};$$

- dangereux et bavard

$$c_1 : \frac{1+1}{\sqrt{2}}; c_2 : \frac{1}{\sqrt{3}}; c_3 : \frac{2}{\sqrt{3}}; c_4 : \frac{1}{\sqrt{3}}; c_5 : \frac{1+2}{\sqrt{6}};$$

4. Pour la dernière requête, “dangereux et bavard”, on constate que deux documents sont à égalité. Est-ce que cela change si on prend en compte l'idf, comment et pourquoi ?

Solution : bavard est un peu moins présent que dangereux dans la collection, ce qui amène à classer c_4 avant c_2 .

5. Pour la requête “lent et sympa”, et les documents c_2 et c_4 , qu'est-ce qui change si on ne met pas de restriction sur le vocabulaire (tous les mots sont indexés) ?

Solution : Dans ce cas le plus petit document (c4) l'emporte car sa norme est plus petite. Intuitivement : il parle plus *spécifiquement* de lent et de sympa que c2.

6. On voudrait pouvoir mesurer les co-occurrences de termes, autrement dit produire un indicateur représentant la probabilité que deux termes apparaissent ensemble dans un même commentaire. Proposez une formule estimant cette probabilité et s'appuyant sur les informations présentes dans la matrice d'incidence.

Troisième partie : Pig et MapReduce (3 pts)

Nous recevons un flux de commentaires dans un fichier `trajets.csv`. Il contient l'identifiant du conducteur, du client, et le commentaire. Voici le début.

```
1, 101, "Voiture bruyante"
1, 103, "Une vraie épave"
2, 101, "La voiture est propre, plus que le conducteur..."
..
```

Utilisant Pig latin, on charge cette collection avec la commande suivante :

```
trajets = load 'trajets.csv' as (idConducteur, idClient, commentaire);
```

Et on exécute le script Pig suivant :

```
coll1 = filter trajets by contains(commentaire, "voiture")
coll2 = group coll1 by idConducteur;
coll3 = foreach coll2 generate group, COUNT(coll1.commentaire);
```

1. Expliquez le résultat produit par ce script.
2. Comment ce script peut-il être traduit en MapReduce ? Donnez la fonction de Map et la fonction de Reduce, sous la forme de votre choix.
3. Quelle serait la requête SQL correspondant à ce script Pig ?

Quatrième partie : questions de cours (3 pts)

1. Qu'est-ce qui peut justifier de passer de la base relationnelle à un système NoSQL ? Discuter des avantages et inconvénients, donner l'ordre de grandeur du volume à partir duquel cette migration pourrait se justifier.
2. Dans une structure de hachage distribué, à quoi correspond la notion de serveur virtuel et quel est son intérêt ?
3. Que pensez-vous de l'affirmation suivante : *la réplication sert essentiellement à améliorer les temps de lecture* ?