

Sujet d'examen UE NFE204

Année universitaire 2016-2017

Examen seconde session FOD : 9 septembre 2017

Consignes

Durée de l'examen : 3h00 ; Documents non autorisés ; Calculatrice autorisée
Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.
Ce sujet contient 3 pages.
Important : nous n'évaluons pas les réponses par la syntaxe. Ne vous inquiétez pas d'utiliser un point-virgule à la place d'un point d'exclamation ou autres détails mineurs

Première partie : documents structurés et MapReduce (6 pts)

Le service informatique du Cnam a décidé de représenter ses données sous forme de documents structurés pour faciliter les processus analytiques. Voici un exemple de documents centrés sur les étudiant.e.s et incluant les Unités d'Enseignement (UE) suivies par chacun.e.

```
{
  "_id": 978,
  "nom": "Jean Dujardin",
  "annee": "2016",
  "UE": [{ "ue:11", "note": 12,
           { "ue:27", "note": 17 },
           { "ue:37", "note": 14 }
        ]
}
{
  "_id": 476,
  "nom": "Vanessa Paradis",
  "annee": "2016",
  "UE": [{ "ue:13", "note": 17 },
           { "ue:27", "note": 10 },
           { "ue:76", "note": 11 }
        ]
}
```

1. Sachant que ces documents sont produits à partir d'une base relationnelle, reconstituez le schéma de cette base et indiquez le contenu des tables correspondant aux documents ci-dessus.
2. Proposez une autre représentation des mêmes données, centrée cette fois, non plus sur les étudiants, mais sur les UEs.
3. On veut implanter, par un processus MapReduce, le calcul de la moyenne des notes d'un étudiant pour l'année 2016. Quelle est la représentation la plus appropriée parmi les trois précédentes (une en relationnel, deux en documents structurés), et pourquoi ?

- Spécifiez le calcul du nombre d'étudiants par UE pour une année donnée, en MapReduce, en prenant en entrée des documents centrés sur les étudiants (exemple donné ci-dessus).
- Quelle serait la requête SQL correspondant à ce dernier calcul sur la base relationnelle ?

Deuxième partie : recherche d'information (7 pts)

Voici des descriptifs (abrégés) d'UEs.

- c_1 On étudie les systèmes d'information construits en java.
- c_2 L'UE est consacrée aux interfaces java d'analyse de données dans les bases nosql.
- c_3 Les *design patterns* en Java et leur implantation dans les *frameworks* java 2.
- c_4 On montre que les systèmes nosql sont bien adaptés à l'analyse de grandes collections.
- c_5 On étudie les systèmes java en premier lieu, puis les systèmes d'analyse en second lieu

On va se limiter au vocabulaire (java, système, nosql, analyse). (NB : on suppose une phase préalable de normalisation qui élimine les pluriels, majuscules, etc.)

- Donnez une matrice d'incidence contenant les tf, et un tableau donnant les idf (sans le log), pour les termes précédents. Placez les termes en ligne, les descriptifs en colonne.

Solution :

	c1	c2	c3	c4	c5
java 5/4	1	1	2	0	1
système 5/3	1	0	0	1	2
nosql 5/2	0	1	0	1	0
analyse 5/3	0	1	0	1	1

- Donnez les normes des vecteurs représentant ces descriptifs.

Solution : Les normes

$$\|c_1\| = \sqrt{1+1}; \|c_2\| = \sqrt{3}; \|c_3\| = \sqrt{4}; \|c_4\| = \sqrt{3}, \|c_5\| = \sqrt{6}$$

- Donner la similarité cosinus basée sur les tf (on ignore l'idf) pour les requêtes suivantes. Expliquez brièvement la raison du classement obtenu.

- système ;
- nosql et analyse ;
- java et système.

Solution : Les cosinus (requête non normalisée).

$$\text{— système : } c_1 : \frac{1}{\sqrt{2}}; c_4 : \frac{1}{\sqrt{3}}; c_5 : \frac{2}{\sqrt{6}};$$

— nosql et analyse :

$$c_2 : \frac{1+1}{\sqrt{3}}; c_4 : \frac{1+1}{\sqrt{3}}; c_5 : \frac{1}{\sqrt{6}};$$

— java et système

$$c_1 : \frac{1+1}{\sqrt{2}}; c_2 : \frac{1}{\sqrt{3}}; c_3 : \frac{2}{\sqrt{3}}; c_4 : \frac{1}{\sqrt{3}}; c_5 : \frac{1+2}{\sqrt{6}};$$

- Pour la dernière requête, "java et système", on constate que deux documents sont à égalité. Est-ce que cela change si on prend en compte l'idf, comment et pourquoi ?

Solution : bash

système est un peu moins présent que java dans la collection, ce qui amène à classer c4 avant c2.

- En supposant que l'on décide que deux termes déjà présents dans la matrice sont synonymes, comment peut-on modifier les informations de cette dernière (tf et idf) pour en tenir compte, sans tout recalculer ?

Quatrième partie : systèmes distribués (4 pts)

On vous demande d'expliquer quelques-uns des principes du *consistent hashing*.

1. Expliquez comment on choisit le serveur sur lequel on place un document.
2. Pourquoi la structure est-elle basée sur un anneau ? Pourquoi pas un segment de droite par exemple ?
3. Pourquoi y a-t-il autant de valeurs sur l'anneau (2 puissance 64 typiquement) ? Pourquoi ne pas commencer avec 8 ou 16 valeurs, et augmenter ensuite ?
4. Quelle est l'utilité de la notion de nœud virtuel ?

Cinquième partie : questions de cours (3 pts)

1. Pourquoi faut-il stocker les paires intermédiaires sur disque dans un processus MapReduce ? Pourquoi ne peut-on directement les transmettre aux machines qui effectuent la phase de Reduce ?
2. Dans une ferme de serveur (*cloud*) est-il plus efficace échanger des données entre les mémoires RAM de deux serveurs distincts, ou entre la mémoire RAM et le disque d'un même serveur ?
3. Que pensez-vous de l'affirmation suivante : *la réplication sert essentiellement à améliorer les temps de lecture* ?