

Sujet d'examen UE NFE204 présentiel - Session 2

Année universitaire 2016-2017 – Examen seconde session : 4 avril 2017

Consignes

Durée de l'examen : 3h00 ; Documents non autorisés ; Calculatrice autorisée.
Ce sujet contient 2 pages.
Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.

Première partie : questions de cours (3 pts)

1. En recherche d'information, qu'est-ce que le rappel ? qu'est-ce que la précision ?
2. Rappeler la règle du quorum (majorité des votants) en cas de partitionnement de réseau, et justifiez-là.
3. Dans un traitement MapReduce, à quoi correspond l'opération dite de *shuffle* ?

Deuxième partie : documents structurés (6 pts)

Nous gérons un site de commerce électronique qui propose des services de co-voiturage. Nous commençons avec des objectifs modestes (quelques milliers de clients) et la base relationnelle suivante :

- Conducteur (**id**, nom)
- Client (**id**, nom)
- Trajet (**idConducteur**, **idClient**, tarif)

Voici également un tout petit échantillon de la base.

				<i>idConducteur</i>	<i>idClient</i>	tarif
id	nom	id	nom	1	100	1
1	Albert	100	Berthe	1	101	5
2	Aline	101	Eugène	2	101	3

La table *Conducteur* La table *Client* La table *Trajet*

On décide de remplacer la base relationnelle par une base NoSQL.

1. Donnez une première représentation de l'échantillon ci-dessus sous la forme d'un document JSON. Nous l'appellerons représentation A.
2. Proposez une autre représentation, toujours en JSON, différente de la première. Nous l'appellerons représentation B.
3. On veut calculer le tarif moyen des trajets, par conducteur (calcul C1) et par client (calcul C2). Indiquez pour chaque calcul la représentation (A ou B) la plus adapté et expliquez brièvement.
4. Est-il possible de passer de la représentation A à la représentation B par un traitement Map Reduce ? Expliquez comment, en indiquant ce que font les fonctions de Map et de Reduce.

Troisième partie : recherche d'information (6 pts)

Quelques extraits de recettes de cuisine.

- d_1 Mélanger le lait et trois œufs
- d_2 Assembler deux jaunes d'œuf et trois blancs d'œufs, battre vigoureusement et verser l'assemblage des œufs dans le moule
- d_3 Verser la moitié du sucre dans le lait, réserver l'autre moitié dans un bol.
- d_4 Faire caraméliser le sucre et le recouvrir ensuite avec le lait.
- d_5 Le pain perdu se fait aisément à base d'œufs et de lait.

On va se limiter au vocabulaire `lait`, `sucr`, `œuf`.

1. Donnez une matrice d'incidence contenant les `tf`, et un tableau donnant les `idf` (sans le `log`), pour les trois termes précédents. *Mettez les termes en ligne et les documents en colonne.*
2. Donner les résultats classés par similarité cosinus basée sur les `tf` (on ignore l'`idf`) pour les requêtes suivantes.
 - `œuf`;
 - `lait` et `sucr`;
 - `lait` et `œuf`.
3. On ajoute le document d_6 : "Une recette sans sucre ni œuf".
Quel est son score pour la requête "lait et sucre", quel autre document a le même score et qu'est-ce qui change si on prend en compte l'`idf`?
4. Pour la requête "lait et œuf" et les documents d_1 et d_5 , qu'est-ce qui change si on ne met pas de restriction sur le vocabulaire (tous les mots sont indexés)?

Quatrième partie : MapReduce (5 pts)

On veut étudier les températures à partir de relevés géo-localisés effectués par des capteurs répartis sur un territoire. Ces capteurs transmettent des relevés de température qui ont la forme suivante :

Relevé (`idCapteur`, `loc`, `date`, `température`)

Où `loc` est la localisation du capteur. Les relevés sont stockés dans un très gros entrepôt de données. On vous demande de concevoir les traitements suivants avec une approche MapReduce. Donnez la spécification des fonctions de Map et de Reduce ou, à défaut, la description la plus rigoureuse possible.

Questions.

1. Produire la moyenne des températures par capteur pour une période *per* données (on suppose une fonction booléenne $f(date, per)$ qui renvoie vrai ssi $date \in per$).
2. Produire la moyenne des températures par mois pour l'ensemble des capteurs (on suppose une fonction $f(d) : m$ qui prend en entrée une date et fournit en sortie le mois).
3. On suppose maintenant connue une table $Région(nom, zone)$ qui donne la zone géographique couverte par une région. Cette table est suffisamment petite pour tenir en mémoire RAM d'un serveur.
Comment obtenir la moyenne des températures sur une région avec MapReduce ? De quelle fonction avez-vous besoin ? Comment faut-il gérer la table $Région$ dans le protocole de distribution ? Indiquez le plus précisément possible comment vous effectueriez ce calcul distribué.