

Sujet d'examen UE NFE204 - Session 1

Année universitaire 2016-2017

Examen première session : 7 février 2017

Consignes

Durée de l'examen : 3h00 ; Documents non autorisés ; Calculatrice autorisée

Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.

Ce sujet contient 3 pages.

Important : nous n'évaluons pas les réponses par la syntaxe. Ne vous inquiétez pas d'utiliser un point-virgule à la place d'un point d'exclamation ou autres détails mineurs

Première partie : documents structurés (5 pts)

Un institut chargé d'analyser l'opinion publique collecte des articles parus dans la presse en ligne, ainsi que les commentaires déposés par les internautes sur ces articles. Ces informations sont stockées dans une base relationnelle, puis mises à disposition des analystes sous la forme de documents JSON dont voici deux exemples.

```
{
  "_id": 978,
  "_source": "lemonde.fr",
  "date": "07/02/2017",
  "titre": "Le président Trump décide d'interdire l'entrée de tout étranger aux USA",
  "contenu": "Suite à un décret paru ...",
  "commentaires": [
    {
      "internaute": "chocho@monsite.com",
      "note": 5,
      "commentaire": "Les décisions du nouveau président sont inquiétantes ..."
    },
    {
      "internaute": "alain@dugenou.com",
      "note": 2,
      "commentaire": "Arrêtons de critiquer ce grand homme..."
    }
  ]
}

{
  "_id": 54,
  "source": "nimportequoi.fr",
  "date": "07/02/2017",
  "titre": "La consommation de pétrole aide à lutter contre le réchauffement",
  "contenu": "Contrairement à ce qu'affirment les media officiels ...",
  "commentaires": [
    {
      "internaute": "alain@dugenou.com",
      "note": 5,
      "commentaire": "Enfin un site qui n'a pas peur de dire la vérité ..."
    }
  ]
}
```

Les notes vont de 1 à 5, 1 exprimant un fort désaccord avec le contenu de l'article, et 5 un accord complet.

1. À votre avis, quel est le schéma de la base relationnelle d'où proviennent ces documents ? Montrez comment les informations des documents ci-dessus peuvent être représentés avec ce schéma (ne recopiez pas tous les textes, donnez les tables avec quelques lignes montrant la répartition des données).
2. On collecte des informations sur les internautes (année de naissance, adresse). Où les placer dans la base relationnelle ? Dans le document JSON ?
3. On veut maintenant obtenir une représentation JSON centrée sur les internautes et pas sur les sources d'information. Décrivez le processus Map/Reduce qui transforme une collection de documents formatés comme les exemples ci-dessus, en une collection de documents dont chacun donne les commentaires déposés par un internaute particulier.

Deuxième partie : recherche d'information (4 pts)

On veut indexer les articles pour pouvoir les analyser en fonction des candidats qu'ils mentionnent. On s'intéresse en particulier à 4 candidats : Clinton, Trump, Sanders et Bush. Voici 4 extraits d'articles (ce sont nos documents d_1, d_2, d_3, d_4).

1. L'affrontement entre Trump et Clinton bat son plein. Clinton a-t-elle encore une chance ?
 2. Tous ces candidats, Clinton, Trump, Sanders et Bush, semblent encore en mesure de l'emporter.
 3. La surprise, c'est Sanders, personne ne l'attendait à ce niveau.
 4. Ce que Bush pense de Trump ? A peu de choses près ce que ce dernier pense de Bush.
1. Donnez une matrice d'incidence contenant les tf pour les quatre candidats, et un tableau donnant les idf (sans appliquer le log). Mettez les noms de candidats en ligne, et les documents en colonne.

Solution :

	d1	d2	d3	d4
Clinton (2)	2	1	0	0
Trump (4/3)	1	1	0	1
Sanders (2)	0	1	1	0
Bush (2)	0	1	0	2

2. Donner les résultats classés par similarité cosinus basée sur les tf (on ignore l'idf) pour les requêtes suivantes. Expliquez brièvement le classement.
 - Bush ;
 - Trump et Clinton
 - Trump et Sanders

Solution : Les normes

— $\|d_1\| = \sqrt{4+1} = \sqrt{5}$; $\|d_2\| = \sqrt{1+1+1+1} = 2$; $\|d_3\| = \sqrt{1}$; $\|d_4\| = \sqrt{1+4} = \sqrt{5}$.

Les cosinus (requête non normalisée).

— Bush : $d_2 : \frac{1}{2} = 0,5$; $d_4 : \frac{2}{\sqrt{5}} \approx 0,89$

d_4 est premier car il mentionne deux fois Bush.

— Trump et Clinton

$d_1 : \frac{2+1}{\sqrt{5}}$; $d_2 : \frac{1+1}{2}$; $d_4 : \frac{1}{\sqrt{5}}$;

d_1 est premier comme on pouvait s'y attendre : il parle exclusivement de Trump et Clinton. Viennent ensuite d_2 puis d_4 .

— Trump et Sanders

$d1 : \frac{1}{\sqrt{5}} ; d2 : \frac{2}{2} ; d3 : \frac{1}{1} d4 : \frac{1}{\sqrt{5}}$

$d2$ et $d3$ arrivent à égalité. Intuitivement, il parlent tous les deux "à moitié" de Trump et Sanders. $d1$ et $d4$ parlent de Trump *ou* de Sanders et aussi des autres candidats.

3. Reprenons la requête, "Trump et Clinton" et le premier document du classement. Quelle légère modification de ce document lui donnerait une mesure cosinus encore plus élevée ? Expliquez pourquoi.

Solution : Il suffit d'ajouter une fois la mention de Trump.

4. Je fais une recherche sur "Sanders". Pouvez-vous indiquer le classement sans faire aucun calcul ? Expliquez.

Troisième partie : systèmes distribués (3 pts)

On considère un système Cassandra avec un facteur de réplication $F = 3$ (donc, 3 copies d'un même document).

Appelons W le nombre d'acquittements reçus pour une écriture, R le nombre d'acquittements reçus pour une lecture.

1. Décrivez brièvement les caractéristiques des configurations suivantes :
 - (a) $R = 1, W = 3$
 - (b) $R = 1, W = 1$
2. Quelle est la formule sur R, W et F qui assure la cohérence immédiate (par opposition à la cohérence à terme) du système ? Expliquez brièvement.

Quatrième partie : MapReduce (4 pts)

Toujours sur nos documents donnés en début d'énoncé (première partie) : on veut analyser, pour la source "lemonde.fr", le nombre de commentaires ayant obtenus respectivement 1, 2, 3, 4 ou 5.

1. Décrivez la modélisation MapReduce de ce calcul. Donnez le pseudo-code de chaque fonction, ou indiquez par un texte clair son déroulement.
2. Donnez la forme de la chaîne de traitement (*workflow*), avec des opérateurs Pig ou Spark, qui implante ce calcul.

Quatrième partie : questions de cours (4 pts)

1. Qu'entend-on par "*bag of words*" pour le modèle des documents textuels en recherche d'information ?
2. Expliquez la notion de nœud virtuel dans la distribution par *consistent hashing*.
3. Que signifie, pour une structure de partitionnement, être *dynamique*. Avons-nous étudié un système où le partitionnement n'était pas dynamique ?
4. Donnez une définition de la scalabilité.