

Sujet d'examen UE NFE204 - Présentiel

Année universitaire 2017-2018

Examen seconde session : 17 avril 2018

Consignes

Durée de l'examen : 3h00 ; Documents non autorisés ; Calculatrice autorisée
Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.
Ce sujet contient 2 pages.
Important : nous n'évaluons pas les réponses par la syntaxe. Ne vous inquiétez pas d'utiliser un point-virgule à la place d'un point d'exclamation ou autres détails mineurs

L'ensemble de l'examen doit vous permettre de montrer que vous avez assimilé les principales notions vues en cours et en TP et que vous savez les mettre en application et les expliquer. La clarté, la concision, la précision des réponses seront donc appréciées.

Première partie : modélisation semi-structurée (6 pts)

Un grand magasin enregistre tous les tickets de caisse des transactions effectuées par ses clients. Un ticket de caisse comprend la date et l'heure de chaque transaction, le numéro de la caisse, le prix total, et la liste des articles achetés avec, pour chacun, la quantité et le prix unitaire. Le ticket de caisse comprend également l'identifiant du client si ce dernier a utilisé sa carte de fidélité. Sinon cet identifiant est à null.

1. Dans une base relationnelle, combien de tables faudrait-il pour représenter les informations d'un ticket de caisse (expliquer et donner le schéma de ces tables) ; combien d'insertions de ligne faut-il faire pour chaque ticket ?
2. Si on choisit une base NoSQL, comment représenter un ticket de caisse en JSON. Donnez un exemple simple. Combien d'insertions faut-il faire pour créer un ticket ?
3. Je veux compter le nombre de transactions par caisse et par jour. Quelle est la requête SQL si les données sont dans une base relationnelle ?
4. Même question si la base est NoSQL : comment calculer le nombre de transactions par caisse et par jour
5. Indiquez les avantages et inconvénients de chaque solution, relationnelle ou NoSQL.

Deuxième partie : MapReduce (3 pts)

Je veux calculer le montant moyen des tickets par client, pour les clients dont l'identifiant est non nul. Décrivez la modélisation MapReduce de ce calcul. Donnez le pseudo-code de chaque fonction, ou indiquez par un texte clair son déroulement.

Troisième partie : comprendre Elasticsearch (8 pts)

Voici quelques aspects d'Elastic Search qui devraient vous être familiers, et d'autres qui n'ont pas été abordés en cours

Indexation

La documentation nous dit : *When you index a document, it is stored on a single primary shard determined by a simple formula :*

$$\text{shard} = \text{hash}(\text{id}) \% \text{number_of_primary_shards}$$

Voici la configuration initiale de votre *cluster* Elasticsearch pour les questions qui suivent (rappel : réplica = n signifie $n + 1$ copies d'un document).

```
cluster.name: philippe
index.number_of_shards: 3
index.number_of_replicas: 2
```

Et je crée un index. Chacune des questions ci-dessous vaut 1 point. Une brève explication sera appréciée.

1. Est-ce que mon *cluster* peut être constitué d'un seul nœud (un seul serveur) ?
2. Est-ce que je peux augmenter le nombre de *shards* ?
3. Est-ce que je peux augmenter le nombre de réplicas ?
4. Est-ce que je peux ajouter des nœuds à mon *cluster* ?
5. Si oui, à partir de quand est-ce que ça ne sert plus à rien d'ajouter des nœuds, en prenant en compte la configuration initiale ?

Un dernier point à gagner. Un de vos collègues vous affirme qu'il vaut mieux créer un index avec beaucoup de *shards*, pour anticiper la croissance future. Voici un argument contre ce choix, issu de la documentation. *Term statistics, used to calculate relevance, are per shard. Having a small amount of data in many shards leads to poor relevance.*

Comment lui expliqueriez-vous cet argument dans un français clair et concis ? Voir aussi la seconde question ci-dessous.

Requêtes

1. On effectue une recherche dans un *cluster* Elasticsearch constitué de 10 fragments (primaires), et on veut récupérer le résultat par tranches de 10 documents. Combien le coordinateur de la requête doit-il récupérer de documents de chaque fragment au minimum pour constituer un résultat correct pour chaque tranche ?
2. Quelle information le coordinateur de la requête devrait-il propager à tous les fragments pour que le classement soit correct (oui cette question est liée à un extrait de la doc donné précédemment) ?

Quatrième partie : questions de cours (3 pts)

1. En recherche d'information, que signifient les termes "faux positifs" et "faux négatifs" ?
2. Rappeler la règle du quorum (majorité des votants) en cas de partitionnement de réseau, et justifiez-la.
3. Qu'entend-on par "bag of words" pour le modèle des documents textuels en recherche d'information ?