

Sujet d'examen UE NFE204

Session FOD

8 septembre 2018

Consignes

Durée de l'examen : 3h00 ; Documents non autorisés ; Calculatrice autorisée
Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.
Ce sujet contient 3 pages.

Première partie : documents structurés (6 pts)

Nous gérons un site de commerce électronique qui propose des services de co-voiturage. Nous commençons avec des objectifs modestes (quelques milliers de clients) et la base relationnelle suivante :

- Conducteur (**id**, nom)
- Client (**id**, nom)
- Trajet (**idConducteur**, **idClient**, tarif)

Voici également un tout petit échantillon de la base.

id	nom	id	nom	idConducteur	idClient	tarif
1	Albert	100	Berthe	1	100	1
2	Aline	101	Eugène	1	101	5
				2	101	3

La table *Conducteur* La table *Client* La table *Trajet*

On décide de remplacer la base relationnelle par une base NoSQL.

1. Donnez une première représentation de l'échantillon ci-dessus sous la forme d'un document JSON. Nous l'appellerons représentation A.
2. Proposez une autre représentation, toujours en JSON, différente de la première. Nous l'appellerons représentation B.
3. On veut calculer le tarif moyen des trajets, par conducteur (calcul C1) et par client (calcul C2). Indiquez pour chaque calcul la représentation (A ou B) la plus adaptée et expliquez brièvement.
4. Est-il possible de passer de la représentation A à la représentation B par un traitement Map Reduce ? Expliquez comment, en indiquant ce que font les fonctions de Map et de Reduce.

Deuxième partie : recherche d'information (7 pts)

Voici des descriptifs (abrégés) d'UEs proposées par le Cnam.

- c*₁ On étudie les systèmes d'information construits en java.
- c*₂ L'UE est consacrée aux interfaces java d'analyse de données dans les bases nosql.
- c*₃ Les *design patterns* en Java et leur implantation dans les *frameworks* java 2.
- c*₄ On montre que les systèmes nosql sont bien adaptés à l'analyse de grandes collections.
- c*₅ On étudie les systèmes java en premier lieu, puis les systèmes d'analyse en second lieu

On va se limiter au vocabulaire (java, système, nosql, analyse). (NB : on suppose une phase préalable de normalisation qui élimine les pluriels, majuscules, etc.)

1. Donnez une matrice d'incidence contenant les tf, et un tableau donnant les idf (sans le log), pour les termes précédents. Placez les termes en ligne, les descriptifs en colonne.

Solution :

	c1	c2	c3	c4	c5
java 5/4	1	1	2	0	1
système 5/3	1	0	0	1	2
nosql 5/2	0	1	0	1	0
analyse 5/3	0	1	0	1	1

2. Donnez les normes des vecteurs représentant ces descriptifs.

Solution : Les normes

$$\|c_1\| = \sqrt{1+1}; \|c_2\| = \sqrt{3}; \|c_3\| = \sqrt{4}; \|c_4\| = \sqrt{3}, \|c_5\| = \sqrt{6}$$

3. Donner la similarité cosinus basée sur les tf (on ignore l'idf) pour les requêtes suivantes. Expliquez brièvement la raison du classement obtenu.

- système ;
- nosql et analyse ;
- java et système.

Solution : Les cosinus (requête non normalisée).

$$\text{— système : } c_1 : \frac{1}{\sqrt{2}}; c_4 : \frac{1}{\sqrt{3}}; c_5 : \frac{2}{\sqrt{6}};$$

— nosql et analyse :

$$c_2 : \frac{1+1}{\sqrt{3}}; c_4 : \frac{1+1}{\sqrt{3}}; c_5 : \frac{1}{\sqrt{6}};$$

— java et système

$$c_1 : \frac{1+1}{\sqrt{2}}; c_2 : \frac{1}{\sqrt{3}}; c_3 : \frac{2}{\sqrt{3}}; c_4 : \frac{1}{\sqrt{3}}; c_5 : \frac{1+2}{\sqrt{6}};$$

4. Pour la dernière requête, "java et système", on constate que deux documents sont à égalité. Est-ce que cela change si on prend en compte l'idf, comment et pourquoi ?

Solution : bash

système est un peu moins présent que java dans la collection, ce qui amène à classer c4 avant c2.

5. En supposant que l'on décide que deux termes déjà présents dans la matrice sont synonymes, comment peut-on modifier les informations de cette dernière (tf et idf) pour en tenir compte, sans tout recalculer ?

Troisième partie : systèmes distribués (4 pts)

On vous demande d'expliquer quelques-uns des principes du *consistent hashing*.

1. Expliquez comment on choisit le serveur sur lequel on place un document.
2. Pourquoi la structure est-elle basée sur un anneau ? Pourquoi pas un segment de droite par exemple ?
3. Pourquoi y a-t-il autant de valeurs sur l'anneau (2 puissance 64 typiquement) ? Pourquoi ne pas commencer avec 8 ou 16 valeurs, et augmenter ensuite ?
4. Quelle est l'utilité de la notion de nœud virtuel ?

Quatrième partie : questions de cours (3 pts)

1. Pourquoi faut-il stocker les paires intermédiaires sur disque dans un processus MapReduce ? Pourquoi ne peut-on directement les transmettre aux machines qui effectuent la phase de Reduce ?
2. Dans une ferme de serveur (*cloud*) est-il plus efficace échanger des données entre les mémoires RAM de deux serveurs distincts, ou entre la mémoire RAM et le disque d'un même serveur ?
3. Que pensez-vous de l'affirmation suivante : *la réplication sert essentiellement à améliorer les temps de lecture* ?