

Sujet d'examen UE NFE204

Session FOD

30 juin 2018

Consignes

Durée de l'examen : 3h00 ; Documents non autorisés ; Calculatrice autorisée
Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.
Ce sujet contient 3 pages.

Première partie : modélisation semi-structurée (4 pts)

Un grand magasin enregistre tous les tickets de caisse des transactions effectuées par ses clients. Un ticket de caisse comprend la date et l'heure de chaque transaction, le numéro de la caisse, le prix total, et la liste des articles achetés avec, pour chacun, la quantité et le prix unitaire.

1. Dans une base relationnelle, combien de tables faudrait-il pour représenter les informations d'un ticket de caisse (expliquer et donner le schéma de ces tables) ; combien d'insertions de ligne faut-il faire pour chaque ticket ?
2. Si on choisit une base NoSQL, comment représenter un ticket de caisse en JSON. Donnez un exemple simple. Combien d'insertions faut-il faire pour créer un ticket ?
3. Je veux compter le nombre de transactions par caisse et par jour. Quelle est la requête SQL si les données sont dans une base relationnelle ?
4. Même question avec MapReduce : comment obtenir le nombre de transactions par caisse et par jour par un calcul distribué. Donnez les fonctions en pseudo-code ou, à défaut, une explication très précise.

Solution :

1. En relationnel, il faut 2 tables, une pour les tickets avec les champs `noCaisse`, `date`, `heure` et `prixTotal`, une autre pour les articles avec `idArticle`, `quantité` et `prixUnitaire`. Un champ `idClient` dans la table `Ticket` peut être à null. La table `Article` comprend une clé étrangère `idTicket` pour savoir de quel ticket l'achat de l'article fait partie.

Il faut une insertion dans la table `Ticket`, et autant d'insertions dans la table `Article` qu'il y a d'articles achetés dans une même transaction.

2. En JSON, par exemple :

```
{
  "_id": 978,
  "noCaisse": 12,
  "date": "01/01/2017",
  "heure": "13:30",
  "prixTotal": 58.47,
  "idClient": null,
  "articles": [
    {"idArticle": 1982, "quantité": 5, "prix": 10.45},
```

```

    { "idArticle": 34, "quantité": 1, "prix": 45},
    { "idArticle": 154, "quantité": 3, "prix": 3.02},
  ]
}

```

Une insertion suffit.

3. En SQL :

```

select count(*) from Ticket t, Article a
where a.idTicket = t.id
group by date, noCaisse

```

4. En NoSQL, il faut écrire et exécuter un programme MapReduce.

La fonction de Map émet une paire intermédiaire dont la clé est le critère de regroupement, soit la paire (date, numéro de caisse).

```

function fonctionMap ($ticket)
{
  emit ( [$ticket.date, $ticket.noCaisse], 1)
}

```

La fonction de Reduce effectue le compte des paires intermédiaires, autrement dit des tickets ayant même date et même numéro de caisse.

```

function fonctionReduce ($clé, $valeurs)
{
  return ($clé, count($valeurs))
}

```

Deuxième partie : calcul sur flux (3 pts)

Je veux obtenir, en continu, le montant total perçu par chaque caisse depuis l'ouverture du magasin le matin. Les tickets arrivent dans un flux réinitialisé chaque jour, et vous disposez d'un moteur de traitement distribué de flux ayant les mêmes fonctionnalités que celles vues en cours.

1. Décrivez le *workflow* qui implante ce calcul. Préciser les opérateurs, leur rôle, la nature des flux en entrée et en sortie.
2. Quel est le degré maximal de parallélisation de ce traitement (expliquez...) ?

Troisième partie : comprendre Elasticsearch (8 pts)

Voici quelques aspects d'Elastic Search qui devraient vous être familiers, et d'autres avancés qui n'ont pas été abordés en cours

Indexation

La documentation nous dit : *When you index a document, it is stored on a single primary shard determined by a simple formula :*

$$shard = hash(id) \% number_of_primary_shards$$

Voici la configuration de votre *cluster* Elasticsearch pour les questions qui suivent. Nb : *réplica* = *n* signifie *n + 1* copie d'un document.

```
cluster.name: philippe
index.number_of_shards: 3
index.number_of_replicas: 2
```

Et je crée un index. Chacune des questions ci-dessous vaut 1 point. Une brève explication sera appréciée.

1. Comment va réagir Elastic Search à votre avis si le *cluster* est constitué d'un seul nœud ?
2. Que faut-il faire pour étendre le nombre de *shards* ?
3. Que faut-il faire pour étendre le nombre de réplicas ?
4. Est-ce que je peux ajouter des nœuds à mon *cluster* ?
5. Si oui, à partir de quand est-ce que ça ne sert plus à rien d'ajouter des nœuds ?

Un dernier point à gagner. Un de vos collègues vous affirme qu'il vaut mieux créer un index avec beaucoup de *shards*, pour anticiper la croissance future. Voici un argument contre ce choix, issu de la documentation : *term statistics, used to calculate relevance, are per shard. Having a small amount of data in many shards leads to poor relevance.*

Comment lui expliqueriez-vous cet argument dans un français clair et concis ?

Requêtes

1. On effectue une recherche dans un *cluster* ElasticSearch constitué de 10 fragments (primaires), et on veut récupérer le résultat par tranches de 10 documents. Combien faut-il récupérer au minimum de documents de chaque fragment pour constituer un résultat correct pour chaque tranche ?
2. Quelle information le coordinateur de la requête devrait-il propager à tous les fragments pour que le classement soit correct (oui cette question est liée à un extrait de la doc donné précédemment) ?

Quatrième partie : structures distribuées (2 pts)

On met en place un système MongoDB qui applique un partitionnement par intervalle. La clé est l'identifiant des documents, engendrés par incrémentation d'un compteur.

1. On s'aperçoit que l'opération de *split* est toujours effectuée par le même serveur. Comment expliquez-vous cette situation ?
2. Si je mets en place un partitionnement par hachage, est-ce que je résous ce problème ? Expliquez.

Cinquième partie : questions de cours (3 pts)

1. En recherche d'information, que signifient les termes "faux positifs" et "faux négatifs" ?
2. Rappeler la règle du quorum (majorité des votants) en cas de partitionnement de réseau, et justifiez-la.
3. Qu'entend-on par "bag of words" pour le modèle des documents textuels en recherche d'information ?