

Sujet d'examen UE NFE204 - Session rattrapage

Année universitaire 2018-2019

Examen première session : avril 2019

Consignes

Durée de l'examen : 3h00 ; Documents non autorisés ; Calculatrice autorisée

Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.

Ce sujet contient 3 pages.

Important : nous n'évaluons pas les réponses par la syntaxe. Ne vous inquiétez pas d'utiliser un point-virgule à la place d'un point d'exclamation ou autres détails mineurs

Première partie : modélisation par documents structurés (7 pts)

Le Grand Débat a permis de collecter les contributions de beaucoup de Français. Le gouvernement a défini 5 sujets ("Impôts", "Transition écologique", etc.) et proposé un ensemble de questions pour chaque sujet (ex : "Payez-vous trop d'impôts" ou "Faut-il une taxe carbone") Chaque citoyen (anonymisé : on ne connaît que sa région de résidence) peut alors entrer sa contribution sous la forme d'un texte libre.




FIGURE 1 – Schéma de la base du Grand Débat

Les contributions sont stockées dans une base relationnelle dont le schéma est donné par la figure 1 en UML. Elles sont publiées ensuite sous la forme de documents JSON.

1. Donnez le schéma relationnel correspondant à la figure 1.
2. Donnez un exemple de base relationnelle avec quelques données (très simplifiées) dans chaque table : deux sujets, deux questions (une par sujet), trois contributions par deux citoyens.
3. Donnez une représentation JSON d'un document rassemblant toutes les informations (questions, contributions, citoyens) relatives au premier sujet que vous avez choisi.
4. Indiquez le traitement MapReduce qui permet de passer de la représentation précédente à une représentation centrée sur les citoyens.

5. Vous anticipez un très grand nombre de contributions et souhaitez donc prévoir un stockage des documents JSON dans un système distribué. Quelle est la représentation qui vous semble préférable parmi les deux précédentes ?
6. Vous développez un programme $ANALYSECONTRIB(d)$ qui s'applique à un document d contenant l'ensemble des contributions relatives à une question. Quel format ce document devrait-il avoir à votre avis pour atteindre une scalabilité maximale ? Comment obtenir un tel document à partir de l'une des représentations JSON déjà proposées ?

Deuxième partie : comprendre Elasticsearch (8 pts)

Voici quelques aspects d'Elastic Search qui devraient vous être familiers, et d'autres avancés qui n'ont pas été abordés en cours

Indexation

La documentation nous dit : *When you index a document, it is stored on a single primary shard determined by a simple formula :*

$$shard = hash(id) \% number_of_primary_shards$$

Voici la configuration de votre *cluster* Elasticsearch pour les questions qui suivent. Nb : réplica = n signifie $n + 1$ copies d'un document.

```
cluster.name: philippe
index.number_of_shards: 3
index.number_of_replicas: 2
```

Et je crée un index. Chacune des questions ci-dessous vaut 1 point. Une brève explication sera appréciée.

1. Comment va réagir Elastic Search à votre avis si le *cluster* est constitué d'un seul nœud ?
2. Que faut-il faire pour étendre le nombre de *shards* ?
3. Que faut-il faire pour étendre le nombre de réplicas ?
4. Est-ce que je peux ajouter des nœuds à mon *cluster* ?
5. A partir de quand devient-il inutile d'ajouter des nœuds ?

Un dernier point à gagner. Un de vos collègues vous affirme qu'il vaut mieux créer un index avec beaucoup de *shards*, pour anticiper la croissance future. Voici un argument contre ce choix, issu de la documentation : *term statistics, used to calculate relevance, are per shard. Having a small amount of data in many shards leads to poor relevance.*

Comment lui expliqueriez-vous cet argument dans un français clair et concis ?

Requêtes

1. On effectue une recherche dans un *cluster* Elasticsearch constitué de 10 fragments (primaires), et on veut récupérer le résultat par tranches de 10 documents. Combien faut-il récupérer au minimum de documents de chaque fragment pour constituer un résultat correct pour chaque tranche ?
2. Quelle information le coordinateur de la requête devrait-il propager à tous les fragments pour que le classement soit correct (oui cette question est liée à un extrait de la doc donné précédemment) ?

Troisième partie : systèmes distribués (3 pts)

On considère un système Cassandra avec un facteur de réplication $F = 3$ (donc, 3 copies d'un même document).

Appelons W le nombre d'acquittements reçus pour une écriture, R le nombre d'acquittements reçus pour une lecture.

1. Décrivez brièvement les caractéristiques des configurations suivantes :
 - (a) $R = 1, W = 3$
 - (b) $R = 1, W = 1$
2. Quelle est la formule sur R, W et F qui assure la cohérence immédiate (par opposition à la cohérence à terme) du système ? Expliquez brièvement.

Quatrième partie : questions de cours (3 pts)

1. Qu'entend-on par "*bag of words*" pour le modèle des documents textuels en recherche d'information ?
2. Expliquez la notion de nœud virtuel dans la distribution par *consistent hashing*.
3. Une structure de partitionnement par intervalle indexe des fragments contenant des documents. Pourquoi ne pas indexer les documents directement ?