

Sujet d'examen UE NFE204 FOAD - Session 2

Année universitaire 2019-2020, 5 septembre

Consignes. Cet examen est exceptionnellement organisé à distance. Vous devez rendre votre copie numérisée à 17h00 au plus tard. Aucune copie ne sera acceptée après cette heure limite. Les seuls formats acceptés sont le PDF et le JPEG, ceci afin d'éviter tout problème de lecture. Prenez vos dispositions pour être en mesure de fournir le bon format le moment venu. Une activité de discussion en direct (« *chat* ») est ouverte dans l'espace Moodle pour d'éventuelles questions.

1 Première partie : modélisation NoSQL (6 pts)

Nous créons une base généalogique dont voici l'unique table relationnelle (avec l'essentiel).

```
create table Personne
(
  id integer not null,
  nom varchar not null,
  idPère integer,
  idMère integer,
  primary key (id),
  foreign key (idPère) references Personne,
  foreign key (idMère) references Personne
)
```

Voici également un tout petit échantillon de la base.

id	nom	idPère	idMère
102	Charles IX	87	41
65	Laurent de Médicis		
87	Henri II	34	
34	François 1er		
97	Marguerite de Valois	87	41
41	Catherine de Médicis		65
43	François II	87	41

1. Proposez une représentation sous forme de document structuré (JSON ou XML) de l'entité Charles IX et de ses *ascendants*.
2. Que proposeriez-vous pour ajouter dans cette représentation la fratrie de Charles IX ? Discutez brièvement des avantages et inconvénients de votre solution.
3. Proposez une représentation sous forme de document structuré (JSON ou XML) de l'entité François 1er et de ses *descendants*.
4. Conclusion ? Vers quel type de base NoSQL vous tourneriez-vous et pour quelle raison ?

2 Seconde partie : MapReduce (10 pts)

Nous disposons d'une matrice M de dimension $N \times N$ représentant les liens entre les N pages du Web, chaque lien étant qualifié par un facteur d'importance (ou "poids"). La matrice est représentée par une collection C dans laquelle chaque document est de la forme $\{"id": i, "lig": j, "poids": m_{ij}\}$, et représente un lien entre la page P_i et la page P_j de poids m_{ij} .

Exemple : voici une matrice M avec $N = 4$. La première cellule de la seconde ligne est donc représentée par un document $\{"id": 1, "lig": 2, "col": 1, "poids": 7\}$

$$M = \begin{bmatrix} 1 & 2 & 3 & 4 \\ 7 & 6 & 5 & 4 \\ 6 & 7 & 8 & 9 \\ 3 & 3 & 3 & 3 \end{bmatrix}$$

Questions

1. On estime qu'il y a environ $N = 10^{10}$ pages sur le Web, avec 15 liens par page en moyenne. Quelle est la taille de la collection C , en TO, en supposant que chaque document a une taille de 16 octets ?
2. Nos serveurs ont 2 disques de 1 TO chacun et chaque document est répliqué 2 fois. Combien affectez-vous de serveurs au système de stockage ?
3. Chaque ligne L_i de M peut être vue comme un vecteur décrivant la page P_i . Spécifiez le traitement MapReduce qui calcule la norme de ces vecteurs à partir des documents de la collection C .
4. Nous voulons calculer le produit de la matrice avec un vecteur $V(v_1, v_2, \dots, v_N)$ de dimension N . Le résultat est un autre vecteur W tel que :

$$w_i = \sum_{j=1}^N m_{ij} \times v_j$$

On suppose pour le moment que V tient en mémoire RAM et est accessible comme variable statique par toutes les fonctions de Map ou de Reduce. Spécifiez le traitement MapReduce qui implante ce calcul.

5. Maintenant, on suppose que V ne tient plus en mémoire RAM. Proposez une méthode de partitionnement de la collection C et de V qui permette d'effectuer le calcul distribué de $M \times V$ avec MapReduce sans jamais avoir à lire le vecteur sur le disque.
Donnez le critère de partitionnement et la technique (par intervalle ou par hachage).
6. Supposons qu'on puisse stocker *au plus* deux (2) coordonnées d'un vecteur dans la mémoire d'un serveur. Inspirez-vous de la figure <http://b3d.bdpedia.fr/calculdistr.html#mr-execution-ex> pour montrer le déroulement du traitement distribué précédent en choisissant le nombre minimal de serveurs permettant de conserver le vecteur en mémoire RAM.
Pour illustrer le calcul, prenez la matrice 4×4 donnée en exemple, et le vecteur $V = [4, 3, 2, 1]$.
7. Expliquez pour finir comment calculer la similarité cosinus en V et les L_i .

Important : pour spécifier les chaînes de traitement, donner les fonctions de Map et de Reduce, en javascript, en Pig, en pseudo-code, au pire en langage naturel en étant le plus précis possible.

3 Troisième partie : recherche plein texte (4 pts)

Vous avez étudié dans le cours la notion d'*index inversé*. Quand un tel index doit être distribué sur plusieurs machines, deux choix de partitionnement sont possibles : partitionnement sur les termes ou partitionnement sur les documents.

1. Définissez brièvement (mais précisément) chaque mode de partitionnement
2. Pour chacune des affirmations ci-dessous, indiquez (et expliquez) pour la méthode de partitionnement elle est vraie
 - (a) L'insertion d'un document implique un seul serveur
 - (b) La recherche avec n termes implique au plus n serveurs
 - (c) La recherche implique tous les serveurs
 - (d) Le calcul du score d'un document pour une recherche implique une coordination par un nœud-maître.