

Sujet d'examen UE NFE204 FOAD - Session 1

Année universitaire 2019-2020, 30 juin

Consignes. Cet examen est exceptionnellement organisé à distance. Vous devez rendre votre copie numérisée à 21h00 au plus tard. Aucune copie ne sera acceptée après cette heure limite. Les seuls formats acceptés sont le PDF et le JPEG, ceci afin d'éviter tout problème de lecture. Prenez vos dispositions pour être en mesure de fournir le bon format le moment venu. Une activité de discussion en direct (« chat ») est ouverte dans l'espace Moodle pour d'éventuelles questions. Important : il y a 22 points en tout à gagner. Lisez soigneusement l'énoncé et choisissez l'ordre selon vos points forts.

1 Première partie : modélisation NoSQL et MapReduce (8 pts)

En période d'épidémie, nous voulons construire un système de prévention. Ce système doit être informé rapidement des nouvelles infections détectées, retrouver et informer rapidement les personnes ayant rencontré récemment une personne infectée, et détecter enfin les foyers infectieux (*clusters*). On s'appuie sur une application installée sur les téléphones mobiles. Elle fonctionne par *bluetooth* : quand deux personnes équipées de l'application sont proches l'une de l'autre, l'une d'entre elles (suivant un protocole d'accord) envoie au serveur un *message de contact* dont voici trois exemples :

```
{"_id": "7ytGy", "pseudo1": "xuyh57", "pseudo2": "jojoXYZ", "date": "30/06/2020"}
{"_id": "ui9xiuu", "pseudo1": "jojoXYZ", "pseudo2": "tat37HG", "date": "30/06/2020"}
{"_id": "Iuuu76", "pseudo1": "jojoXYZ", "pseudo2": "xuyh57", "date": "30/06/2020"}
```

Ce message contient donc un identifiant unique, les pseudonymes des deux personnes et la date de la rencontre. Un pseudonyme est une clé chiffrée identifiant une unique personne. Pour des raisons de sécurité, un nouveau pseudo est généré régulièrement et chaque application conserve *localement* la liste des pseudos engendrés. Les messages de contact (mais pas les listes de pseudos) sont stockés sur un serveur central dans une base DB_1 .

Questions

1. DB_1 est asymétrique (un pseudo est stocké parfois dans le champ `pseudo1`, parfois dans le champ `pseudo2`) et redondante puisque chaque contact apparaît plusieurs fois si deux personnes se sont rencontrés souvent dans la journée (cf. les exemples ci-dessus). Proposez un traitement de type MapReduce qui produit, à partir de la base DB_1 , une base DB_2 des *rencontres quotidiennes* contenant un document par pseudo et par jour, avec la liste des contacts effectués ce jour-là. Pour les exemples précédents, on devrait obtenir en ce qui concerne jojoXYZ :

```
{ "pseudo": "jojoXYZ",
  "date": "30/06/2020",
  "contacts": [{ "pseudo": "tat37HG", "count": 1 },
               { "pseudo": "xuyh57", "count": 2 } ]
}
```

Vous disposez d'une fonction `groupby()` qui prend un ensemble de valeurs et produit une liste contenant chaque valeur et son nombre d'occurrences. Par exemple `groupby(x, y, x, z, y, x) = [(x, 3), (y, 2), (z, 1)]`. Attention à l'asymétrie de représentation des pseudos dans les messages.

2. Voici quatre documents. les deux premiers sont stockés sur le serveur S_1 , le troisième sur le serveur S_2 , et le dernier sur le serveur S_3 .

— d_1 : {"_id": "X1", "pseudo1": "X1", "pseudo2": "X2", "date": "30/06/2020" }
 — d_2 : {"_id": "X3", "pseudo1": "X3", "pseudo2": "X2", "date": "30/06/2020" }
 — d_3 : {"_id": "X2", "pseudo1": "X2", "pseudo2": "X4", "date": "30/06/2020" }
 — d_4 : {"_id": "X1", "pseudo1": "X1", "pseudo2": "X4", "date": "30/06/2020" }

Inspirez-vous de la figure <http://b3d.bdpedia.fr/calculdistr.html#mr-execution-ex> pour montrer le déroulement du traitement MapReduce avec deux *reducers*.

3. Initialement la base DB_2 est relationnelle : quel est son schéma pour pouvoir représenter correctement le contenu des documents des rencontres quotidiennes ?
4. Vérifiez que votre schéma est correct en donnant le contenu des tables pour la rencontre du pseudo "jojoXYZ" le 30 juin (document ci-dessus).
5. Maintenant DB_2 est une base NoSQL documentaire et les rencontres sont stockées dans une collection *Rencontres*. Quand une personne est infectée, elle transmet au serveur la liste de ses pseudos. Voici par exemple la liste des pseudos conservés sur mon application mobile ::

`{"mesPseudos": ["jojoXYZ", "johj0N", "fjhukij87", "kodhvy"]}`

Tous les jours on stocke les listes dans une collection *Infections*. Donnez la chaîne de traitement qui construit la collection de tous les pseudos qui ont été en contact avec une personne infectée.

Important : pour spécifier les chaînes de traitement, donner les fonctions de Map et de Reduce, en javascript, en Pig, en pseudo-code, au pire en langage naturel en étant le plus précis possible.

2 Deuxième partie : recherche d'information (5 pts)

La base des rencontres peut être représentée comme une matrice dans laquelle chaque vecteur horizontal représente les rencontres effectuées par une personne dans le passé avec ses contacts. Nous considérons la matrice suivante. Notez qu'elle est symétrique et que nous plaçons sur la diagonale le nombre total de contacts effectués par une personne.

	tat37HG	xuyh57	jojoXYZ	Ubbdyu
tat37HG	5	1	1	3
xuyh57	1	3	2	0
jojoXYZ	1	2	3	0
Ubbdyu	3	0	0	3

On veut étudier les foyers infectieux en appliquant des méthodes vues en cours NFE204, et une ébauche de classification *kMeans*.

1. Donnez les normes des vecteurs.
2. On soupçonne que jojoXYZ et Ubbdyu sont à l'origine de deux foyers C_1 et C_2 . Donnez une mesure de distance basée sur la similarité cosinus entre ces deux pseudos, entre jojoXYZ et xuyh57 et finalement entre Ubbdyu et tat37HG. En déduire la composition des deux foyers.
3. Outre la fonction cosinus, on dispose d'une fonction *centroid*(G) qui calcule le centroïde d'un ensemble de vecteurs G .
 Quelle chaîne de traitement scalable permet de produire la classification de tous les pseudos dans l'un des deux foyers et d'obtenir les nouveaux centroïdes ?
4. La chaîne de traitement précédente doit être répétée jusqu'à convergence pour obtenir un *kMeans* complet. Si on travaille avec Spark, quelles informations devraient être conservées dans un RDD persistant selon vous ?

3 Troisième partie : analyse à grande échelle (5 pts)

On veut maintenant contrôler la propagation du virus grâce aux informations recueillies. On prend la matrice des rencontres suivantes (la même que précédemment mais cette fois la diagonale est à 0 puisqu'on s'intéresse à la transmission d'une personne à l'autre).

	tat37HG	xuyh57	jojoXYZ	Ubbdyu
tat37HG	0	1	1	3
xuyh57	1	0	2	0
jojoXYZ	1	2	0	0
Ubbdyu	3	0	0	0

Faisons quelques hypothèses simplificatrices :

1. le nombre de rencontres de chaque pseudo avec un contact représente la probabilité de rencontrer chacun des contacts. Par exemple, le premier document ci-dessus nous dit que jojoXYZ a deux fois plus de chances de rencontrer xuyh57 que de rencontrer tat37HG.
2. La liste des contacts est fixe.
3. Chaque personne fait exactement une rencontre par jour.

En résumé, chaque personne rencontre exactement un de ses 3 contacts, chaque jour, avec une probabilité proportionnelle à la fréquence antérieure des rencontres avec ces mêmes contacts.

1. Donnez la matrice des probabilités de contact obtenue à partir de la matrice des rencontres
2. Dessinez le graphe en étiquetant les arêtes par leur probabilité.
3. On reçoit l'information que jojoXYZ est infecté : quelle est la probabilité que Ubbdyu le soit également deux jours plus tard ?
4. Si l'une des personnes de notre groupe est infectée, expliquez comment on calcule les probabilités d'infection de chaque personne n jours plus tard. Donnez l'exemple de la première étape.

Quatrième partie : réplication et partitionnement (4 pts)

Donnez la solution de l'exercice <http://b3d.bdpedia.fr/sharding.html#ex-s3-1> (Ajout d'un serveur avec hachage cohérent).