

Sujet d'examen UE NFE204 - Session 1

Année universitaire 2019-2020

Examen première session : 4 février 2020

Consignes

Durée de l'examen : 3h00 ; Documents non autorisés ; Calculatrice autorisée

Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.

Ce sujet contient 3 pages.

Important : nous n'évaluons pas les réponses par la syntaxe. Ne vous inquiétez pas d'utiliser un point-virgule à la place d'un point d'exclamation ou autres détails mineurs

Première partie : modélisation NoSQL (7 pts)

Les articles de recherche universitaires sont maintenant gérés dans des dépôts d'archive, comme HAL en France. Posons-nous quelques questions sur le fonctionnement d'une telle archive. Un modèle très sommaire du dépôt est donné dans la figure 1. Les chercheurs publient des articles (qui peuvent avoir plusieurs co-auteurs) et sont *affiliés* à des organismes de recherche. Ces organismes sont hiérarchiquement structurés : un chercheur peut être attaché à une équipe (organisme de base), qui fait partie d'un laboratoire (organisme parent) qui lui-même fait partie d'un établissement (par exemple le Cnam), etc.




FIGURE 1 – Modèle (sommaire) du dépôt

Voici également un tout petit échantillon de la base relationnelle.

ref	titre	année
hal-875	Music modeling	2018
hal-293	Recommendations on Twitter	2019

La table *Article*

id	nom	affiliation	idAuteur	refArticle
nt	N. Travers	DVRC	hal-875	nt
pr	P. Rigaux	Vertigo	hal-293	nt
rfs	R. Fournier-S'niehotta	Vertigo	hal-875	pr
cdm	C. du Mouza	ISID	hal-875	rfs
			hal-293	cdm

La table *Chercheur*

La table des auteurs

1. Proposez un format de document JSON représentant toutes les informations relatives à l'article hal-875 présentes dans les trois tables ci-dessus (représentation A).
2. Proposez un document JSON représentant toutes les informations relatives à l'organisme Vertigo présentes dans 3 tables ci-dessus (représentation B).
3. Expliquez le calcul MapReduce permettant de produire les documents B à partir des documents A. **Important** : pour spécifier les calculs MapReduce, donner les fonctions de Map et de Reduce, en javascript, en pseudo-code, au pire en langage naturel en étant le plus précis possible.
4. Maintenant on prend en compte la table décrivant la hiérarchie des organismes, dont voici un échantillon.

id	intitulé	ville	idParent
Vertigo	Données et apprentissage	Paris	cedric
DVRC	Systèmes intelligents	Nanterre	De Vinci
ISID	Systèmes d'information	Paris	cedric
cedric	Centre informatique	Paris	Cnam

La table des organismes de recherche

Dessinez cette hiérarchie, et proposez une modélisation JSON pour ajouter l'information sur les organismes dans la représentation B. Illustrez cette modélisation sur le document "Vertigo" de la seconde question.

5. Les références bibliographiques sont gérées depuis des dizaines d'années dans un format texte dit Bibtex. Voici par exemple un document Bibtex représentant un article.

```
@article{frt-02435620,
  TITLE = {{Modeling Music as Synchronized Time Series}},
  AUTHOR = {Fournier-S'niehotta, Raphael and Rigaux, Philippe and Travers, Nicolas},
  URL = {https://hal-cnam.archives-ouvertes.fr/hal-02435620},
  JOURNAL = {{Information Systems}},
  PUBLISHER = {{Elsevier}},
  VOLUME = {73},
  PAGES = {35-49},
  YEAR = {2018},
}
```

Comment qualifieriez-vous ce format par rapport à JSON ? Voyez-vous des inconvénients, des avantages, à cette représentation ?

Deuxième partie : recherche d'information (8 pts)

Les articles ont des résumés, et on va construire un index sur ces résumés à des fins de classification et d'analyse. Voici un extrait des résumés de 5 articles $A_1, \dots, A_5$.

- A_1 Cet article compare les stratégies d'optimisation des échanges réseaux entre processeurs
- A_2 Un orchestre moderne doit savoir maîtriser une harmonie atonale
- A_3 Comparaison entre les propriétés des réseaux filaires et des réseaux optiques
- A_4 Pourquoi un processeur quantique ne peut surmonter un processeur standard qu'en présence d'un réseau performant
- A_5 Mozart est-il mieux servi par un orchestre de chambre ou un orchestre philharmonique ?

On va se limiter au vocabulaire (harmonie, processeur, réseau, orchestre). (NB : on suppose une phase préalable de normalisation qui élimine les pluriels, majuscules, etc.)

1. Donnez une matrice d'incidence contenant les tf, et un tableau donnant les idf (sans le log), pour les termes précédents. Placez les termes en ligne, les résumés en colonne.
2. Donnez les normes des vecteurs représentant ces résumés.
3. Dans un espace vectoriel à deux dimensions avec "processeur" en abscisse et "réseau" en ordonnée, placez les vecteurs représentant nos documents.
4. Donner les résultats classés par similarité cosinus basée sur les tf (on ignore l'idf) pour les requêtes suivantes. Détaillez les calculs.
 - processeur et réseau
 - harmonie et orchestre
5. Sans calcul, indiquez quel document est classé en tête pour la requête avec le seul mot "réseau", et expliquez pourquoi.
6. Indiquez la similarité cosinus de chaque paire de documents.
7. Des catégories d'article semblent-elles se dégager ? Combien, et quelle procédure de classification pourriez-vous proposer ?

Troisième partie : flux (2 pts)

Le dépôt reçoit un flux d'articles `fluxArt` avec leur résumé. On dispose d'une procédure de classification que nous appellerons `ClasserArticle(r)` : C. Elle prend en entrée un résumé `r` et produit une catégorie `C`.

On veut écrire un traitement de flux qui compte le nombre d'articles par catégorie. Pour rappel, voici le traitement vu en cours pour compter les mots

```
case class CompteurMot(mot: String, compteur: Int)
val stream = senv.socketTextStream("localhost", 9000, '\n')
val mots = stream.flatMap({ str => str.split("\\W+") })
    .map({ CompteurMot(_, 1) })
    .keyBy("mot")
    .reduce( (acc, occ)
      => {CompteurMot (acc.mot, acc.compteur + 1) })
    .print()
senv.execute("Le compteur de mots")
```

Proposez, sur cette base, le traitement comptant le nombre d'articles par catégorie. Vous pouvez, si vous le souhaitez, proposer une description textuelle des opérateurs successifs à appliquer, ou même un dessin commenté.

Quatrième partie : questions de cours (3 pts)

1. Que signifie, pour une structure de partitionnement, être dynamique. Avons-nous étudié un système où le partitionnement n'était pas dynamique ?
2. Quelles sont les opérations proposées par une ressource dans une architecture RESTful ?
3. Donnez une définition de la scalabilité.