

Sujet d'examen UE NFE204 - Session 1

Année universitaire 2021-2022

Examen session FOAD : 23 juin 2022

Première partie : modélisation NoSQL (8 pts)

Dans le monde d'après, il n'y a plus de presse, de quotidiens ou de magazines. Des journalistes indépendants, payés au caractère, écrivent des articles et les proposent à des plateformes de diffusion. Ces journalistes sont (faiblement) rémunérés en fonction du nombre de personnes qui lisent l'article sur ces plateformes.

Posons-nous quelques questions sur le fonctionnement de cette presse ubérisée. Un modèle UML très sommaire est donné dans la figure 1. Les journalistes publient des articles, et ces articles sont diffusés par des plateformes (plusieurs plateformes si possible, qui elles-mêmes publient beaucoup d'articles).




FIGURE 1 – Modèle (sommaire) de la diffusion d'articles ubérisés

Au départ, on représente tout cela avec une base relationnelle dont voici un tout petit échantillon.

ref	titre	année
ju21	Renaissance des insoumis ?	2022
ju798	Aura-t-on des vaccins pour Noël	2021

La table *Article*

id	nom
nt	N. Travers
pr	P. Rigaux
rfs	R. Fournier-S'niehotta
cdm	C. du Mouza

La table *Journaliste*

refArticle	idAuteur
ju21	cdm
ju21	pr
ju21	nt
ju798	pr

La table des publications

idPlateforme	nom
pj2	Béru
pj5	Croco
pj6	Vautour

La table des plateformes

s refArticle	idPlateforme
ju21	pj2
ju798	pj6
ju21	pj6

La table des diffusions

1. Proposez un format de document JSON représentant toutes les informations présentes dans les tables ci-dessus et relatives à l'auteur *P. Rigaux* (représentation A).
2. Proposez un document JSON représentant toutes les informations relatives à la plateforme *Vautour* présentes dans les tables ci-dessus (représentation B).
3. Expliquez le calcul MapReduce permettant de produire les documents de type B à partir des documents de type A.
Important : pour spécifier les calculs MapReduce, donner les fonctions de Map et de Reduce, en javascript, en pseudo-code, au pire en langage naturel en étant le plus précis possible.
4. On suppose que le contenu de la base est accessible à un processeur Pig latin sous forme de trois collections. La première collection est celle des articles avec des documents du type :

```
{ "ref" : "ju21", "titre": "Renaissance des insoumis?", "année": 2022 }
```

La collection des auteurs. Exemples :

```
{ "nom" : "P. Rigaux", "refArticle": "ju21" }
{ "nom" : "P. Rigaux", "refArticle": "ju798" }
```

Et enfin la collection des diffusions. Exemples :

```
{ "plateforme" : "Béru", "refArticle": "ju21" }
{ "plateforme" : "Vautour", "refArticle": "ju798" }
```

On veut obtenir, à partir de l'échantillon de base de données donné en début d'énoncé, un document représentant les informations sur un article :

```
{ "ref": "ju21",
  "titre" : "Renaissance des insoumis?",
  "année": 2022,
  "auteurs": [
    ],
  "plateformes": [
  ]
}
```

- (a) Donnez le contenu JSON des champs auteurs et plateformes d'après la base relationnelle de l'énoncé.
- (b) Quelle chaîne de traitement permet de passer des trois collections à la représentation sous forme de document ci-dessus ? Exprimez la chaîne de traitement avec des opérateurs (pas besoin d'un syntaxe complète, un texte précis ou un schéma commenté fait très bien l'affaire).
- (c) À votre avis combien faut-il d'opérations MapReduce successives pour effectuer ce calcul ?

Deuxième partie : flux (4 pts)

Chaque fois que quelqu'un lit un article sur une plateforme, un message est produit. Le format de ce message est le suivant :

```
{ "refArticle": "ju9", "contribution": 0.005 }
```

La contribution est le montant (en Euros) généré par cette lecture. Ces messages arrivent en un flux nommé *lectures*. On veut écrire un traitement de flux qui cumule le montant des contributions par article.

1. En vous inspirant des chaînes de traitement sur les flux vues dans le dernier chapitre du cours, indiquez comment on maintient, pour chaque article, le cumul des contributions.
2. On veut rémunérer les auteurs d'articles toutes les 6 heures. Quelle est la technique à utiliser pour obtenir le montant ?
3. Quelle est la parallélisation maximale permise par ce traitement ?

Troisième partie : recherche d'information (8 pts)

Voici un échantillon du flux de nouvelles sur les élections régionales.

1. (d1) La Corse et l'Alsace sont deux régions pourvu d'une forte identité et d'une langue régionale. L'Alsace est plus calme...
2. (d2) L'Alsace, la Corse, et la Normandie n'ont pas grand chose à voir avec la Bretagne.
3. (d3) le nouveau président de la région Bretagne a prononcé son discours d'investiture.
4. (d4) La Corse et la Normandie montrent la progression du parti des chaussettes vertes : analyse détaillée pour la Normandie.

On veut indexer les nouvelles reçues de manière à pouvoir les rechercher en fonction d'une région. Le vocabulaire auquel on se restreint est donc celui des noms de pays (Alsace, Corse, Bretagne, Normandie).

1. Donnez une matrice d'incidence contenant les tf pour les quatre régions, et un tableau donnant les idf (sans appliquer le log). Mettez les noms de région en ligne, et les documents en colonne.
2. Donner les résultats classés par similarité cosinus basée sur les tf (on ignore l'idf) pour les requêtes suivantes. Expliquez brièvement le classement.
 - Normandie ;
 - Corse et Bretagne.
3. Reprenons la dernière requête, "Corse et Bretagne" et les documents d2 et d3. Qu'est-ce que la prise en compte de l'idf changerait au classement ?