

Sujet d'examen UE NFE204 - Session 1

Année universitaire 2022-2023

Examen session FOAD : 20 juin 2023

Consignes

Durée de l'examen : 3h00 ; Documents autorisés : 10 pages recto/verso de notes manuscrites ; Calculatrice autorisée

Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.

Ce sujet contient 4 pages.

Important : nous n'évaluons pas les réponses par la syntaxe. Ne vous inquiétez pas d'utiliser un point-virgule à la place d'un point d'exclamation ou autres détails mineurs

Première partie : modélisation NoSQL (7 pts)

Les articles de recherche universitaires sont maintenant gérés dans des dépôts d'archive, comme HAL en France. Posons-nous quelques questions sur le fonctionnement d'une telle archive. Un modèle très sommaire du dépôt est donné dans la figure 1. Les chercheurs publient des articles (qui peuvent avoir plusieurs co-auteurs) et sont *affiliés* à des organismes de recherche. Ces organismes sont hiérarchiquement structurés : un chercheur peut être attaché à une équipe (organisme de base), qui fait partie d'un laboratoire (organisme parent) qui lui-même fait partie d'un établissement (par exemple le Cnam), etc.




FIGURE 1 – Modèle (sommaire) du dépôt

Voici également un tout petit échantillon de la base relationnelle.

ref	titre	année
hal-875	Music modeling	2018
hal-293	Recommendations on Twitter	2019

La table *Article*

id	nom	affiliation	idAuteur	refArticle
nt	N. Travers	DVRC	hal-875	nt
pr	P. Rigaux	Vertigo	hal-293	nt
rfs	R. Fournier-S'niehotta	Vertigo	hal-875	pr
cdm	C. du Mouza	ISID	hal-875	rfs
			hal-293	cdm

La table *Chercheur*

La table des auteurs

1. Proposez un format de document JSON représentant toutes les informations relatives à l'article hal-875 présentes dans les trois tables ci-dessus (représentation A).
2. Proposez un document JSON représentant toutes les informations relatives à l'organisme Vertigo présentes dans 3 tables ci-dessus (représentation B).
3. Expliquez le calcul MapReduce permettant de produire les documents B à partir des documents A. **Important** : pour spécifier les calculs MapReduce, donner les fonctions de Map et de Reduce, en javascript, en pseudo-code, au pire en langage naturel en étant le plus précis possible.
4. Maintenant on prend en compte la table décrivant la hiérarchie des organismes, dont voici un échantillon.

id	intitulé	ville	idParent
Vertigo	Données et apprentissage	Paris	cedric
DVRC	Systèmes intelligents	Nanterre	De Vinci
ISID	Systèmes d'information	Paris	cedric
cedric	Centre informatique	Paris	Cnam

La table des organismes de recherche

Dessinez cette hiérarchie, et proposez une modélisation JSON pour ajouter l'information sur les organismes dans la représentation B. Illustrez cette modélisation sur le document "Vertigo" de la seconde question.

5. Les références bibliographiques sont gérées depuis des dizaines d'années dans un format texte dit Bibtex. Voici par exemple un document Bibtex représentant un article.

```
@article{frrt-02435620,
  TITLE = {{Modeling Music as Synchronized Time Series}},
  AUTHOR = {Fournier-S'niehotta, Raphael and Rigaux, Philippe and Travers, Nicolas},
  URL = {https://hal-cnam.archives-ouvertes.fr/hal-02435620},
  JOURNAL = {{Information Systems}},
  PUBLISHER = {{Elsevier}},
  VOLUME = {73},
  PAGES = {35-49},
  YEAR = {2018},
}
```

Comment qualifieriez-vous ce format par rapport à JSON ? Voyez-vous des inconvénients, des avantages, à cette représentation ?

Deuxième partie : recherche d'information (7 pts)

Les articles ont des résumés, et on va construire un index sur ces résumés à des fins de classification et d'analyse. Voici un extrait des résumés de 5 articles $A_1, \dots, A_5$.

- A_1 Cet article compare les stratégies d'optimisation des échanges réseaux entre processeurs
- A_2 Un orchestre moderne doit savoir maîtriser une harmonie atonale
- A_3 Comparaison entre les propriétés des réseaux filaires et des réseaux optiques
- A_4 Pourquoi un processeur quantique ne peut surmonter un processeur standard qu'en présence d'un réseau performant
- A_5 Mozart est-il mieux servi par un orchestre de chambre ou un orchestre philharmonique ?

On va se limiter au vocabulaire (harmonie, processeur, réseau, orchestre). (NB : on suppose une phase préalable de normalisation qui élimine les pluriels, majuscules, etc.)

1. Donnez une matrice d'incidence contenant les tf, et un tableau donnant les idf (sans le log), pour les termes précédents. Placez les termes en ligne, les résumés en colonne.

Solution :

	A1	A2	A3	A4	A5
harmonie 5/1	0	1	0	0	0
processeur 5/2	1	0	0	2	0
réseau 5/3	1	0	2	1	0
orchestre 5/2	0	1	0	0	2

2. Donnez les normes des vecteurs représentant ces résumés.

Solution : Les normes

$$\|A_1\| = \sqrt{2}; \|A_2\| = \sqrt{2}; \|A_3\| = \sqrt{2}; \|A_4\| = \sqrt{5}; \|A_5\| = \sqrt{4}$$

3. Dans un espace vectoriel à deux dimensions avec "processeur" en abscisse et "réseau" en ordonnée, placez les vecteurs représentant nos documents.
4. Donner les résultats classés par similarité cosinus basée sur les tf (on ignore l'idf) pour les requêtes suivantes. Détaillez les calculs.
 - processeur et réseau
 - harmonie et orchestre
5. Sans calcul, indiquez quel document est classé en tête pour la requête avec le seul mot "réseau", et expliquez pourquoi.

Troisième partie : systèmes distribués (5 pts)

Voici quelques aspects d'Elastic Search qui devraient vous être familiers, et d'autres qui n'ont pas été abordés en cours

La documentation nous dit : *When you index a document, it is stored on a single primary shard determined by a simple formula :*

$$shard = hash(id) \% number_of_primary_shards$$

Voici la configuration initiale de votre *cluster* ElasticSearch pour les questions qui suivent (rappel : réplica = n signifie $n + 1$ copies d'un document).

- Nombre de fragments (*shards*) : 3
- Nombre de réplicas : 2

Et je crée un index. Chacune des questions ci-dessous vaut 1 point. Une brève explication sera appréciée.

1. Est-ce que mon *cluster* peut être constitué d'un seul nœud (un seul serveur) ?

Solution : Oui, mais l'index sera en situation périlleuse puisqu'il manquera deux serveurs pour héberger les réplicas. Autre réponse : non car il faut stocker les réplicas sur des serveurs distincts.

2. Est-ce que je peux augmenter le nombre de *shards* sans recréer l'index ?

Solution : Non, c'est du hachage statique, toute affectation à un fragment est définitive, sauf à reconstituer l'index.

3. Est-ce que je peux augmenter le nombre de réplicas ?

Solution : Oui, aucun problème, à condition d'avoir assez de serveurs sinon ça n'a pas vraiment de sens.

4. Est-ce que je peux ajouter des nœuds à mon *cluster* ?

Solution : Oui, ça peut améliorer la distribution des fragments.

5. Si oui, à partir de quand est-ce que ça ne sert plus à rien d'ajouter des nœuds, en prenant en compte la configuration initiale ?

Solution : Quand on a un fragment par serveur, ça ne sert à rien d'en ajouter. Donc $3 * (2 + 1) = 9$ serveurs.

Un dernier point à gagner. Un de vos collègues vous affirme qu'il vaut mieux créer un index avec beaucoup de *shards*, pour anticiper la croissance future. Voici un argument contre ce choix, issu de la documentation. *Term statistics, used to calculate relevance, are per shard. Having a small amount of data in many shards leads to poor relevance.*

Quatrième partie : questions de cours (2 pts)

Nous avons vu que dans un système comme Cassandra, on pouvait régler des paramètres *W* (acquittements en écriture) et *R* (acquittements en lecture).

Ce réglage correspond à la recherche d'un compromis, mais entre quelles propriétés ? Reprenez le théorème CAP et donnez des réponses argumentées aux questions suivantes :

1. Si *W* est fixé à 1, quelle(s) propriété(s) est/sont sacrifiée(s) avec une faible valeur de *R* ? Et avec la valeur de *R* maximale ?

Solution : Si *R* est faible, on sacrifie la cohérence car on augmente la probabilité de lire une valeur obsolète. En augmentant *R* on améliore la cohérence, mais on diminue la disponibilité et la tolérance.

2. Si *W* est fixé à la valeur maximale, le choix de *R* influe-t-il sur les propriétés CAP ?

Solution : Non, si on a réussi à faire l'écriture avec tous les acquittements, toute lecture ramène une valeur cohérente, la disponibilité et la tolérance sont aussi maximales.