

# Sujet d'examen UE NFE204 - Session 2

Année universitaire 2022-2023

Examen rattrapage : 5 septembre 2023

## Consignes

Durée de l'examen : 3h00 ; Documents non autorisés ; Calculatrice autorisée

Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.

Ce sujet contient 3 pages.

*Important* : nous n'évaluons pas les réponses par la syntaxe. Ne vous inquiétez pas d'utiliser un point-virgule à la place d'un point d'exclamation ou autres détails mineurs

## Première partie : documents structurés et MapReduce (7 pts)

Nous gérons un site de commerce électronique qui recense des restaurants et permet à des internautes de les noter. Pour l'instant nous utilisons un système relationnel, dont voici le schéma (très simplifié).

- Restaurant (**id**, nom)
- Internaute (**id**, nom)
- Notation (**idRestau**, **idInternaute**, note, commentaire)

Voici également un tout petit échantillon de la base.

| <b>id</b> | nom         | <b>id</b> | nom    | <b>idRestau</b> | <b>idInternaute</b> | note | commentaire |
|-----------|-------------|-----------|--------|-----------------|---------------------|------|-------------|
| 20        | Aux délices | 100       | Marie  | 20              | 100                 | 1    | Nul         |
| 21        | Le régal    | 101       | Adrien | 20              | 101                 | 5    | Parfait     |
|           |             |           |        | 21              | 101                 | 3    | Moyen       |

La table *Restaurant*      La table *Internaute*      La table *Notation*

On veut implanter un algorithme de filtrage collaboratif. Un des calculs consiste notamment à déterminer la note moyenne donnée par chaque internaute. Quelqu'un décide alors de remplacer la base relationnelle par une base NoSQL, et SQL par MapReduce. Voyons s'il a raison.

1. Donnez une représentation de l'échantillon ci-dessus sous la forme d'une collection de documents JSON, centrée sur les entités "Restaurant". Nous l'appellerons représentation A.
2. Proposez une autre représentation, centrée sur les entités "Internaute". Nous l'appellerons représentation B.
3. Donnez la requête SQL qui calcule la note moyenne donnée par chaque internaute.
4. Expliquez le calcul MapReduce donnant cette moyenne, pour la représentation A.
5. Même chose pour la représentation B.
6. La phase de Reduce peut-elle être évitée pour l'un des calculs MapReduce ? Si oui expliquez pourquoi, et l'impact sur la performance du calcul.

**Important** : pour spécifier les calculs MapReduce, donner les fonctions de Map et de Reduce, en javascript, en pseudo-code, au pire en langage naturel en étant le plus précis possible.

## Deuxième partie : recherche d'information (8 pts)

On ajoute dans les documents des commentaires sur les restaurants, désignés par  $c_1, \dots, c_5$ . On veut maintenant créer un index plein texte pour rechercher des commentaires. On va travailler sur l'échantillon suivant.

- $c_1$  Plats médiocres, bonne carte des vins, accueil cordial.
- $c_2$  Le vin est moyen, les desserts sont mauvais, mais le décor est agréable.
- $c_3$  En général, le vin est trop cher au restaurant, mais ici la carte des vins est complète et de qualité.
- $c_4$  Passons sur le décor d'un goût douteux. Les plats et desserts sont délicieux, c'est tout ce qui compte après tout.
- $c_5$  Plat, dessert et un verre de vin pour un prix correct. Le plat du jour est toujours intéressant.

On va se limiter au vocabulaire (vin, plat, décor, dessert). (NB : on suppose une phase préalable de normalisation qui élimine les pluriels, majuscules, etc.)

1. Donnez une matrice d'incidence contenant les tf, et un tableau donnant les idf (sans le log), pour les termes précédents. Placez les termes en ligne, les commentaires en colonne.
2. Donnez les normes des vecteurs représentant ces commentaires.
3. Donner les résultats classés par similarité cosinus basée sur les tf (on ignore l'idf) pour les requêtes suivantes.
  - plat;
  - décor et dessert;
  - vin et plat.

Expliquez brièvement la raison du classement pour le premier document.

4. Pour la requête "décor et dessert", et les documents  $c_2$  et  $c_4$ , qu'est-ce qui change si on ne met pas de restriction sur le vocabulaire (tous les mots sont indexés) ?
5. On voudrait pouvoir mesurer les co-occurrences de termes, autrement dit produire un indicateur représentant la probabilité que deux termes apparaissent ensembles dans un même commentaire. Proposez une formule estimant cette probabilité et s'appuyant sur les informations présentes dans la matrice d'incidence.

## Troisième partie : flux (2 pts)

Nous recevons un flux de notes données à des restaurants nommé `restaus`. Chaque élément contient le nom du restaurant, l'identifiant de l'utilisateur, la note et le commentaire. Voici un échantillon.

```
1,Le bougnat,100,4,"Plats médiocres ..."  
2,Délices de Saïgon,100,2,"Desserts nuls..."  
3,Le régat,101,4,"venez pour le décor"  
..
```

On met en place une chaîne de traitement pour ce flux. Voici cette chaîne exprimée avec les opérateurs de Pig

```
coll1 = filter restaus by contains(commentaire, "dessert")  
coll2 = group coll1 by nomRestaurant;  
coll3 = foreach coll2 generate group, AVG(coll1.note);
```

1. Que produit cette chaîne ?
2. Quel est le degré maximal de parallélisation ?

### Quatrième partie : questions de cours (3 pts)

1. Je soumetts une requête  $t_1, t_2, \dots, t_n$ . Quel est le poids de chaque terme dans le vecteur représentant cette requête ? La normalisation de ce vecteur est elle importante pour le classement (justifier) ?
2. Dans un traitement MapReduce, à quoi correspond l'opération dite de *shuffle* ?
3. Dans un système distribué avec partitionnement, je décide de partitionner ma collection de films sur le genre. Discuter des avantages et inconvénients de ce choix.