

Examen NFE204 - Session 1

04 février 2014

Consignes

Durée de l'examen : 2h00

Documents non autorisés ; Calculatrice autorisée

Les exercices sont indépendants les uns des autres. Merci de soigner votre écriture.

Ce sujet contient 4 pages.

Important : nous n'évaluons pas les réponses par la syntaxe. ne vous inquiétez pas d'utiliser un point-virgule à la place d'un point d'exclamation ou autres détails mineurs

Première partie : XML (7 pts)

On va s'intéresser aux recettes de cuisine et à leur représentation documentaire. Voici tout d'abord un exemple de recette représenté en XML.

```
<?xml version="1.0" encoding="UTF-8"?>
<recipe measures="FR">
  <title>Crêpes</title>
  <catalogued_in>
    <catalog name="plat">autre</catalog>
    <catalog name="difficulté">moyenne</catalog>
    <catalog name="toques">2</catalog>
  </catalogued_in>
  <ingredient_lines>
    <yield piece="pers.">6</yield>
    <ingredient_line>
      <quantity unit="g">150</quantity>
      <ingredient>sucré</ingredient>
    </ingredient_line>
    <ingredient_line>
      <quantity unit="g">750</quantity>
      <ingredient>farine</ingredient>
    </ingredient_line>
    <ingredient_line>
      <quantity piece=" " >8</quantity>
      <ingredient>oeuf</ingredient>
    </ingredient_line>
    <ingredient_line>
      <quantity piece="c. à soupe">4</quantity>
      <ingredient>huile</ingredient>
    </ingredient_line>
    <ingredient_line>
      <quantity unit="l">2</quantity>
      <ingredient>lait</ingredient>
    </ingredient_line>
    <ingredient_line>
      <quantity piece="c. à soupe">1</quantity>
      <ingredient>gros sel</ingredient>
    </ingredient_line>
  </ingredient_lines>
</recipe>
```

```
</ingredient_lines>
<instructions>Mélanger oeufs battus en omelette et sucre. Ajoutez farine, blé noir, huile et lait.
</instructions>
</recipe>
```

Listing 1 – Fichier crepes.xml

XPath : compréhension

Donnez le résultat des expressions XPath suivantes, appliqué au document `crepes.xml`.

1. `/recipe/ingredient_lines/ingredient_line/ingredient`
2. `/recipe/ingredient_lines/ingredient_line/quantity/@unit`
3. `/recipe/catalogued_in/catalog[@name="difficulté"]/text()`

Solution :

1. La liste des nœuds `ingredient`, avec leur nœud-texte fils.
2. Les attributs `unit`.
3. Le texte indiquant la difficulté de la recette : ici, "moyenne".

XPath : expression

On suppose que la base documentaire "Recettes" se représente sous la forme d'un très grand document XML avec un élément-racine `recipes`, contenant des sous-éléments `recipe` comme dans l'exemple précédent.

```
<?xml version="1.0" encoding="UTF-8"?>
<recipes>
  <recipe measures="FR">
    (... une recette...)
  </recipe>
  <recipe measures="US">
    (... une autre ...)
  </recipe>
</recipes>
```

Donnez en XPath les expressions permettant de récupérer les informations suivantes :

1. Titre des recettes contenant du chocolat.
2. Quantité de farine dans la recette des gougères.
3. Combien d'ingrédients dans la recette des profiteroles ?
4. Titre des recettes pour lesquelles on n'a pas d'instructions.

Solution :

1. `//recipe[ingredient_lines/ingredient_line/ingredient="chocolat"]/title`
2. `//recipe[title="gougères"]/ingredient_lines/ingredient_line[ingredient/text()="farine"]/quantity`
3. `count(//recipe[title="profiteroles"]/ingredient_lines/ingredient_line)`
4. `//recipe[not(instructions)]/title`

Seconde partie : indexation (5 pts)

Nous souhaitons indexer les recettes. On va s'intéresser en particulier au champ instructions. Voici quelques exemples :

La *panna cotta* (identifiant 'pc') :

Mettre la crème, le sucre et la vanille dans une casserole et faire frémir. Ajouter les 3 feuilles de gélatine préalablement trempées dans l'eau froide. Bien remuer et verser la crème dans des coupelles. Laisser refroidir quelques heures.

la *crème brûlée* (identifiant 'cb')

Faire bouillir le lait, ajouter la crème et le sucre hors du feu. Ajouter les jaunes d'oeufs, mettre au four au bain marie et laisser cuire doucement à 180°C environ 10 minutes. Laisser refroidir puis mettre dessus du sucre roux et le brûler avec un petit chalumeau.

et la *mousse au chocolat* (identifiant 'mc').

Faire ramollir le chocolat dans une terrine. Incorporer les jaunes et le sucre. Puis, battre les blancs en neige ferme et les ajouter délicatement au mélange à l'aide d'une spatule. Mettre au frais 1 heure ou 2 minimum.

1. Créer les listes inverses pour les mots suivants : "crème, sucre, oeuf, gélatine".

Vous indiquerez quel traitement préalable vous effectuez sur le texte, le nombre de termes que vous prenez en compte dans chaque document, l'idf des termes, et le tf dans chaque liste.

Solution : IDF :

- *crème* apparaît dans 2 documents sur 3, $\text{idf}=3/2$;
- *sucre* dans 3 sur 3 ($\text{idf}=1$),
- *oeuf* dans 1 sur 3 ($\text{idf}=3$) comme *gélatine*.

Traitement du texte : on retire les articles, prépositions (stop words), les pluriels des noms. Le document pc contient 24 termes ; le document cb contient 29 termes ; le document mc 20 termes.

- *crème* : pc (2/24), cb (1/29)
- *sucre* : cb (2/29), mc (1/20), pc (1/24)
- *oeuf* : cb (1/29)
- *gélatine* : pc (1/24)

2. Donner les résultats classés par combinaison $\text{tf} \cdot \text{idf}$ pour les requêtes suivantes (pas la peine d'appliquer le logarithme).

- *crème* et *sucre*
- *crème* et *oeuf*
- *oeuf* et *gélatine*

Solution :

- *crème* et *sucre* : cb ($3/2 * 1/29 + 1 * 2/29$), pc ($3/2 * 2/24 + 1 * 1/24$), mc (1/20)
- *crème* et *oeuf* : cb ($3/2 * 1/29 + 3 * 1/29$), pc ($3/2 * 2/24$)
- *oeuf* et *gélatine* : pc ($3 * 1/24$), cb ($3 * 1/29$)

3. Commentez le résultat de la dernière requête. Est-il correct intuitivement ? Que penser de l'indexation du terme 'oeuf', est-elle représentative du contenu des recettes ?

Solution : Clairement, il faut des oeufs dans la crème au chocolat, mais le mot lui-même n'apparaît pas, ce qui fausse les résultats. The tf est à 0 pour le document mc, et l'idf de 'oeuf' est surévalué (parce que le nombre de documents lui-même est ridiculement petit).

Troisième partie : systèmes NoSQL (8 pts)

1. **Réplication** : rappeler la définition des répliques synchrones et asynchrones, et indiquez brièvement les avantages/inconvénients de chacune.

2. **Architecture.** Dans quelle architecture peut-on aboutir à des écritures conflictuelles ? Donnez un exemple.
3. **Gestion des pannes.** Rappeler la règle du quorum (majorité des votants) en cas de partitionnement de réseau, et justifiez-là.
4. **MapReduce.** Dans une exécution MapReduce, le *reducer* peut-il commencer à s'exécuter avant la fin de la phase de *map* ? Expliquer pourquoi (vous pouvez donner un exemple).