

Sujet d'examen UE NFE204 - Session 2

Année universitaire 2024-2025

Examen session hybride : 15 avril 2025

Consignes

Durée de l'examen : 3h00 ; Calculatrice autorisée ; Documents autorisés : 5 pages recto-verso de note personnelles. Ce sujet contient 2 pages.

Première partie : modélisation semi-structurée (8 pts)

Un grand magasin enregistre tous les tickets de caisse des transactions effectuées par ses clients. Un ticket de caisse comprend la date et l'heure de chaque transaction, le numéro de la caisse, le prix total, et la liste des articles achetés avec, pour chacun, la quantité et le prix unitaire. Le ticket de caisse comprend également l'identifiant du client si ce dernier a utilisé sa carte de fidélité. Sinon cet identifiant est à null.

1. Dans une base relationnelle, combien de tables faudrait-il pour représenter les informations d'un ticket de caisse (expliquer et donner le schéma de ces tables) ; combien d'insertions de ligne faut-il faire pour chaque ticket ?
2. Si on choisit une base NoSQL, comment représenter un ticket de caisse en JSON. Donnez un exemple simple. Combien d'insertions faut-il faire ?
3. Je veux compter le nombre de transactions par caisse et par jour. Quelle est la requête SQL si les données sont dans une base relationnelle ?
4. Même question si la base est NoSQL : comment calculer le nombre de transactions par caisse et par jour
5. Proposez un format de document semi-structuré (en JSON par exemple) pour une base des articles, la description de chaque article incluant la liste des ventes (une vente = date, quantité, client)

Deuxième partie : MapReduce (7 pts)

Je veux calculer le montant moyen des tickets par client, pour les clients dont je connais l'identifiant.

1. Décrivez la modélisation MapReduce de ce calcul. Donnez le pseudo-code de chaque fonction, ou indiquez par un texte clair son déroulement.
2. Donnez la forme de la chaîne de traitement (*workflow*), avec des opérateurs Pig ou Spark, qui implante ce calcul.
3. Indiquez comment on produit un document 'Article' avec la liste des ventes à partir de la collection des tickets de caisse.

Troisième partie : systèmes distribués (3 pts)

On vous demande d'expliquer quelques-uns des principes du *consistent hashing*.

1. Expliquez comment on choisit le serveur sur lequel on place un document.
2. Pourquoi la structure est-elle basée sur un anneau ? Pourquoi pas un segment de droite par exemple ?
3. Pourquoi y a-t-il autant de valeurs sur l'anneau (2 puissance 64 typiquement) ? Pourquoi ne pas commencer avec 8 ou 16 valeurs, et augmenter ensuite ?
4. Quelle est l'utilité de la notion de nœud virtuel ?

Quatrième partie : questions de cours (2 pts)

Pourquoi faut-il stocker les paires intermédiaires sur disque dans un processus MapReduce ? Pourquoi ne peut-on directement les transmettre aux machines qui effectuent la phase de Reduce ?