

# PROJET Certificat de spécialisation Analyste de données massives.

## Groupe

Aurélie LE CAIN

## INTRODUCTION

### Contexte

Essilor International est une société française qui conçoit, fabrique et commercialise des verres correcteurs et des équipements d'optique ophtalmique. La société est le numéro un mondial des verres correcteurs.

Le groupe tire sa réussite d'une stratégie d'innovation en consacrant plus de 150 millions d'euros par an à la recherche et à l'innovation pour proposer des produits toujours plus performants.

Les informations relatives au fonctionnement de chaque programme de recherche sont stockées dans une base de données relationnelle ERA tenue à jour depuis une quinzaine d'années. Au cours de la vie d'un programme les informations trackées sont donc disponibles.

Des outils de gestion des ressources par programme vont être mis à disposition des managers de programme. Ces outils permettront de mieux piloter les ressources en prenant en compte les retards et la situation du programme au cours du temps. Les outils de PPM sont des supports au projet pendant sa durée de vie. Mais ces outils nécessitent en entrée des abaques de typologie de programme. Il m'a donc été demandé dans un premier temps de fournir des Baselines le plus fiable possible connaissant les expériences réelles du passé.

D'autre part, on se pose également la question de l'innovation d'un programme (mesurée par le nombre de brevets déposés pendant ce programme) en fonction des ressources qui lui sont attribuées. On souhaite ici mesurer l'activité web d'un sujet technique et corréler cette information aux ressources attribuées sur le programme et le nombre de brevets. Cela afin de prédire quel nombre de brevets on peut espérer obtenir pour un futur programme en fonction des ressources qui lui sont allouées et l'activité web d'un sujet.

### Objectif

Dans un premier temps on va analyser les données d'ERA afin de voir s'il existe une classification/classement des programmes R&D sur les données sauvegardées depuis 2009.

Puis on cherchera à coupler les informations des programmes aux nombres de brevets et à l'activité Web du sujet traité dans le programme.

### Sources de données

La base sera donc constituée des données issues de la base de données de l'entreprise ERA qui comporte les informations suivantes :

- Les durées des phases d'étude de conception, de capitalisation, ...
- Le type de projet exploratoire ou applicatif,
- Les coordinateurs et participants
- Les ressources humaines

- Les niveaux de stratégie
- le département, le groupe, la division, la localisation
- le type : 1<sup>er</sup> niveau de segmentation
- le status : Court/moyen/long terme
- la coordination : 2<sup>ème</sup> niveau de segmentation
- nom de l'activité : 3<sup>ème</sup> niveau de segmentation
- le mois
- track/forecast, nombre de jours trackés, nombre de h/m

Et des informations Brevets :

- Nombre de brevets par programme

Et couplées à des données extraites du web comme :

- le nombre de documents qui traitent du sujet
- identifier les concurrents
- mesurer l'activité des concurrents
- mesurer l'activité globale au cours du temps et nous positionner sur l'axe temps

Cette deuxième source de donnée (le web) sera de type documentaire et obtenue à partir d'une API de Google Scholar (scholar.py). Cette API est téléchargeable sur internet gratuitement et nécessite un compilateur python et l'installation de BeautifulSoup. Les résultats des requêtes d'articles ou brevets sur Google seront extraites sous format csv grâce à cette API.

## PLAN


|       |                                             |    |
|-------|---------------------------------------------|----|
| I.    | Analyse de données des programmes.....      | 3  |
| I.1.  | Données Programmes.....                     | 3  |
| I.2.  | Données Brevet & Données Web.....           | 5  |
| II.   | RIAK et son mode de réplication.....        | 10 |
| II.1. | Histoire de RIAK .....                      | 10 |
| II.2. | Riak : une base de données clé-valeur ..... | 10 |
| II.3. | Architecture Multi-Noeud .....              | 11 |
| II.4. | Réplication .....                           | 12 |

# I. Analyse de données des programmes

## I.1. Données Programmes

L'outil de PPM comme énoncée dans l'introduction, permet de gérer les ressources à partir d'une Baseline donnée. On souhaite fournir en fonction des livrables cette Baseline sorte de une trajectoire d'un programme.

Voici un exemple de Baseline en termes de coûts cumulés que l'on a :



Cette Baseline est la mesure des efforts humains au cours du temps qui traduit la gestion des ressources sur le programme.

Nous disposons de fichiers n'ayant pas le même type d'informations et il faut extraire les informations de l'ensemble de ces fichiers. Pour cela, j'ai écrit un script LUA disponible en **ANNEXE 1** afin de réunir des informations :

-du fichier programme qui possède des informations sur tous les programmes et leurs 4 phases (préparation, conception, faisabilité, capitalisation) 2359 lignes et 50 colonnes

-des fichiers ressources par année 40 000 lignes et 46 colonnes par fichier

Il a fallu relier les informations concernant les ressources aux informations relatives aux phases. En effet, dans le premier fichier je disposais des dates de début et de fin des phases dans l'autre je disposais des dates de tracking et du nombre de jours tracké par mois et par personne pour ce même programme.

Sur les 2359 entités, après extraction seule une centaine sont exploitables car il s'agit de programme R&D terminés qui possèdent des informations sur les 4 phases énoncées plus haut. Voici le type de fichier que je crée par la suite à l'aide du script LUA :

|            | Program Preparation Phase |            |          |         | Program Concept Phase |            |          |         | Program Feasibility Phase |            |          |          | Program Capitalization Phase |            |          |       |
|------------|---------------------------|------------|----------|---------|-----------------------|------------|----------|---------|---------------------------|------------|----------|----------|------------------------------|------------|----------|-------|
|            | Début                     | Fin        | Durée    | TRACK   | Début                 | Fin        | Durée    | TRACK   | Début                     | Fin        | Durée    | TRACK    | Début                        | Fin        | Durée    | TRACK |
| PGACT11210 | 1320145200                | 1328871600 | 8726400  | 26.5    | 1328958000            | 1333188000 | 4230000  | 1195.1  | 1333274400                | 1383217200 | 49942800 | 1162.475 | 1383303600                   | 1391166000 | 7862400  |       |
| PGACT12153 | 1338544800                | 1354878000 | 16333200 | 531.625 | 1354964400            | 1372586400 | 17622000 | 2350.25 | 1372672800                | 1404122400 | 31449600 | 2159.5   | 1404208800                   | 1414753200 | 10544400 |       |

### **Concernant l'analyse statistique que j'envisage à partir de ce fichier de résultat :**

D'une part, j'envisage d'étendre le nombre de programmes à ceux pour lesquels au moins 3 phases sont renseignées dans le fichier concernant le programme (au lieu de 4) afin d'augmenter le nombre de programmes concernés par la réalisation de ces Baselines. Je vais m'orienter vers des classifications pour cette partie afin de dégager des groupes de programme. Il faudra sûrement intégrer d'autres informations sur la technicité des programmes afin de pouvoir augmenter le nombre de variables qui vont me permettre de travailler sur une typologie de programmes. J'extraie environ 35 variables pour définir ces programmes.

La première étape de sélection des programmes concernés par l'étude est donc réalisée, je vais donc travailler désormais sur l'aspect exploitation de ces données à partir de méthode de datamining.

## I.2. Données Brevet & Données Web

On dispose d'un fichier indiquant le nom et le code du programme, un résumé du programme sa date de clôture et son titre ainsi que le nombre de brevets déposés dans le cadre de ce programme. Voici les premières lignes de ce fichier structuré :

| Code       | Nbre Brevets | Nom          | Fin      | Résumé              |
|------------|--------------|--------------|----------|---------------------|
| PGRXT12059 | 10           | Additive Ma  | nov-13   | « Additive manufa   |
| PGDSG1012  | 6            | Varilux GX   | Dec 2013 | This applicative p  |
| PGDSG7045  | 6            | PAL binocul  | Dec2010  | To improve PAL v    |
| PGTNC11085 | 6            | Dual side Di | oct-14   | Obiective of the pi |

On a d'abord identifié 15 grands thèmes de recherche en lisant les différents résumés des programmes. Puis on a associé à ces 15 thèmes de recherche :

- des mots-clés
- le nombre de brevets déposés.

On souhaite identifier l'activité web de ces grands thèmes à l'aide des mots-clés et la corréler au nombre de brevets déposés.

| Code       | Nbre Brevets | Date     | Thème                     |
|------------|--------------|----------|---------------------------|
| PGRXT12059 | 10           | nov-13   | Additive manufacturing 3D |
| RDHMC7287  | 4            | juil-09  | Anti Fog                  |
| PGHMC13001 | 3            | mars-15  | Anti Fog                  |
| PGHMC10218 | 2            | juin-12  | Anti Fog                  |
| M2HC5060   | 1            | May2008  | Anti Fog                  |
| PGHMC11078 | 1            | janv-13  | Anti Fog                  |
| RDHMC7108  | 1            | juin-13  | Anti Fog                  |
| PGDSG7045  | 6            | Dec2010  | Bino                      |
| PGDSG9164  | 1            | Dec 2012 | blur disto                |
| PGDSG10127 | 6            | Dec 2013 | DualSide                  |
| PGDSG7316  | 1            | Dec 2008 | DualSide                  |
| TNC11085   | 1            | oct-14   | DualSide                  |
| PGTNC9135  | 4            | Dec2010  | Fresnel                   |
| PGTPL7087  | 3            | juil-09  | Fresnel                   |
| PGNCP7116  | 2            | dec2010  | Fresnel                   |
| PGTNC11004 | 1            | Dec2013  | Fresnel                   |
| PGTNC13126 | 1            | may2015  | Fresnel                   |
| PGRXT12002 | 2            | fev 2013 | Lamination                |
| PGRXT8006  | 2            | Apr 2010 | Lamination                |
| PGRXT9137  | 2            | sept-11  | Lamination                |
| PGTNC11050 | 1            | mars-13  | Lens mapper fronto mapper |
| PGHMC8302  | 3            | Dec2009  | Mesoporeux                |
| PGDSG7042  | 1            | sept-10  | Myopie Enfants Chinois    |
| PGDSG13009 | 5            | oct-14   | Personnalisation          |
| PGDSG7074  | 4            | juil-09  | Personnalisation          |
| PGDSG9236  | 2            | janv-13  | Personnalisation          |

|            |   |          |                  |
|------------|---|----------|------------------|
| PGDSG11047 | 3 | Fev2015  | Retinal Diseases |
| PGSTT12051 | 1 | sept-13  | UV cut           |
| PGSTT12052 | 1 | May 2013 | UV cut           |
| PGTNC11008 | 1 | oct-12   | UV cut           |
| PGACT11210 | 1 | janv-14  | Verres Actifs    |
| PGDSG9158  | 1 | Dec 2012 | VisionPosture    |

| Thème                        | Mots-Clés                                                                                    |
|------------------------------|----------------------------------------------------------------------------------------------|
| Bino                         | ophthalmic lens binocular performance                                                        |
| AntiFog                      | Anti fog lens ophthalmic                                                                     |
| disto                        | ophthalmic lens swimming effect space deformation                                            |
| DualSide                     | ophthalmic lens aspheric double-sided                                                        |
| Lamination                   | ophthalmic lens lamination film ophthalmic lens lamination process                           |
| Lens mapper fronto<br>mapper | ophthalmic lens mapper<br>ophthalmic lens mesoporous" "ophthalmic<br>lens mesoporous coating |
| Mesoporeux                   |                                                                                              |
| Myopie Enfants               | ophthalmic lens myopia control prevention                                                    |
| Chinois                      | ophthalmic fresnel power lens                                                                |
| Fresnel                      | ophthalmic progressive lens [wearer] ethnic/ethnicity                                        |
| Ethno                        | ophthalmic lens customization / personalization / individualization                          |
| Personnalisation             | ophthalmic lens retinal diseases prevention                                                  |
| Retinal Diseases             | ophthalmic active/adjustable lens [correction]                                               |
| Verres Actifs                | ophthalmic progressive lens wearers posture/behavior                                         |
| VisionPosture                |                                                                                              |

On a d'abord installé python puis BeautifulSoup (bibliothèque de parsing HTML) sur Windows on utilise l'API scholar.py

```
C:\Python34\python.exe "setup.py" install
```

On va extraire des informations web (Google patent et Google Scholar) que l'on va stocker dans un fichier csv. Par exemple, j'ai pu identifier le thème « anti fog » ainsi on va rechercher les informations web à partir de cette requête :

```
C:\Python34\python.exe scholar.py -c 1000 -csv-header --phrases « anti fog ophthalmic lens » >> res.csv
```

Au préalable, j'ai modifié le fichier scholar.py qui ne me permettait pas d'afficher plus de résultats que ceux obtenus sur une page (donc 10 ou 20 selon la configuration de Google Scholar sur mon poste). Pour cela j'ai dû comprendre la structure du fichier scholar.py. Les requêtes sont transformées en réponse http avant d'être interprétées par BeautifulSoup. Le seul moyen pour passer à la page suivante est de modifier le numéro qui suit « start » dans les requêtes Google. Or les requêtes telles qu'elles étaient créées par scholar.py ne me permettaient pas de passer à la page suivante :

```
http://scholar.google.com/scholar?as_q=&as_epq=&as_oq=&as_eq=&as_occt=any&as_sau  
thors=einstein&as_publication=&as_ylo=&as_yhi=&as_sdt=0%2C5&as_vis=0&btnG=&hl=en
```

Voici donc comment j'ai modifié le code :

Avant :

```
querier.send_query(query)

if options.csv:
    csv(querier)
elif options.csv_header:
    csv(querier, header=True)
elif options.citation is not None:
    citation_export(querier)
else:
    txt(querier, with_globals=options.txt_globals)

if options.cookie_file:
    querier.save_cookies()

return 0
```

Après :

```
numbrl=0
starturl ="https://scholar.google.com/scholar?start="
endurl = "&q=anti+fog+ophthalmic+lens&hl=en&num=20&as_sdt=0,5"

while(numbrl<=1000):
    url = starturl+ str(numbrl) +endurl
    numbrl += 20
    #querier.send_query(query)
    #print(query.get_url())
    html = querier._get_http_response(url)
    querier.parse(html)
    if options.csv:
        csv(querier)
    elif options.csv_header:
```

```

        csv(querier, header=True)
    elif options.citation is not None:
        citation_export(querier)
    else:
        txt(querier, with_globals=options.txt_globals)

    if options.cookie_file:
        querier.save_cookies()
    querier = None
    querier = ScholarQuerier()
    querier.apply_settings(settings)
    time.sleep(5)
return 0

```

J'ai également modifié dans ce fichier :

`print(encode(result))` en `print(result.encode('utf8'))` suite à des erreurs générées lors des extractions.

Par contre, l'utilisation de `scholar.py` semble contrôlée et pour une même requête on peut parfois avoir un résultat et puis Google finit par me repérer. Le programme est bloqué et n'extrait plus rien. Lorsque je rouvre Google Scholar par des voies traditionnelles, je dois même parfois rentrer un captcha. Je dois faire l'extraction depuis une connexion avec une adresse IP flottante.

SeoQuake a été installé et testé sur Firefox, il permet de fournir des résultats type Page Rank et les mots qui ressortent le plus fréquemment avec la requête et bien d'autres informations. Mais les sorties que l'on peut exploiter dans le fichier csv ne contiennent malheureusement pas le résumé du résultat de la requête à partir duquel j'aurais pu effectuer mon analyse. Toutefois cet outil est très intéressant.

On a ainsi construit 15 fichiers issus de la recherche des mots clés pour ces 15 familles identifiées.

### Voici le détail de ma démarche :

Après avoir installé MongoDB sous Windows et Robomongo avec les commandes suivantes :

```

> netsh advfirewall firewall add rule name="Open mongod port 27017" dir=in action=allow
protocol=TCP localport=27017

> netsh advfirewall firewall add rule name="Allowing mongod" dir=in action=allow
program=" C:\Program Files\MongoDB 2.6 Standard\bin\mongod.exe"

> netsh advfirewall firewall add rule name="Allowing mongos" dir=in action=allow
program=" C:\Program Files\MongoDB 2.6 Standard\bin\mongos.exe"

> cd C:\Program Files\MongoDB 2.6 Standard\bin

> mongod.exe --install --logpath c:\mongo\logs --logappend --bind_ip 127.0.0.1 --dbpath
C:\mongo\data\db --directoryperdb

C > :\Program Files\MongoDB 2.6 Standard\bin\mongod.exe --install --logpath C:\mongo\logs -
logappend --bind_ip 127.0.0.1 --dbpath C:\mongo\data\db --directoryperdb

> net start MongoDB

> mongo.exe

```

Importation de données dans une base avec un fichier "csv" :



```
Mongoimport -d Google -c Antifog --type csv --file C:\mongo\scholar.py-master\res.csv --headerline
```

-d : définit le nom de la base où l'on souhaite importer les données  
-c : définit le nom de la collection que l'on souhaite remplir  
--type : définit le type de fichier importé  
--file : définit le chemin où se situe le fichier de données  
--headerline : pour utiliser la première ligne comme un nom de champs et non comme un document distinct (concerne les fichiers de type "csv" et "tsv")

Le données dans le fichier CSV doivent être séparées par des virgules et non de point-virgule. J'ai également modifié scholar.py pour obtenir le bon format de sortie.

def as\_csv(self, header=False, sep=','): au lieu de def as\_csv(self, header=False, sep='|'):

def csv(querier, header=False, sep=','): def csv(querier, header=False, sep='|'):

J'ai ensuite écrit un script dans Robomongo pour exploiter les données extraites du web. Ce script est écrit en partie en JavaScript (premier langage de script pour le web mis au point en 1995 par Netscape) présent en **ANNEXE 2**.

A l'aide de ce script, on peut ainsi obtenir :

- l'année min et max de parution des articles ou brevets extraits du web,
- le nombre d'articles totaux présent dans la base par année,
- le nombre de brevet par année,
- le nombre de brevet Essilor par année.

### **Concernant l'analyse statistique que j'envisage à partir de ce fichier de résultat :**

J'envisage une analyse type ACP et régression PLS pour analyser ces informations et essayer de trouver une corrélation possible entre l'activité des sujets sur le web et le nombre de brevets déposés.

## II. RIAK et son mode de réplication

### II.1. Histoire de RIAK

Riak est un système NoSQL inspiré de Dynamo (Amazon) dont la première version a été livrée en 2009. Riak a été développé par BashoTechnologies. Riak est sous licence Apache qui est une licence de logiciel libre et openSource.

La société Basho, en distribue deux versions commerciales :

- Riak Enterprise,
- et Riak Cloud Storage pour l'utilisation de Riak dans le cloud.

Riak est développé en Erlang, un langage développé initialement par la société Ericksson et qui est spécialement adapté au traitement parallèle et à l'informatique distribuée.


Le mode de réplication de Riak est le même que celui mis en place dans Dynamo et on en trouve une explication au lien suivant <http://docs.basho.com/riak/latest/theory/concepts/Clusters>.

### II.2. Riak : une base de données clé-valeur

Riak s'appuie sur un modèle de données (*clé, valeur*) extrêmement simplifié, et fournit des primitives d'accès  $put(k, v)$  (pour créer/mettre à jour) et  $v = get(k)$  pour rechercher. MongoDB et CouchDB se distinguent entre autres par un modèle de données plus riche (JSON).

Les bases de données clé-valeur sont très facilement scalables et permettent de gérer des milliards d'entrées en garantissant des temps de lecture et écriture très bas mais sont plus lentes pour traiter l'information. Les autres systèmes clé valeur sont :

Redis, Amazon DynamoDB, MemCached. On est dans la catégorie des systèmes temps réels.



Dans RIAK, les données sont organisées dans des **buckets (=fragments)**, que l'on peut voir comme des classes de documents. À l'intérieur d'un bucket, un document est référencé par une clé. On peut accéder à des documents de différentes façons (directement en donnant le bucket et la clé d'un document, map/reduce,..)

Exemple :


PUT /riak/{bucket}/{key} (Create, Update)

GET /riak/{bucket}/{key} (Read)  
DELETE GET /riak/{bucket}/{key} (Delete)

où {bucket} est la classe de documents et {key} la clé identifiant le document. Un avantage de ce type de bases de données est qu'il n'y a aucune restriction sur le type des fichiers que l'on traite.


### **Base de données documentaires :**

Pour des documents semi-structurés, il vaut mieux utiliser les bases de données documentaires (MongoDB, RethinkDB, CouchDB, Terrastore...). C'est le document qui est l'unité d'information à qui l'on attribue une clé.



### **Base de données orientée colonnes :**

Enfin pour des documents à stocker type SQL, les bases de données orientées colonnes sont le plus adaptées (Apache HBase, Apache Cassandra, Hypertable, Apache Accumulo...). Chaque colonne peut-être attribuée à une machine différente.




Tous ces systèmes peuvent être classés dans la catégorie appelés systèmes analytiques: ils stockent des données massives dans un environnement distribué, et permettent l'application de traitements distribués à l'ensemble de ces données.

## **II.3. Architecture Multi-Nœud**

A la manière de Dynamo d'Amazon, il n'y a pas de serveur maître et chaque nœud est indépendant. Les connexions utilisateurs peuvent s'effectuer sur n'importe quel nœud, qui se chargera de rediriger le client vers le nœud contenant les données souhaitées. On parle d'architecture multi-Nœuds.

Un nœud particulier, le *routeur*, maintient la structure de *routing*, reçoit les requêtes de l'application et les redirige vers les nœuds en charge du *stockage*. Ces derniers stockent les fragments. On pourrait imaginer une équivalence stricte (un nœud = un fragment) mais pour des raisons de souplesse du système, un même nœud est en général en charge de plusieurs fragments. Les fragments s'appellent des buckets. La méthode de partitionnement est par hachage.



Il s'agit d'un hachage cohérent où chaque nœud est responsable de  $1/(\text{Nombre total de nœud})$  du cercle. Ce cercle représente 160bit qui est divisé en 64 en partition égale comme on le voit sur la figure ci-dessus qui sont appelés des nœuds virtuels. Un nœud est responsable de plusieurs nœuds virtuels.

## II.4. Réplication


La réplication se fait de pair à pair, entre des nœuds jouant tous le même rôle. Il est ainsi très facile de rajouter ou supprimer n'importe quelle machine d'une instance de Riak.

Quand un objet est stocké dans le cluster, un nœud peut participer en tant que nœud de coordination pour la demande. Le nœud de coordination consulte l'état de l'anneau pour déterminer quel vnode possède la partition contenant la clé, puis envoie la demande d'écriture à ce vnode ainsi qu'aux vnodes responsables des  $N-1$  prochaines copies. La demande d'écriture peut également préciser qu'au moins  $W$  ( $= <N$ ) de ces vnodes répondent avec succès, et que  $DW$  ( $= <W$ ) répondent avec succès après avoir stocké durablement la valeur.

Une demande de lecture, ou un GET, fonctionne de la même manière :

L'envoi de la requête au vnode possédant la partition contenant la clé ainsi qu'aux  $N-1$  nœuds qui possèdent une copie. On peut préciser dans la requête qu'au moins  $R$  ( $= <N$ ) nœuds répondent avant d'envoyer la réponse.

Dans l'exemple ci-dessous on assigne la valeur REM pour la clé artiste, cette clé étant assignée à 3 partitions, les 3 partitions se verront alors attribuées la valeur REM. En cas de lecture, et si la valeur n'est pas trouvée immédiatement ou que les valeurs retournées ne sont pas les mêmes, le comportement de Riak est déterminé par un ensemble de paramètres de configurations que l'on liste dans le tableau suivant.



| Parameter    | Common name | Default value | Description                                                                                                                                                                                                                                                                                                                                                             |
|--------------|-------------|---------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| n_val        | N           | 3             | Replication factor, i.e. the number of nodes in the cluster on which an object is to be stored                                                                                                                                                                                                                                                                          |
| r            | R           | quorum        | The number of servers that must respond to a read request                                                                                                                                                                                                                                                                                                               |
| w            | W           | quorum        | Number of servers that must respond to a write request                                                                                                                                                                                                                                                                                                                  |
| pr           | PR          | 0             | The number of primary <a href="#">vnodes</a> that must respond to a read request                                                                                                                                                                                                                                                                                        |
| pw           | PW          | 0             | The number of primary <a href="#">vnodes</a> that must respond to a write request                                                                                                                                                                                                                                                                                       |
| dw           | DW          | quorum        | The number of servers that must report that a write has been successfully written to disk                                                                                                                                                                                                                                                                               |
| rw           | RW          | quorum        | If R and W are undefined, this parameter will substitute for both R and W during object deletes. It is extremely unlikely that you will need to adjust this parameter.                                                                                                                                                                                                  |
| notfound_ok  |             | true          | This parameter determines how Riak responds if a read fails on a node. Setting to true (the default) is the equivalent to setting R to 1: if the first node to respond doesn't have a copy of the object, Riak will immediately return a not found error. If set to false, Riak will continue to look for the object on the number of nodes specified by N (aka n_val). |
| basic_quorum |             | false         | If notfound_ok is set to false, Riak will be more thorough in looking for an object on multiple nodes. Setting basic_quorum to true in this case will instruct Riak to wait for only a quorum of responses to return a notfound error instead of N responses.                                                                                                           |

Voici la liste des scenarios possible lorsque la demande de lecture est envoyée aux 3 vnodes responsables des 3 copies :

| Scenario                                                                                                                                                                   | What happens in Riak                                                                                                                                                                          |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| All 3 vnodes agree on the value                                                                                                                                            | Once the first 2 vnodes return the value, that value is returned to the client                                                                                                                |
| 2 of 3 vnodes agree on the value, and those 2 are the first to reach the coordinating node                                                                                 | The value is returned to the client. Read repair will deal with the conflict per the later scenarios, which means that a future read may return a different value or <a href="#">siblings</a> |
| 2 conflicting values reach the coordinating node and <a href="#">vector clocks</a> allow for resolution                                                                    | The vector clocks are used to resolve the conflict and return a single value, which is propagated via read repair to the relevant vnodes                                                      |
| 2 conflicting values reach the coordinating node, vector clocks indicate a fork in the object history, and <code>allow_multis</code> set to <code>false</code>             | The object with the most recent timestamp is returned and propagated via read repair to the relevant vnodes                                                                                   |
| 2 siblings or conflicting values reach the coordinating node, vector clocks indicate a fork in the object history, and <code>allow_mult</code> is set to <code>true</code> | All keys are returned as siblings, optionally with associated values (depending on how the request is made)                                                                                   |

Voici la liste des scenarios en cas d'écriture :

| Scenario                                                                                                                                                               | What happens in Riak                                                                        |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------|
| A vector clock is included with the write request, and is newer than the vclock attached to the existing object                                                        | The new value is written and success is indicated as soon as 2 vnodes acknowledge the write |
| A vector clock is included with the write request but conflicts with the vclock attached to the existing object, with <code>allow_mult</code> set to <code>true</code> | The new value is created as a sibling for future reads                                      |

## Scenario

## What happens in Riak

A vector clock is included with the write request but conflicts with (or is older than) the vclock attached to the existing object, with `allow_mult` set to false

Riak will decide which object “wins” on the basis of timestamps; no sibling will be created

A vector clock is not included with the write request and an object already exists, with `allow_mult` set to true

The new value is created as a sibling for future reads

A vector clock is not included with the write request and an object already exists, with `allow_mult` set to false


The new value overwrites the existing value

La réplication (Multi-Data Center Replication) de Riak lorsqu’il y a plusieurs clusters ne fait pas partie de la version OpenSource. Les clusters indépendants sont connectés ensemble, chacun possédant sa propre structure de partitionnement en anneau. L’un des clusters agit comme un cluster principal et les autres comme secondaires. Si le cluster principal tombe en panne le cluster secondaire agit comme un cluster principal.


Un seul nœud (server) du cluster principal va être à l’écoute des répliquions sur une adresse IP externe. Un seul nœud (client) du cluster secondaire se connecte au nœud server et envoie les demandes de répliquion. Au démarrage un nœud server est jumelé à un nœud client. Les nœuds qui participeront à la répliquion seront élus par un protocole d’élection.

Il existe 2 modes de fonctionnement :

-fullsync : synchronisation complète du cluster principal et secondaire.



-et realtime : synchronisation incrémentale du cluster principal et secondaire : la répliquion est déclenchée par des mises à jour envoyé par le client au cluster principal.



La taille de l'anneau du hachage doit être la même pour le cluster principal et le cluster secondaire.



# ANNEXE 1 :

```
local rootFolder      = CO.FileSystem:ThisFileDirectory()
package.path           = package.path .. ";" .. rootFolder .. [{"?.lua"]}

local directory       = CO.FileSystem:ThisFileDirectory()

-- lecture des extractions par année qui contiennent les informations de tracking
40 000 lignes et 46 colonnes par fichier
local Folder          = [[C:\Users\lecaina\Documents\2015\1-DonneesERA\2-
DonneesERA\Ressources\]]
local A= CO.SeparatedFields:New()
A.Separator = ";"
A.HasHeader = true
local                 maillages_listes           = CO.FileSystem:Dir
(Folder, "*.csv", false, CO.FileSystem_File)

-- lecture du fichier qui contient les informations sur les programmes 2359 lignes
et 50 colonnes
local PhaseFile       = [[C:\Users\lecaina\Documents\2015\1-DonneesERA\2-
DonneesERA\Phase\program.csv]]
local Phase= CO.SeparatedFields:New()
Phase.Separator = ";"
Phase.HasHeader = true
Phase:ReadFile(PhaseFile)

--structure de stockage du résultat de l'extraction
local B = CO.SeparatedFields:New ()
B.HasHeader = true
B.Separator = ";"

print("Debut de l'extraction")

NbreProg=0

--Extraction du nom des programmes et de leur code
for i=0,#Phase-1 do

    if((Phase[i]["PROJECT TYPE"].Value == "R&D Program") and
(Phase[i]["STATUS"].Value == "Complete"))then

        Code = Phase[i]["PROJECT CODE"].Value
        ---On remplit toutes les info de B par une chaîne de caractère (le csv
est incompatible avec des cases vides)
        for i=0,35 do
            B[i][Code].Value = " "
        end
        B[21][Code].Value = Phase[i]["PROJECT NAME"].Value --Nom du programme
        B[29][Code].Value =0 --Nombre
de ressources pour ce programme
        B[35][Code].Value =Code --Code
programme

    end

end
```

```

for i=0,#Phase-1 do

    if((Phase[i]["PROJECT TYPE"].Value == "R&D Program") and
(Phase[i]["STATUS"].Value == "Complete"))then

        --Extraction de l'info contenue dans "FIRST PLAN START DATE" si la
phase concernée nous est utile
        k=1000
        if(Phase[i]["MILESTONE TYPE"].Value == "Program Preparation Phase")
then
            k=0
        end
        if(Phase[i]["MILESTONE TYPE"].Value == "Program Concept Phase") then
            k=1
        end
        if(Phase[i]["MILESTONE TYPE"].Value == "Program Feasibility Phase")
then
            k=2
        end
        if(Phase[i]["MILESTONE TYPE"].Value == "Program Capitalization Phase")
then
            k=3
        end

        if(k==0 or k==1 or k==2 or k==3) then

            Nom = Phase[i]["PROJECT NAME"].Value
            Code = Phase[i]["PROJECT CODE"].Value

            B[29][Code].Value = B[29][Code].Value +k+1
            Debut= string.split(Phase[i]["FIRST PLAN START DATE"].Value,
"/")

            Fin = string.split(Phase[i]["FIRST PLAN END DATE"].Value, "/")
            B[k*5+1][Code].Value = (Phase[i]["MILESTONE TYPE"].Value)--Nom
de la phase

            if(Phase[i]["FIRST PLAN START DATE"].Value ~= " ") then
                B[k*5+2][Code].Value = os.time{year = Debut[3],
month=Debut[2], day =Debut[1]}--date début phase
            end
            if(Phase[i]["FIRST PLAN END DATE"].Value ~= " ") then
                B[k*5+3][Code].Value = os.time{year = Fin[3], month=Fin[2],
day =Fin[1]}--date fin phase
            else
                print("t")
            end
            B[k*5+4][Code].Value = 0----durée phase
            B[k*5+5][Code].Value = 0 ----ressources

        --Extraction d'info supplémentaires pour caractériser un
programme

        if(B[0][Code].Value~=Code) then
            NbreProg=NbreProg+1
            B[0][Code]= Phase[i]["PROJECT CODE"].Value
            B[21][Code].Value = Phase[i]["PROJECT NAME"].Value
            B[22][Code].Value = (Phase[i]["STRATEGICAL AXIS"].Value)

            B[23][Code].Value = (Phase[i]["COORDINATION"].Value)
            B[24][Code].Value = (Phase[i]["SUBGROUP"].Value)
            B[25][Code].Value = (Phase[i]["TECHNOLOGY"].Value)

```

```

B[26][Code].Value = (Phase[i]["ACTIVE INITIAL CLOSURE
DATE"].Value)
B[27][Code].Value = (Phase[i]["ACTIVE CLOSURE DATE"].Value)
B[28][Code].Value = (Phase[i]["ACTIVE START DATE"].Value)

end
end
end

--Calcule de la durée d'une phase (=Fin de la phase -début de la phase)
for i=0,NbreProg-1 do

    if(tonumber(B[29][i].Value)==10 )then

        for k=0,3 do
            B[k*5+4][i].Value =B[k*5+3][i].Value-B[k*5+2][i].Value
        end

    end

end

--On va ensuite extraire les informations des autres fichiers de tracking
for i_maillages=0,#maillages_listes-1 do

    Fichier = maillages_listes[i_maillages]
    print(Fichier)
    A:ReadFile (Fichier)

    for i=0,#A-1 do

        if((A[i]["PROJECT TYPE"].Value == "R&D Program") and
(A[i]["TRACK/FRCST"].Value == "TRACK") and (A[i]["MONTH"].Value~= " "))then

            Nom = A[i]["PROJECT NAME"].Value
            Code = A[i]["PROJECT CODE"].Value

            TRACK = string.split(A[i]["MONTH"].Value, "/")
            date = os.time{year = TRACK[1], month=TRACK[2], day
=31}

            for k=1,4-1 do --il y a 4 phases

                if (tonumber(B[29][Code].Value)==10 ) then

                    print(date,tonumber(B[(k-
1)*5+2][Code].Value),tonumber(B[k*5+3][Code].Value))
                    if((tonumber(B[(k-
1)*5+2][Code].Value)<=date) and (date< tonumber(B[k*5+3][Code].Value)))then

                        B[(k-1)*5+5][Code].Value = B[(k-
1)*5+5][Code].Value + tonumber(A[i]["DAYS"].Value)

                    end

                end

            end

        end

    end

end

```

```

end

--Information supplémentaire pour caractériser un programme
B[30][Code].Value = (A[i]["DIVISION"].Value)
B[31][Code].Value = (A[i]["DIVISION CODE"].Value)
B[32][Code].Value = (A[i]["PROJECT FAMILY"].Value)
B[33][Code].Value = (A[i]["FREE 1"].Value)
B[34][Code].Value = (A[i]["FREE 2"].Value)
--B[35][Code].Value = (A[i]["LOCALISATION"].Value)

end

end

end

--Structure que l'on sauvegarde : on extrait les informations de B pour lesquels
les 4 phases sont renseignées
ind=0
local RES = CO.SeparatedFields:New ()
RES.HasHeader = true
RES.Separator = ";"
for i=0,NbreProg-1 do

    --Si les 4 phases sont renseignées
    if(tonumber(B[29][i].Value)==10)then

        for j=0,35 do
            RES[j][ind].Value=B[j][i].Value
        end
        ind=ind+1

    end

end

end

--Sauvegarde du résultat
filename = [C:\Users\lecaina\Documents\2015\1-DonneesERA\2-DonneesERA\Bilan.csv]
RES:ToFile(filename)
print("fin")

function string:split(sep)
    local sep, fields = sep or ":", {}
    local pattern = string.format("(^[^%s]+)", sep)
    self:gsub(pattern, function(c) fields[#fields+1] = c end)
    return fields
end

```

## ANNEXE 2 :

```
year = db.Antifog.aggregate(
[
  {
    $group:
      {
        _id: "",
        maxYear: { $max: "$year" },
        minYear: { $min: "$year" }
      }
  }
])

mini = ( year.result[0].minYear)
maxi = ( year.result[0].maxYear)

i=1;
var yearTab=[];
for (var annee= mini; annee <= maxi; annee++) {
  yearTab[i]=annee;
  i=i+1;
}
var monResult=[];
i=1;
for (var annee= mini; annee <= maxi; annee++) {
  var mapFunction = function(){
    emit(this.title,1)
  };
  var reduceFunction = function(key,values){return Array.sum(values)};
  var queryParam = {query : {"year" :annee},out:"result_set"};
  db.Antifog.mapReduce(mapFunction,reduceFunction,queryParam);
  monResult[i]=db.result_set.count()
  i=i+1;
}

var monResultPatent=[];
i=1;
for (var annee= mini; annee <= maxi; annee++) {
  var mapFunction = function(){
    test = this.url.indexOf("patent")
    if(test==--1){
      emit(this.title,0)
    }else{
      emit(this.title,1)
    }
  };
  var reduceFunction = function(key,values){return Array.sum(values)};
  var queryParam = {query : {"year" :annee},out:"result_set"};
  db.Antifog.mapReduce(mapFunction,reduceFunction,queryParam);
  monResultPatent[i]=db.result_set.count()
  i=i+1;
}

var monResultEssilor=[];
i=1;
```

```

for (var annee= mini; annee <= maxi; annee++) {
    var mapFunction = function(){
        test = this.excerpt.indexOf("essilor")
        if(test== -1){
            emit(this.title,0)
        }else{
            emit(this.title,1)
        }
    };
    var reduceFunction = function(key, values){return Array.sum(values)};
    var queryParam = {query : {"year" : annee}, out: "result_set"};
    db.Antifog.mapReduce(mapFunction, reduceFunction, queryParam);
    monResultEssilor[i]=db.result_set.count()
    i=i+1;
}

var monResultPatentEssilor=[];
i=1;
for (var annee= mini; annee <= maxi; annee++) {
    var mapFunction = function(){
        test = this.excerpt.indexOf("essilor")
        test2 = this.url.indexOf("patent")
        if(test== -1 && test2== -1){
            emit(this.title,0)
        }else{
            emit(this.title,1)
        }
    };
    var reduceFunction = function(key, values){return Array.sum(values)};
    var queryParam = {query : {"year" : annee}, out: "result_set"};
    db.Antifog.mapReduce(mapFunction, reduceFunction, queryParam);
    monResultPatentEssilor[i]=db.result_set.count()
    i=i+1;
}

```