

NFE204

Mini Projet

**Étude statistique de la
base d'adresses
Nationale Ouverte BANO**

Auditeur : VOINOT Eric
Dossier suivi par : Philippe RIGAUX

Année
2015

NFE204 00	Bases de données documentaires et distribuées	Eric VOINOT
		27/06/2015
	Étude de la BANO	Page 1

Sommaire

Introduction	2
La BANO vue de MongoDB	4
Étude de CouchDB	6
Conclusion	10

NFE204 00	Bases de données documentaires et distribuées	Eric VOINOT 27/06/2015
	Étude de la BANO	Page 2

Introduction


Étant curieux dans le cadre de différents projets professionnels d'être en mesure d'estimer la population ou au minimum le nombre d'habitations localisée dans une rue, je me suis donc mis à la recherche d'une telle base de données.

C'est après plusieurs recherches ouvertes sur internet que j'ai découvert sur le site www.data.gouv.fr la base d'adresses Nationale Ouverte BANO.

Cette base contient plus de 15 millions d'adresses composites collectées depuis plusieurs sources telles que OpenStreetMap et les bases de données des communautés urbaines de grandes villes telles que PARIS, Montpellier, Strasbourg,.... Cette base reste certes incomplète par rapport aux données de l'INSEE, mais elle dispose d'attributs qui correspondent plus à mes besoins.

Les taux d'adresses renseignées approchent pour l'instant les 40% en moyenne. Cette base devrait cependant devenir plus représentative par les actions engagées pour sa constitution (création d'un guichet unique pour la mise à jour, élargissement du nombre de partenariats).

Cette pertinence peut être observée sur la carte de synthèse de la répartition de ces adresses.



Pour chaque adresse on trouve la liste des attributs suivants :

- ▶ id (unique) : code_insee + codefantoir + numero
- ▶ numero : numéro dans la voie avec suffixe (ex: 1, 1BIS, 1D)
- ▶ voie : nom de voie
- ▶ code_post : code postal sur 5 caractères
- ▶ nom_comm : nom de la commune
- ▶ source : OSM = donnée directement issue d'OpenStreetMap, OD = donnée provenant de source open data locales, O+O = donnée opendata enrichie par OSM, CAD = donnée directement issue du cadastre, C+O = donnée du cadastre enrichie par OSM (nom de voie par exemple)
- ▶ lat : latitude en degrés décimaux WGS84
- ▶ lon : longitude en degrés décimaux WGS84

NFE204 00	Bases de données documentaires et distribuées	Eric VOINOT 27/06/2015
	Étude de la BANO	Page 3

Ces données sont disponibles sous plusieurs formats (csv, shapefile, ttl, json) à l'adresse suivante :

<http://bano.openstreetmap.fr/data/>

Dans le cadre de ce projet, je vais me restreindre à la base de données mosellane (département 57)

 bano-57-shp.zip 05-Jul-2015 05:11 11M

 bano-57.csv 05-Jul-2015 05:10 20M

 bano-57.json.gz 05-Jul-2015 06:17 4.2M

 bano-57.ttl.gz 05-Jul-2015 05:11 9.2M

- ▶ Mon étude doit me permettre d'obtenir des données statistiques spatiales, telles que le nombre d'adresses dans un périmètre donné (pour obtenir des notions sur le nombre d'habitants pouvant y résider) le nombre d'adresses dans une rue.
- ▶ La répartition des adresses par type de voie.
- ▶ Le nombre d'adresses par communes.
- ▶ Trouver la position géographique d'une adresse.


La BANO vue de MongoDB

Lancement du serveur MongoDB

>mongod

Lancement d'un client MongoDB

>mongo



```

Microsoft Windows [version 6.1.7601]
Copyright (c) 2009 Microsoft Corporation. Tous droits réservés.

C:\Users\Eric>mongo
2015-07-06T22:47:33.914+0200 Hotfix KB2731284 or later update is not installed,
will zero-out data files
MongoDB shell version: 2.6.9
connecting to: test
Server has startup warnings:
2015-07-06T22:44:53.264+0200 [initandlisten]
2015-07-06T22:44:53.264+0200 [initandlisten] ** WARNING: mongod started without
--replSet yet 1 documents are present in local.system.replset
2015-07-06T22:44:53.264+0200 [initandlisten] **          Restart with --replSet
unless you are doing maintenance and no other clients are connected.
2015-07-06T22:44:53.264+0200 [initandlisten] **          The TTL collection moni
tor will not start because of this.
2015-07-06T22:44:53.264+0200 [initandlisten] **          For more info see http:
//dochub.mongodb.org/core/ttlcollections
2015-07-06T22:44:53.264+0200 [initandlisten]
>

```

Création de la base bdd

NFE204 00	Bases de données documentaires et distribuées	Eric VOINOT 27/06/2015
	Étude de la BANO	Page 4

>use bdd

Création de la collection adresses

>db.createCollection("adresses")

```
> db.createCollection("adresses")
{ "ok" : 1 }
>
```


Chargement des données dans MongoDB

>mongoimport -d bdd -c adresses --file bano-57.json --jsonArray

Essai d'insertion depuis Robomongo

L'insertion de fichier JSON reste également possible directement depuis l'interface de Robomongo.

La fenêtre insert Document permet de vérifier si le fichier est valide avec le bouton valide et d'insérer les données avec le bouton save.



Les premières requêtes sous MongoDB

Afin d'évaluer le nombre de données constituant cette base, il paraît important dans un premier temps de constituer quelques statistiques sur les données chargées

Nombre d'enregistrements :

> db.adresses.count() : 67898

Liste des différentes communes et nombre

> db.adresses.distinct("city") :

Nombre de communes différentes

> db.adresses.distinct("city").length : 730

Liste des rues de la commune de Creutzwald

> db.adresses.find({city:"Creutzwald", type:"street"}, {name:1})

Nombre de rue trouvées

> db.adresses.find({city:"Creutzwald", type:"street"}, {name:1}).length():261

NFE204 00	Bases de données documentaires et distribuées	Eric VOINOT 27/06/2015
	Étude de la BANO	Page 5

Liste des rues d'une commune (rues distinctes)

```
> db.adresses.distinct("name",{city:"Creutzwald"})
```


Nombre de rues distinctes trouvées:

```
> db.adresses.distinct("name",{city:"Creutzwald"}).length :375
```

Etude de CouchDB

Lancer l'interface de couchDB et créer la base adresses

http://127.0.0.1:5984/_utils/index.html



Préparation du fichier avant insertion :

Le fichier JSON de la BANO n'est pas fourni sous une forme de tableau et ne peut donc pas être importé en sous couchDB.

Ce fichier doit être transformé sous la forme de tableau suivante :

```
{ "docs": [
    { "id": ...} ,
    { "id": ...} ,
  ]
}
```

Pour insérer les virgules nécessaires entre chaque champs, le remplacement de caractères au moyen de Notepad++ semble une solution simple et rapide.

```
*C:\Users\Eric\bano-57.json - Notepad++
Fichier Edition Recherche Affichage Encodage Langage Paramétrage Macro Exécution Compléments Documents ?
bano-57.json
1 { "docs": [
2   { "id": "57001", "type": "village", "name": "Aboncourt", "postcode": "57920", "lat": "49.260323", "lon": "6.345546", "city": "Aboncourt", "departement": "Moselle", "region": "Lorraine",
3   { "id": "57002", "type": "village", "name": "Aboncourt-sur-Seille", "postcode": "57590", "lat": "48.815924", "lon": "6.338821", "city": "Aboncourt-sur-Seille", "departement": "Moselle", "region": "Lorraine",
4   { "id": "57003", "type": "town", "name": "Abreschviller", "postcode": "57560", "lat": "48.636535", "lon": "7.096371", "city": "Abreschviller", "departement": "Moselle", "region": "Lorraine",
5   { "id": "57004", "type": "village", "name": "Achain", "postcode": "57340", "lat": "48.913043", "lon": "6.590878", "city": "Achain", "departement": "Moselle", "region": "Lorraine",
6   { "id": "57006", "type": "town", "name": "Achen", "postcode": "57412", "lat": "49.043332", "lon": "7.181914", "city": "Achen", "departement": "Moselle", "region": "Lorraine",
7   { "id": "57007", "type": "village", "name": "Adaincourt", "postcode": "57580", "lat": "49.004902", "lon": "6.435792", "city": "Adaincourt", "departement": "Moselle", "region": "Lorraine",
8   { "id": "57008", "type": "village", "name": "Adelange", "postcode": "57380", "lat": "49.005158", "lon": "6.610931", "city": "Adelange", "departement": "Moselle", "region": "Lorraine",
9   { "id": "57009", "type": "village", "name": "Ajoncourt", "postcode": "57590", "lat": "48.844314", "lon": "6.288818", "city": "Ajoncourt", "departement": "Moselle", "region": "Lorraine",
10  { "id": "57010", "type": "village", "name": "Alaincourt-la-Côte", "postcode": "57590", "lat": "48.897803", "lon": "6.339980", "city": "Alaincourt-la-Côte", "departement": "Moselle", "region": "Lorraine",
11  { "id": "57011", "type": "village", "name": "Albestroff", "postcode": "57670", "lat": "48.931810", "lon": "6.855884", "city": "Albestroff", "departement": "Moselle", "region": "Lorraine",
12  { "id": "57012", "type": "town", "name": "Algrange", "postcode": "57440", "lat": "49.359080", "lon": "6.047574", "city": "Algrange", "departement": "Moselle", "region": "Lorraine",
13  { "id": "57013", "type": "town", "name": "Alsting", "postcode": "57515", "lat": "49.178341", "lon": "6.997835", "city": "Alsting", "departement": "Moselle", "region": "Lorraine",
14  { "id": "57014", "type": "village", "name": "Altrippe", "postcode": "57660", "lat": "49.028413", "lon": "6.819255", "city": "Altrippe", "departement": "Moselle", "region": "Lorraine",
15  { "id": "57015", "type": "village", "name": "Altville", "postcode": "57730", "lat": "49.071665", "lon": "6.732015", "city": "Altville", "departement": "Moselle", "region": "Lorraine",
16  { "id": "57016", "type": "village", "name": "Alzing", "postcode": "57320", "lat": "49.278643", "lon": "6.554408", "city": "Alzing", "departement": "Moselle", "region": "Lorraine",
17  { "id": "57017", "type": "town", "name": "Amanvillers", "postcode": "57865", "lat": "49.166705", "lon": "6.041733", "city": "Amanvillers", "departement": "Moselle", "region": "Lorraine",
18  { "id": "57018", "type": "village", "name": "Amélcourt", "postcode": "57170", "lat": "48.838284", "lon": "6.501169", "city": "Amélcourt", "departement": "Moselle", "region": "Lorraine",
19  { "id": "57019", "type": "city", "name": "Amnéville", "postcode": "57360", "lat": "49.260434", "lon": "6.140724", "city": "Amnéville", "departement": "Moselle", "region": "Lorraine",
20 ]
}
```

Chargement des données dans CouchDB en utilisant l'api bulk document qui permet de charger le fichier complet sous la forme d'un tableau

```
>curl -X POST http://127.0.0.1:5984/adresses/_bulk_docs -d @bano-57.json -H "content-Type:application/json"
```

Pour la suite des requêtes j'utilise l'interface futon de couchDB

Cette interface est disponible à l'adresse

http://127.0.0.1:5984/_utils/database.html?adresses

Nombre de voies dans la base adresses :

Map Function	Reduce Function
<pre>function(doc) { emit("nombre de voies", 1); }</pre>	<pre>function(key, values){ return sum(values) ; }</pre>

"nombre de voies" : 67898

Liste des différentes communes et nombre de voies

Map Function	Reduce Function
<pre>function(doc) { emit(doc.city, 1); }</pre>	<pre>function(key, values){ return null; }</pre>

Key	Value
"Aboncourt"	null
"Aboncourt-sur-Seille"	null
"Abreschviller"	null
"Achain"	null
"Achen"	null
"Adaincourt"	null
"Adelange"	null
"Ajoncourt"	null
"Alaincourt-la-Côte"	null
"Albestroff"	null

NFE204 00	Bases de données documentaires et distribuées	Eric VOINOT 27/06/2015
	Étude de la BANO	Page 7

Nombre de communes différentes

```
> db.adresses.distinct("city").length : 730
```

Liste des rues de la commune de Creutzwald

Map Function	Reduce Function
<pre>function(doc) { emit(doc.city, 1); }</pre>	<pre>function(key, values){ return null; }</pre>

Key ▲	Value
"Avenue Beethoven" ID: 5fe1c4def781892892a058e85f26651	null
"Avenue Debussy" ID: 5fe1c4def781892892a058e85f3043	null
"Avenue des Roses" ID: 5fe1c4def781892892a058e85f77d39	null
"Avenue Descartes" ID: ab40b13e34b5094444b5e0745e6a9be5	null
"Avenue du Chemin de Per" ID: 5fe1c4def781892892a058e85f35248	null
"Avenue Millet" ID: 5fe1c4def781892892a058e85f62a8f	null
"Avenue Richard Wagner" ID: 5fe1c4def781892892a058e85f77a77	null
"Boulevard des Tulipes" ID: 5fe1c4def781892892a058e85f84c7f	null
"Boulevard du Garang" ID: 5fe1c4def781892892a058e85f4ba49	null
"Boulevard Montaigne" ID: 5fe1c4def781892892a058e85f648cb	null
"Boulevard Pascal" ID: 5fe1c4def781892892a058e85f6ec0	null
"Boulevard Rabelais" ID: 5fe1c4def781892892a058e85f75d1a	null
"Chemin de l'Hôpital" ID: 5fe1c4def781892892a058e85f5e26	null
"Chemin Rutte Bourguignonne" ID: 5fe1c4def781892892a058e85f308a2	null
"Ferme Aux Cloches" ID: 5fe1c4def781892892a058e85f304ac7	null
"Impasse Beau Rivage" ID: 5fe1c4def781892892a058e85f2596c	null

Nombre de rues trouvées par commune

Map Function	Reduce Function
<pre>function(doc) { emit(doc.city,1); }</pre>	<pre>function (key, values){ return sum(values); }</pre>

Key ▲	Value	Grouping: exact ▼	Reduce ☒
"Aboncourt"	76		
"Aboncourt-sur-Seille"	22		
"Abreschviller"	127		
"Achain"	47		
"Achen"	122		
"Adaincourt"	39		
"Adelange"	60		
"Ajoncourt"	47		
"Alaincourt-la-Côte"	34		
"Albestroff"	68		

Showing 1-10 of unknown rows

← Previous Page | Rows per page: 10 ▼ | Next Page →

Chercher les coordonnées du 14 rue de Metz à Faulquemont

NFE204 00	Bases de données documentaires et distribuées	Eric VOINOT 27/06/2015
	Étude de la BANO	Page 8

Map Function
<pre>function(doc) { if(doc.city=="Faulquemont" && doc.type=="street" && doc.name.toLowerCase()=="rue de metz"){ emit("Adresse",{"latitude":doc.housenumbers["14"].lat,"longitude":doc.housenumbe rs["14"].lon}); } }</pre>

Key ▲	Grouping: exact ▼	Value
"Adresse" ID: 2cf4f7a985e15f54a3e7945a1a13aefd		{latitude: 49.041738, longitude: 6.599633}
Showing 1-1 of 1 row		

Chercher les rues à moins de 200m de l'adresse précédente

Map Function
<pre>function(doc) { if(doc.type=="street"){ var lat1=(49.041738/ 180) * Math.PI; var lon1=(6.599633/ 180) * Math.PI; var lat2=(doc.lat/ 180) * Math.PI; var lon2=(doc.lon/ 180) * Math.PI; var d=2000*Math.asin(Math.sqrt((Math.pow(Math.sin((lat1-lat2)/2),2)) + Math.cos(lat1)*Math.cos(lat2)*(Math.pow(Math.sin((lon1-lon2)/2),2))))*6366 if(d<200){ emit (doc.name,d); } } }</pre>

Key ▲	Grouping: exact ▼	Value	Reduce
"Place Monce" ID: 5fe1c4de7f81892892a058e85385b3e		166.56638467773888	☒
"Rue de la Mairie" ID: 2cf4f7a985e15f54a3e7945a1a130cd7		180.558135223951	☐
"Rue de la République" ID: 2cf4f7a985e15f54a3e7945a1a1428a7		65.45170665010407	☐
"Rue de la Vieille Ville" ID: 5fe1c4de7f81892892a058e8538d932		126.84939021315924	☐
"Rue des Halles" ID: 5fe1c4de7f81892892a058e853802eb		188.9264592006733	☐
"Rue des Jardins" ID: 5fe1c4de7f81892892a058e85381ca1		99.70112984892037	☐
"Rue des Maréchaux" ID: 5fe1c4de7f81892892a058e853835d3		144.33580703008906	☐
"Rue du Château" ID: 5fe1c4de7f81892892a058e8537c0e4		95.53684598710578	☐
"Rue du Moulin" ID: 5fe1c4de7f81892892a058e85385ee5		139.4299459160122	☐
"Ruelle de Metz" ID: 5fe1c4de7f81892892a058e8538440a		89.31928031680081	☐
Showing 1-10 of 10 rows			

NFE204 00	Bases de données documentaires et distribuées	Eric VOINOT 27/06/2015
	Étude de la BANO	Page 9

Trouver le nombre d'habitations dans le périmètre de 200m groupées par rues

Map Function	Reduce Function
<pre>function(doc) { if(doc.city=="Faulquemont" && doc.type=="street"){ var lat1=(49.041738/ 180) * Math.PI; var lon1=(6.599633/ 180) * Math.PI; for each (nh in doc.housenumbers){ var lat2=(nh.lat/ 180) * Math.PI; var lon2=(nh.lon/ 180) * Math.PI; var d=2000*Math.asin(Math.sqrt((Math.pow(Math.sin((lat1- lat2)/2),2)) + Math.cos(lat1)*Math.cos(lat2)*(Math.pow(Math.sin((lon1- lon2)/2),2))))*6366 if(d<200){ emit (doc.name + " " + doc.city,d); } } } }</pre>	<pre>function (key, value){ return key.length; }</pre>

Key ▲	Grouping: exact ▼	Value	Reduce
"Place Monroe Faulquemont"		5	
"Rue de l'Eglise Faulquemont"		4	
"Rue de la Mairie Faulquemont"		11	
"Rue de la République Faulquemont"		14	
"Rue de la Vieille Ville Faulquemont"		22	
"Rue de Metz Faulquemont"		33	
"Rue de Pontpierre Faulquemont"		8	
"Rue des Halles Faulquemont"		3	
"Rue des Jardins Faulquemont"		4	
"Rue des Maréchaux Faulquemont"		7	

Showing 1-10 of unknown rows

← Previous Page | Rows per page: 10 ▼ | Next Page →

Conclusion:

Les différents résultats obtenus lors de cette étude m'ont permis de comparer l'exploitation de la BANO au travers de CouchDB et MongoDB.

La première différence est apparue lors du chargement des données. L'intégration d'une base json dans CouchDB nécessite un formatage des données.

Concernant l'interrogation des bases, CouchDB demande de rédiger les requêtes à l'aide de mapReduce sans obliger la rédaction de la fonction reduce. MongoDB quant à lui utilise un langage de requête plus complet.

Ces différentes conclusions et ces quelques requêtes m'ont permis de tester l'utilisation de ces logiciels dans le cadre d'une analyse topographique. Ce travail pourrait me permettre à terme d'utiliser cette base et ces fonctions pour réaliser des applications opérationnelles. Pour l'instant, cette base ne semble pas assez fiable pour garantir la pertinence des données lors d'une telle utilisation.