

CONSERVATOIRE NATIONAL DES ARTS ET METIERS

CNAM Région Centre

MEMOIRE

présenté en vue d'obtenir

L'Unité d'Enseignement NFE204 – Base de données avancée I

SPECIALITE : Informatique

OPTION : Système d'information

par

Stéphane LY

Google Search Appliance

Soutenu le 28 janvier 2014

JURY

PRESIDENT : Mr Philippe RIGAUX

Professeur

MEMBRES :

Liste des abréviations

GSA	Google Search Appliance
PCAI	Plan de Continuité d'Activité Informatique
SLA	Service Level Agreement (contrat de niveau de service)
SPI	Service Provider Interface

Glossaire

appliance	Solution intégrant matériel et logiciel, permettant une mise en œuvre simplifiée.
CentOS	Distribution Linux basée sur Red Hat
collection	Sous-ensemble de l'index, permettant de limiter les recherches
distribuée	Architecture GSA qui permet de répartir l'indexation et les requêtes de recherche sur plusieurs GSA.
frontal	Configuration définissant l'aspect et les fonctionnalités de la page de recherche et de la page de résultats.
Google Analytics	Solution professionnelle d'analyse d'audience Internet.
mirroring	Architecture GSA supportant la tolérance de panne via la réplication d'index entre deux ou plusieurs GSA.
unification	Architecture GSA étendant la capacité d'indexation sur plusieurs sites géographiques.

Table des matières

Liste des abréviations.....	2
Glossaire.....	3
Table des matières.....	4
Introduction.....	5
I PRINCIPE DE FONCTIONNEMENT DU GOOGLE SEARCH APPLIANCE ?.....	6
I.1 DÉFINITIONS.....	6
I.2 LES SOLUTIONS MOTEUR DE RECHERCHE DE GOOGLE.....	6
I.3 COMMENT FONCTIONNE LE GSA ?.....	7
I.3.1 Le format des requêtes de recherche.....	7
I.4 INDEXATION ET RECHERCHE SUR LES SERVEURS DE CONTENU.....	8
II LE DÉPLOIEMENT DU GSA.....	10
III LES PRINCIPALES FONCTIONNALITÉS.....	12
III.1 LES FONCTIONNALITÉS OFFERTES À L'UTILISATEUR.....	12
III.2 LES FONCTIONNALITÉS OFFERTES À L'ADMINISTRATEUR.....	12
IV MISE EN ŒUVRE CHEZ GMF ASSURANCES.....	13
IV.1 INSTALLATION DES GSA.....	13
IV.2 CONFIGURATION DES URL À EXPLORER.....	14
IV.2.1 Page de recherche et présentation des résultats de recherche.....	17
IV.2.2 Diagnostic d'exploration.....	19
Conclusion.....	20
Bibliographie.....	21

Introduction

La richesse d'une entreprise réside dans son savoir faire, ses compétences, ses ressources humaines. Chaque jour, ses collaborateurs produisent des présentations, des études de marché, des procédures techniques...Ces données peuvent représenter d'importants volumes et être stockées dans divers conteneurs: serveur web, partage réseau, système de gestion de contenu...

Disposer d'un accès à ces informations présente un grand intérêt à condition de pouvoir retrouver facilement l'information recherchée. De même, permettre aux internautes de trouver rapidement les informations pertinentes lorsqu'ils visitent le site web de l'entreprise, améliore l'image de marque de cette dernière et son impact commercial.

Pour répondre à ces besoins, Google propose sa solution « Google Search Appliance », un moteur de recherche destiné aux entreprises.

C'est cette solution que je présente dans le cadre de ce mémoire. J'étudie son principe de fonctionnement, détaille ses principales fonctionnalités, puis expose un exemple d'implémentation du Google Search Appliance chez GMF Assurances.

I Principe de fonctionnement du Google Search Appliance ?

I.1 Définitions

Le Google Search Appliance est la solution moteur de recherche universel de Google, destinée aux entreprises. Il se présente sous la forme d'un serveur monté en rack. La partie logicielle repose sur la distribution Linux CentOS tandis que le matériel est fabriqué par Dell Computers. La commercialisation du GSA fonctionne selon un système de licence de deux ans, incluant les coûts de maintenance, de support et de mise à jour logicielles. Ce packaging sous forme d'appliance, réduit les délais et la complexité de mise en œuvre. Le GSA s'intègre très facilement à au système d'information existant.

I.2 Les solutions moteur de recherche de Google

Google commercialise trois types de solution « moteur de recherche » :

Le Google Site Search est un moteur de recherche en ligne, destiné aux serveurs web publique. Sa facturation est fonction du nombre de requête de recherche effectuée par an.

Le Google Mini (figure 1.1) est une version d'entrée de gamme, qui propose les principales fonctionnalités pour l'indexation et la recherche d'information. Il peut indexer jusqu'à 300 000 documents. Il n'est plus commercialisé par Google depuis juillet 2012.



Figure 1.1: Google mini

Le Google Search Appliance (figure 1.2) se décline en deux modèles : GB7007 qui peut indexer jusqu'à 10 millions de documents et GB9009 qui dans sa version standard, prend en charge jusqu'à 30 millions de documents. Le GSA est évolutif, il est possible de relier plusieurs GSA entre eux afin d'en augmenter les capacités d'indexation et de recherche.



Figure 1.2: GSA GB7007 et GB9009

I.3 Comment fonctionne le GSA ?

Le GSA réalise essentiellement quatre grandes fonctions (figure 1.3).

L'exploration (crawl) : la première opération qu'effectue le GSA, une fois connecté au réseau d'entreprise est d'explorer les liens qui lui ont été soumis au travers de la console d'administration web.

L'indexation (index): il construit son index et va, pour chaque document trouvé, alimenter cet index.

Servir (serve): il répond aux requêtes de recherche des utilisateurs en leur présentant des résultats en fonction des paramètres définis dans ses « frontaux ».

Analyse : il analyse les requêtes de recherche afin d'améliorer les futures recherches et réalise des statistiques sur les recherches.




Figure 1.3 : fonctionnement du GSA

I.3.1 Le format des requêtes de recherche

Plusieurs méthodes peuvent être employées pour effectuer une requête de recherche.

1er méthode : on génère les requêtes HTTP GET vers le GSA à l'aide d'un simple formulaire HTML dans un navigateur web.

```
<form method="GET" action="http://search.mycompany.com/search">
<input type="text" name="q" size="32" maxlength="256" value="query string">
<input type="submit" name="btnG" value="Google Search">
<input type="hidden" name="site" value="default_collection">
<input type="hidden" name="client" value="default_frontend">
<input type="hidden" name="output" value="xml_no_dtd">
<input type="hidden" name="proxystylesheet" value="default_frontend">
</form>
```

2ème méthode : la requête de recherche est transmise au GSA par le biais d'une URL dans la page web. Les variables « site » définissant la collection et « client » définissant le frontal sont passées en paramètre de l'URL.

```
http://search.mycompany.com/search?q=query+string&site=default_collection  
&client=default_frontend &output=xml_no_dtd &proxystylesheet=default_frontend
```

3ème méthode : une application web effectue un HTTP GET vers le GSA.

```
GET /search?q=query+string&site=default_collection&client=default_frontend  
&output=xml_no_dtd &proxystylesheet=default_frontend HTTP/1.0
```

I.4 Indexation et recherche sur les serveurs de contenu

Grâce à ses connecteurs de contenu, le GSA est capable d'explorer et d'indexer différents types de documents dans différents conteneurs et de présenter les résultats de recherche au travers d'une interface unique pour l'utilisateur (figure 1.4)



Figure 1.4 : recherche et indexation dans multiples conteneurs

Dans l'exemple de la figure 1.5, on retrouve dans la même page de résultats de recherche, des données provenant d'un annuaire, d'un intranet, d'un système de gestion de contenu.

The screenshot shows a search interface for 'ACME SYSTEMS, INC.' with a search bar containing 'rlocke' and a 'Search' button. Below the search bar, there are links for 'Intranet', 'Directory', 'Rooms', and 'Maps'. The search results are titled 'Acme Systems Search' and show 'Results 1 - 10 (2.03 seconds). Sort by: Date | Relevance'. The results are categorized into four groups on the left:

- Annuaire des employés**: Points to the first result, 'Ryan Locke (rlocke) - blog - resume', which includes a photo and contact information.
- Intranet**: Points to the second result, 'Ryan Locke's Blog - A Better Place to Play', which is a blog post about Acme Systems, Inc. strategy.
- Gestion de contenu**: Points to the third result, 'Ryan Locke's documents', which is a document titled 'Documentum Home - Ryan Locke's documents'.
- Partage de fichiers**: Points to the fourth result, '[MS POWERPOINT] Widget Marketing Strategy.ppt', which is a PowerPoint presentation about redesigning the website for Acme Widgets.

Figure 1.5 : recherche dans multiples conteneurs

II Le déploiement du GSA

Le GSA est une solution évolutive et qui peut s'adapter aux besoins de l'entreprise en terme de SLA (contrat de niveau de service). Les aspects tolérance de panne, répartition de charge et haute disponibilité sont couverts par les trois types d'architecture de déploiement du GSA.

Mirroring (figure 2.1): cette architecture autorise la tolérance de panne en répliquant l'index entre deux ou plusieurs GSA, évitant ainsi de multiplier l'exploration des mêmes documents. La configuration des GSA peut être actif/passif ou actif/actif.

Une fois le mode mirroring activé, l'exploration et l'indexation ne se font que sur le GSA primaire. Les GSA secondaires peuvent répondre aux requêtes de recherche si la configuration des GSA est actif/actif. Un répartiteur de charge externe est nécessaire pour distribuer les requêtes de recherche vers les GSA.




Figure 2.1: architecture mirroring

Unification (figure 2.2): chaque GSA dispose de ses propres collections, frontaux et paramètres d'administration. Dans un environnement d'unification comprenant deux GSA, on peut ajouter un troisième GSA afin d'augmenter la capacité d'indexation. Cette architecture permet également de localiser des GSA sur des sites géographiques différents. Chaque GSA indexe ses documents locaux puis les rend accessibles pour la recherche aux sites distants. Différents modèles de GSA peuvent fonctionner ensemble en mode unification, toutefois, ils doivent exécuter la même version de logiciel (v6 minimum)

Un GSA est désigné nœud primaire, les autres sont désignés nœuds secondaires. Les requêtes de recherche des utilisateurs sont envoyées vers le GSA primaire. Celui-ci vérifie dans son index puis émet une requête de recherche sur les GSA secondaires. Les GSA secondaires retournent leurs résultats au GSA primaire. Ce dernier agrège ses résultats avec ceux des GSA secondaires et renvoie les résultats à l'utilisateur.




Figure 2.2 : architecture unification

Distribuée (figure 2.3) : cette architecture étend les capacités de recherche du GSA. Les GSA sont vus comme un unique GSA. Le GSA configuré en tant qu'admin master gère la configuration de l'exploration, de l'indexation et de la recherche pour l'ensemble des GSA.

Les GSA doivent être du même type (BG7007 ou GB9009) et exécuter la même version de logiciel. Ils doivent également être sur le même réseau local. L'exploration et la recherche distribuée nécessite une bande passante élevée entre chaque GSA.

Quelques limitations toutefois : l'index étant partitionné sur chaque GSA, lorsqu'une défaillance survient sur l'un d'eux, les données indexées sur ce GSA seront absentes de la recherche. L'architecture distribuée peut-être avec associée avec le mode mirroring pour obtenir la haute disponibilité.




Figure 2.3 : architecture distribuée

III Les principales fonctionnalités

III.1 Les fonctionnalités offertes à l'utilisateur

Le GSA propose à l'utilisateur la plupart des fonctionnalités qu'il a l'habitude de trouver sur le moteur de recherche en ligne <http://www.google.com>, auxquelles s'ajoutent des améliorations adaptées aux entreprises pour faciliter les recherches, et les rendre utiles et intuitives.

La suggestion de requête, à la manière de Google Suggestions, permet d'affiner les requêtes afin de faciliter la saisie et la navigation des utilisateurs.

La recherche communautaire, donne la possibilité aux utilisateurs de sélectionner des pages web à promouvoir dans les résultats pour une requête donnée.

La recherche personnalisée, adapte les résultats de recherche à différents groupes d'utilisateur, selon leur service ou leur fonction dans l'entreprise

Les requêtes associées, permettent de définir des synonymes pour des acronymes ou des termes qui font partie du jargon de l'entreprise et pour ensuite présenter ces termes dans le cadre de suggestions de requêtes.

Le résumé dynamiques des pages génère dynamiquement un extrait de la page, facilitant l'évaluation de la pertinence des résultats en les situant dans un contexte donné.

La mise en cache des pages consiste à copier en cache des pages répertoriées dans les résultats de recherche afin d'obtenir des résultats même lorsque les sites ne sont pas accessibles en ligne.

La recherche par période restreint les résultats de recherche sur une période donnée.

La recherche par plage de nombre limite les résultats de recherche à une plage de nombre, par exemple une fourchette de prix.

La recherche booléenne avancée utilise les opérateurs booléens (AND, OR...) pour construire des requêtes de recherche complexe.

III.2 Les fonctionnalités offertes à l'administrateur

La console d'administration web est le point d'entrée principal pour la configuration, l'administration du GSA. Plusieurs rôles sont configurables (administrateur, lecture seule, droits sur une collection ...)

Le contrôle SNMP surveille l'état du système et affiche les statistiques d'exploration.

L'intégration de Google Analytics pour les sites Web publics, permet d'analyser la manière dont les visiteurs utilisent le site web afin d'améliorer les résultats de recherche.

Les interfaces personnalisées : la page de recherche peut-être personnalisée en utilisant l'assistant de conception de modèle ou les feuilles de style XSLT.

Authentification (LDAP, NTLM, Kerberos...), les protocoles d'authentification les plus courants sont pris en charges.

Les connecteurs de contenu pour base de données, pour les systèmes de fichiers (CIFS/SMB, NFS, DFS) communiquent avec l'interface SPI (Service Provider Interface) du GSA pour lui permettre d'indexer différents types de contenu.

IV Mise en œuvre chez GMF Assurances

GMF Assurances a choisi en 2006 la solution Google Search Appliance pour indexer et permettre la recherche sur son site web publique <http://www.gmf.fr>.

Le cahier des charges de l'époque stipule que la solution doit pouvoir indexer des documents de l'espace publique mais aussi certains documents de l'espace sociétaire, accessible uniquement après une authentification sur le site web.

Les résultats de recherche sont présentés sur le site web de manière transparente pour l'internaute. Certains mot-clés doivent renvoyer vers des URLs spécifiques.

Certains types de documents ne doivent pas être indexés (.js, jpeg, formulaire d'authentification...)

Enfin, le service de recherche doit supporter la tolérance de panne.

Pour ces raisons, le Google Search Appliance a été retenu. Deux appliances sont achetées, une primaire et une de secours. Un répartiteur de charge externe de type F5 BIGIP se charge de router les requêtes de recherche vers le GSA de secours lorsque le primaire est inaccessible.

IV.1 Installation des GSA

GMF dispose de deux salles informatique (A et E) sur le même site à SARAN (45770). Ces deux salles prennent chacune le relais de l'autre dans le cadre d'un PCAI (plan de continuité d'activité informatique).

Le GSA primaire est installé en salle A, le GSA de secours en salle E.

Une fois les GSA alimentés électriquement et connectés au réseau, la configuration peut commencer. On utilise une connexion directe au port console du GSA, puis on ouvre l'URL suivante depuis un navigateur web <http://192.168.255.1:1111>.

Cette première configuration permet de donner au GSA son nom d'hôte, sa configuration réseau, de lui définir ses serveurs DNS, SMTP, LDAP... Tous les éléments qui lui seront nécessaires pour trouver et joindre les serveurs de contenu à indexer.

IV.2 Configuration des URL à explorer

Toutes les opérations de configuration se font via la console d'administration web.

Une fois authentifié, on arrive sur la page d'accueil (figure 4.1) qui affiche un état du système et des statistiques d'exploration.



Figure 4.1 : page d'accueil du GSA

Le sous-menu «URL à explorer» permet de saisir les URL à explorer. Plusieurs formats d'URL sont supportés : internet, unc, connecteur de contenu...C'est également dans ce sous-menu que l'on indique les types de fichiers et les URL qui seront exclus de l'indexation.

Accueil

Utilisateur admin connecté depuis l'adresse IP : 56.45.39.141, 56.45.39.141

▼ Explorer et indexer

URL à explorer

Planification de l'exploration

Accès du robot d'exploration

Serveurs proxy

En-têtes HTTP

Hôtes dupliqués

Dates des documents

Planification des charges d'hôte

Fréquence d'actualisation

Collections

► Traitement

► États et rapports

► Administration

Débuter l'exploration à partir des URL suivantes : * (Aide)

https://homol-secontaire-services.gmf.fr/techniquepas/Logon.do?
gsa=true&login=Y0007713139&pwd=00000&avantagesoc=
https://homol-secontaire-services.gmf.fr/espace-societaire/securise/index.jsp
https://homol-secontaire-devis-assure.gmf.fr/devis-souscription/vehicules/pages/devi-
auto/DAP0.faces
https://homol-secontaire-devis-assure.gmf.fr/
https://homol-secontaire-espace-assure.gmf.fr/pointentree/client/homepage
https://homol-secontaire-espace-assure.gmf.fr/
http://homol.covea-finance.fr/
http://www.covea-finance.fr/
smb://filsar01/COMMUNS/MADOC/
https://homol-secontaire-espace-assure.gmf.fr/techniquepas/index.faces

exemple : http://www.monentreprise.fr/

*obligatoire

Suivre et explorer les URL se présentant dans les formats suivants : * (Aide - Tester ces formats)

homol.gmf.fr/
homol-services.gmf.fr/
homol-devis-assure.gmf.fr/
homol-espace-assure.gmf.fr/
homol-secontaire.gmf.fr/
homol-secontaire-services.gmf.fr/
homol-secontaire-devis-assure.gmf.fr/
homol-secontaire-espace-assure.gmf.fr/
homol.covea-finance.fr/
www.covea-finance.fr/
smb://filsar01/COMMUNS/MADOC/
homol-secontaire-espace-assure.gmf.fr/techniquepas/index.faces

exemple : monentreprise.fr/

*obligatoire

Figure 4.2 : sous-menu URL à explorer

L'exploration fonctionne en continu par défaut. Elle peut être modifiée pour fonctionner sur des plages horaires données.

← → ↻ 56.45.3.17:8000/EnterpriseController?actionType=crawlSchedule

Google™ Google Mini > Explorer et indexer > Planification de l'exploration

Accueil

▼ Explorer et indexer

URL à explorer

Planification de l'exploration

Accès du robot d'exploration

Serveurs proxy

En-têtes HTTP

Hôtes dupliqués

Dates des documents

Planification des charges d'hôte

Fréquence d'actualisation

Collections

► Traitement

► États et rapports

► Administration

Utilisateur admin connecté depuis l'adresse IP : 56.45.39.141, 56.45.39.141

Sélectionnez un mode d'exploration : (Aide)

☒ Exploration continue

☐ Exploration complète (peut être planifiée, voir ci-dessous)

Fréquence d'actualisation pour l'exploration continue

Accédez à la page [Fréquence d'actualisation](#) pour configurer l'exploration continue.

L'option Fréquence d'actualisation est facultative.

©2002-2008 Google - À propos

Figure 4.3 : sous-menu Planification de l'exploration

On configure ensuite les comptes de connexion aux serveurs de contenus.

Accueil

▼ Explorer et indexer

URL à explorer

Planification de l'exploration

Accès du robot d'exploration

Serveurs proxy

En-têtes HTTP

Hôtes dupliqués

Dates des documents

Planification des charges d'hôte

Fréquence d'actualisation

Collections

► Traitement

► États et rapports

► Administration

Utilisateur admin connecté depuis l'adresse IP : 56.45.39.141, 56.45.39.141

Utilisateurs et mots de passe pour l'exploration : (Aide)

Pour autoriser le système à explorer des serveurs Web protégés par une authentification utilisateur, vous devez ajouter un nom d'utilisateur et un mot de passe à l'en-tête de chaque requête. Indiquez un domaine uniquement si cela est nécessaire (notamment lors de l'exploration de serveurs Web Microsoft IIS).

Pour les URL correspondant à ce format, utiliser : Nom d'utilisateur : Domaine : Mot de passe : Confirmez le mot de passe : Rendre public : Position :

smb://filsai01/COMMUNS/	admlidap2	ads01			*	☒	Descendre
*googleconnector://prodcc.localhost/	gsae	ads01			*	☒	Monter Descendre
https://homol-secondaire-devis-assu	Y0007713139				*	☒	Monter Descendre
https://homol-secondaire-devis-assu	Y0007713139				*	☒	Monter Descendre
https://homol-secondaire-espace-as	Y0007713139				*	☒	Monter Descendre
https://homol-secondaire-espace-as	Y0007713139				*	☒	Monter Descendre
https://homol-devis-assure.gmf.fr/tec	Y0007713139				*	☒	Monter Descendre
https://homol-devis-assure.gmf.fr/	Y0007713139				*	☒	Monter Descendre
https://homol-espace-assure.gmf.fr/	Y0007713139				*	☒	Monter Descendre

Figure 4.4 : sous-menu Accès du robot d'exploration

Une collection est un sous-ensemble de l'index. Elle permet de restreindre les résultats de recherches.

Accueil

▼ Explorer et indexer

URL à explorer

Planification de l'exploration

Accès du robot d'exploration

Serveurs proxy

En-têtes HTTP

Hôtes dupliqués

Dates des documents

Planification des charges d'hôte

Fréquence d'actualisation

Collections

► Traitement

► États et rapports

► Administration

Utilisateur admin connecté depuis l'adresse IP : 56.45.39.141, 56.45.39.141

Une collection est un sous-ensemble de l'index. Vous pouvez, par exemple, créer une collection marketing ou ingénierie pour prendre en charge les recherches portant uniquement sur les pages marketing ou ingénierie de votre index. Vous devez indiquer le contenu de la collection à l'aide des formats d'URL. Vous avez la possibilité de créer autant de collections que vous le souhaitez. Pour tester les collections, utilisez le [Centre de test](#).

Collections actuelles (Aide)

GMF	Modifier	Exporter la configuration	Supprimer
GMF_PRO	Modifier	Exporter la configuration	Supprimer
GMF_SOC	Modifier	Exporter la configuration	Supprimer
Homol-GMF	Modifier	Exporter la configuration	Supprimer
Homol-GMF_PRO	Modifier	Exporter la configuration	Supprimer
Homol-GMF_SOC	Modifier	Exporter la configuration	Supprimer
Homol2-GMF_PRO	Modifier	Exporter la configuration	Supprimer
Homol2-GMF_SOC	Modifier	Exporter la configuration	Supprimer
MADOC-AZUR-AUTO	Modifier	Exporter la configuration	Supprimer
MADOC-AZUR-IRD	Modifier	Exporter la configuration	Supprimer
MADOC-GMF-AUTO	Modifier	Exporter la configuration	Supprimer
MADOC-GMF-IRD	Modifier	Exporter la configuration	Supprimer
covea-finance	Modifier	Exporter la configuration	Supprimer
default_collection	Modifier	Exporter la configuration	Supprimer
homol-covea-finance	Modifier	Exporter la configuration	Supprimer

Remarque : L'index est mis à jour régulièrement à l'aide des informations de la collection. Prévoyez un certain délai avant l'actualisation de ces informations.

Créer une collection (Aide)

Nom de la collection :

Configuration initiale : ☒ Utiliser la configuration par défaut ☐ Importer la configuration à partir du fichier : Aucun fichier choisi

Figure 4.5 : sous-menu Collections

Dans l'exemple ci-dessous, n'apparaissent dans les résultats de recherche que le contenu correspondant aux URL indiquées.

Utilisateur admin connecté depuis l'adresse IP : 56.45.39.141, 56.45.39.141

[Retour à la liste de toutes les collections](#) Modifier la collection : Homol2-GMF_PRO

Remarque : La collection default_collection est définie par défaut avec le format "/", ce qui permet d'afficher les résultats de la recherche pour la totalité de l'index Google Search Appliance. Pour des raisons administratives, nous vous conseillons d'utiliser au moins une collection de ce format. Celle-ci permettra à l'administrateur de visualiser l'ensemble des URL indexées dans la page [États et rapports > Diagnostic d'exploration](#).

Inclure le contenu correspondant aux formats suivants : ([Aide](#) - [Tester ces formats](#))

```
homol-secondaire.gmf.fr/
homol-secondaire-services.gmf.fr/
homol-secondaire-espace-assure.gmf.fr/
homol-secondaire-devis-assure.gmf.fr/
```

exemple : <http://www.mycompany.com/engineering/>

Ne pas inclure le contenu correspondant aux formats suivants : ([Aide](#) - [Tester ces formats](#))

```
.css$
.js$
/jquery/
contains:j_security_check
```

Figure 4.6 : sous-menu Collections

IV.2.1 Page de recherche et présentation des résultats de recherche

Un frontal définit la page de recherche et la façon dont les résultats de recherche sont présentés à l'utilisateur. Il peut être créé et modifié en utilisant l'assistant de mise en page ou en éditant directement le code de la feuille de style XSLT.

[Accueil](#) [Retour à la liste de tous les frontaux](#) Modifier le frontal : madoc_filсар01_frontal Langue : Français (Par défaut) OK

[Explorer et indexer](#) [Format de sortie](#) [Correspondance](#) [Requêtes associées](#) [Filtres](#) [URL à supprimer](#) [Modules OneBox](#)

Frontaux
[Modules OneBox](#)
[Pondération des résultats](#)
[États et rapports](#)
[Administration](#)

Utilisateur admin connecté depuis l'adresse IP : 56.45.39.141, 56.45.39.141

L'Application d'assistance à la mise en page vous permet de modifier le format de sortie du champ de recherche et des pages de résultats. Pour apporter d'autres changements, utilisez l'Éditeur de feuilles de style XSLT qui permet notamment de modifier le code XSLT généré par l'Application d'assistance à la mise en page. ([Aide](#))

Application d'assistance à la mise en page ([Aide](#))

- Attributs globaux
- Champ de recherche
- Résultats de recherche

Enregistrer le code de mise en page Aperçu Exporter

Éditeurs de feuilles de style XSLT ([Aide](#))

Pour apporter des modifications supplémentaires au code XSLT, cliquez sur le lien ci-dessous. Les modifications que vous avez enregistrées dans l'Application d'assistance à la mise en page ci-dessus seront incluses dans le code XSLT.

REMARQUE : Une fois le code XSLT modifié, vous ne pourrez plus utiliser l'Application d'assistance à la mise en page, sauf si vous restaurez la feuille de style par défaut.

[Modifier le code XSLT](#)

Paramètres par défaut


Figure 4.7 : sous-menu Frontaux

► Attributs globaux

► Champ de recherche

▼ Résultats de recherche

Inclure :

- ☒ Logo ☒ Lien Recherche avancée ☒ Lien Conseils de recherche
☒ Champ de recherche (haut)
- ☒ Informations sur les recherches
☒ Barre bleue ☐ Ligne grise ☐ Aucun séparateur
- ☒ Préc. / Suiv. (haut) ☒ Trier par date / pertinence
- ☒ Extrait
☒ URL ☒ Taille de la page ☒ Date de modification ☒ Lien vers le cache
- ☒  Result Page: Previous 1 2 3 4 5 6 7 8 9 10 11 Next
- ☐ Result Page: Previous 1 2 3 4 5 6 7 8 9 10 11 Next
- ☐ Result Page: Previous Next
- ☒ Champ de recherche (bas)

Company logo Recherche avancée Conseils de recherche

Rechercher

Rechercher : titre Résultats 1 à 10 sur 500 Durée de la recherche : 0,3 s

[< Précédente](#) [Suiv. >](#) [Tri par date](#) / [Tri par pertinence](#)

[Résultat 1](#)

... extrait de la page Web avec les termes de recherche mis en évidence...
 ... autres termes avec leur contexte dans la page...

[www.website.com/url - 10k - DATE - En cache](#)

[Résultat 2](#)

... extrait de la page Web avec les termes de recherche mis en évidence...
 ... autres termes avec leur contexte dans la page...

[www.website.com/url - 10k - DATE - En cache](#)

[Résultat 3](#)

... extrait de la page Web avec les termes de recherche mis en évidence...
 ... autres termes avec leur contexte dans la page...

[www.website.com/url - 10k - DATE - En cache](#)

Result Page: Previous 1 2 3 4 5 6 7 8 9 10 11 Next

Rechercher

Figure 4.8 : assistant de mise en page

Code XSLT brut

Importer la feuille de style : Aucun fichier choisi

```
<!-- *** START OF STYLESHEET *** -->

<!-- *****
XSL to format the search output for Google Search Appliance
***** -->
<xsl:stylesheet xmlns:xsl="http://www.w3.org/1999/XSL/Transform" version="1.0">

<!-- *****
include customer-onebox.xsl, which is auto-generated from the customer's
set of OneBox Module definitions, and in turn invokes either the default
OneBox template, or the customer's:
***** -->
<xsl:include href="customer-onebox.xsl"/>

<xsl:output method="html"/>

<!-- *****
Logo setup (can be customized)
- whether to show logo: 0 for FALSE, 1 (or non-zero) for TRUE
- logo url
- logo size: '' for default image size
***** -->
<xsl:variable name="show_logo">1</xsl:variable>
<xsl:variable name="logo_url">images/Title_Left.gif</xsl:variable>
<xsl:variable name="logo_width">200</xsl:variable>
<xsl:variable name="logo_height">78</xsl:variable>

<!-- *****
Global Style variables (can be customized): '' for using browser's default
***** -->
```

Figure 4.9 : éditeur de feuilles de style XSLT

IV.2.2 Diagnostic d'exploration

Le sous-menu « diagnostic d'exploration » permet de vérifier l'état des URL explorées et les erreurs rencontrées.

Utilisateur admin connecté depuis l'adresse IP : 56.45.39.141, 56.45.39.141

Diagnostic d'exploration (Aide) Afficher les diagnostics pour la collection : Homol2-GMF_PRO

La page de diagnostic d'exploration présente des informations détaillées relatives à l'état de l'exploration effectuée par le système pour un domaine, un hôte, un répertoire ou une URL.

Indiquez les URL pour lesquelles vous souhaitez obtenir des diagnostics :

URL commençant par :

État des URL : Tous les états ☒ Inclure ☐ Exclure

Mode d'affichage des URL : ☒ Arborescence ☐ Liste

Tous les hôtes

Nom d'hôte	URL explorées	Erreurs d'extraction	URL exclues
homol-secondaire.gmf.fr	2000	61	0
homol-secondaire-devis-assure.gmf.fr	8	2	0
homol-secondaire-espace-assure.gmf.fr	38	4	0
homol-secondaire-services.gmf.fr	94	42	0

Figure 4.10 : sous-menu Diagnostic d'exploration

une URL

Mode d'affichage des URL : ☒ Arborescence ☐ Liste

Indiquez les URL pour lesquelles vous souhaitez obtenir des diagnostics :

URL commençant par :

État des URL : Tous les états ☒ Inclure ☐ Exclure

Tous les hôtes > http://homol-secondaire.gmf.fr/

PageRank	Fichier/Répertoire	État de l'exploration Tout afficher - Réussite - Erreurs - Exclues	Heure d'exploration
	actualites	87 explorées - 5 erreurs - 0 exclues	
	agents-services-publics	438 explorées - 16 erreurs - 0 exclues	
	besoins	238 explorées - 10 erreurs - 0 exclues	
	commun	139 explorées - 5 erreurs - 0 exclues	
	conseils-prevention	186 explorées - 11 erreurs - 0 exclues	
	envoi-ami	589 explorées - 1 erreurs - 0 exclues	
	etapes-vie	4 explorées - 1 erreurs - 0 exclues	
	groupe-gmf	123 explorées - 10 erreurs - 0 exclues	
	recherche	1 explorées - 0 erreurs - 0 exclues	
	services	4 explorées - 0 erreurs - 0 exclues	
	services.gmf.fr	1 explorées - 0 erreurs - 0 exclues	
	statique	183 explorées - 0 erreurs - 0 exclues	
	/	Exploré : nouveau document	06 Jan 9:43 PM
	accessibilite.jsp	Exploré : nouveau document	08 Jan 8:07 AM
	aide.jsp	Exploré : nouveau document	08 Jan 3:28 PM
	credit.jsp	Exploré : nouveau document	07 Jan 8:31 PM
	index.jsp	Exploré : nouveau document	07 Jan 7:58 AM
	mentions-legales.jsp	Exploré : nouveau document	09 Jan 11:47 AM
	plan.jsp	Exploré : nouveau document	08 Jan 8:07 AM
	popup-activation.html	Erreur : document non trouvé (404).	22 Dec 9:48 AM
	www.gmf.fr	Erreur : document non trouvé (404).	06 Jan 4:10 AM

Figure 4.11 : sous-menu Diagnostic d'exploration

Conclusion

L'évolution des technologies informatiques et l'augmentation du volume des données complexifient la gestion et la recherche d'information. Permettre une recherche efficace et pertinente est devenue un enjeu stratégique pour les entreprises.

Le Google Search Appliance se pose comme une réponse à cet enjeu. Simple à mettre en œuvre et évolutif, il peut s'adapter aux besoins des entreprises en terme de haute disponibilité, de tolérance de panne ou d'élasticité. Il bénéficie de l'expérience et de la technologie de Google, leader mondial des moteurs de recherche.

Une recherche efficace et utile fait gagner du temps aux collaborateurs qui peuvent alors se consacrer à l'analyse des informations, à la prise de décisions et à la création de nouveau contenu utile. Par conséquent, le GSA représente un bon retour sur investissement.

Toutefois, Il est regrettable que Google ne propose plus de solution d'entrée de gamme plus abordable comme le google mini pour les entreprises ou les administrations dont les besoins sont plus modestes.

Bibliographie

Documentation Google Search Appliance <https://developers.google.com/search-appliance/documentation/614/>

Google Search Appliance – présentation de la version 7.0
<http://googleenterprisefrance.blogspot.fr/2012/10/google-search-appliance-presentation-de.html>

Google Search Appliance <https://support.google.com/gsa/answer/2709672?hl=fr>

Google Search Appliance Gets New Algorithm
<http://www.webpronews.com/google-search-appliance-gets-new-algorithm-2009-10>

GSA http://fr.wikipedia.org/wiki/Google_Search_Appliance

Liste des figures

1.1 : Google mini.....	6
1.2 : GSA GB7007 et GB9009.....	6
1.3 : fonctionnement du GSA.....	7
1.4 : recherche et indexation dans multiples conteneurs.....	8
1.5 : recherche dans multiples conteneurs	9
2.1 : architecture mirroring.....	10
2.2 : architecture unification.....	11
2.3 : architecture distribuée.....	11
4.1 : page d'accueil du GSA.....	14
4.2 : sous-menu URL à explorer.....	15
4.3 : sous-menu Planification de l'exploration.....	15
4.4 : sous-menu Accès du robot d'exploration.....	16
4.5 : sous-menu Collections.....	16
4.6 : sous-menu Collections.....	17
4.7 : sous-menu Frontaux.....	17
4.8 : assistant de mise en page	18
4.9 : éditeur de feuilles de style XSLT.....	18
4.10 : sous-menu Diagnostic d'exploration.....	19
4.11 : sous-menu Diagnostic d'exploration.....	19

Présentation de la solution Google Search Appliance, son principe de fonctionnement, ses fonctionnalités et sa mise en œuvre chez GMF Assurances.

Mémoire d'Ingénieur C.N.A.M., Paris 2014

RESUME

L'évolution des technologies informatiques et l'augmentation du volume des données complexifient la gestion et la recherche d'information. Permettre une recherche efficace et pertinente est devenue un enjeu stratégique pour les entreprises.

L'étude du moteur de recherche Google Search Appliance et sa mise en œuvre chez GMF Assurances nous permet de vérifier que cette solution répond bien aux besoins de l'entreprise.

Mots clés : technologies, donnée, recherche, information, entreprise, moteur.

SUMMARY

The evolution of computer technology and the increase in the volume of data make data management and information retrieval more complex. Enable effective and relevant research has become a strategic issue for companies.

The study of the search engine Google Search Appliance and its implementation in GMF Assurances allows us to verify that this solution meets the needs of the business.

Key words : technology, data, search, information, companies, engine.