

Bases de données documentaires et distribuées  
Cours NFE04  
Bases documentaires

Auteurs : Raphaël Fournier-S'niehotta, Philippe Rigaux, Nicolas Travers  
prénom.nom@cnam.fr

Département d'informatique  
Conservatoire National des Arts & Métiers, Paris, France

## Objectifs

- Qu'est-ce qu'une base de données documentaire (ou base de données orientée documents) ?
- Pour quels documents une telle base de donnée est-elle appropriée ?
- Peut-elle remplacer une base relationnelle ?

## BD documentaire, pourquoi ?

Les exercices précédents nous ont permis de produire des documents (DocBook, SVG) en format XML.

Ces documents représentent du **contenu structuré** et ce **indépendamment de toute application**.

On peut donc construire des systèmes d'information : une bibliothèque numérique, un moteur de recherche, une application Web, des chaînes de publication, etc.

### Question

Quand on passe à l'échelle de milliers ou de millions de documents, comment les gérer ?

## Rôle d'une BD documentaire

Un **système de gestion de bases documentaires** fournit les services suivants.

- Stockage, préservation, sécurité des accès.
- Accès partagé et distant.
- Interrogation, recherche par contenu.
- Outils de traitement, de transformation.
- Passage à l'échelle par distribution.

## Petit panorama

C'est la galaxie des systèmes NoSQL...

Format XML

- BaseX,
- eXist,
- Oracle XML DB

Format JSON


- MongoDB
- CouchDB,
- autres....

Pas de format du tout (clé, valeur)

- Riak, MemCache
- HBase, Cassandra
- ....

## Plan de la présentation

## Prenons l'exemple de notre base de films



## En relationnel

Exemple avec associations 1 à plusieurs et plusieurs à plusieurs.

- Movie (**id**, title, year, genre, summary, *id\_director*, *country*)
- Artist (**id**, first\_name, last\_name, birth\_date)
- Role (*idMovie*, *idArtist*, role)

Caractéristique du relationnel : il faut faire des **jointures** pour reconstituer l'information.

Dans les bases documentaires : on essaie de créer des unités d'information **autonomes** pour éviter d'avoir à faire des jointures.

### Intuition

Les systèmes NoSQL sont conçus pour passer à l'échelle par distribution. C'est en grande partie incompatible avec les jointures.



## Représentation totalement autonome : films

Aucune référence à un autre document.

```
{
  "_id": "movie:57",
  "title": "Jackie Brown",
  "year": "1997",
  "director": {
    "_id": "artist:37",
    "last_name": "Tarantino", "first_name": "Quentin",
    "birth_date": "1963"
  },
  "actors": [
    {
      "_id": "artist:167",
      "first_name": "Robert", "last_name": "De Niro",
      "birth_date": "1943",
      "role": "Luis Gara"
    },
    {
      "_id": "artist:168",
      "first_name": "Pam", "last_name": "Grier",
      "birth_date": "1949",
      "role": "Jackie Brown"
    }
  ]
}
```

## Représentation totalement autonome : acteurs

```
{
  "_id": "artist:167",
  "first_name": "Robert", "last_name": "De Niro",
  "birth_date": "1943",
  "movies": [
    { "title": "Taxi Driver",
      "year": "1976",
      "genre": "crime",
      "director": {
        "last_name": "Tarantino", "first_name": "Quentin",
        "birth_date": "1963"
      }
    },
    { "title": "Jackie Brown",
      "year": "1997",
      "genre": "drame",
      "director": {
        "last_name": "Scorcese", "first_name": "Martin",
        "birth_date": "1942"
      }
    },
    ...
  ]
}
```

## Représentation avec références

et **uniquement** avec des références ..

```
{
  "_id": "movie:57",
  "title": "Jackie Brown",
  "year": "1997",
  "director": "artist:37",
  "actors": [ "artist:167", "artist:168", "artist:169", "artist:170",
"artist:212" ]
}
```

Concis, **mais** nécessite **beaucoup** de jointures (un peu moins qu'en relationnel).  
Comment faire avec MongoDB (à suivre) ?

## Discussion

Quand utiliser (ou pas) une base documentaire ?

- quand les documents contiennent peu ou pas de références ;
- **ou** quand on peut se permettre la redondance (peu de MaJ), **totale ou partielle** ;
- quand les “chemins” liant les documents sont très court (1, 2 max).
  - contre-exemple : artiste -> film -> réalisateur -> pays -> ...
  - exemple : excel sheet -> auteur.
- **on veut traiter de très gros volumes de manière “scalable”.**

Conditions non remplies : un système relationnel est **toujours** une option à considérer.

### Conclusion

C'est du cas par cas en fonction de l'application. Décision basée sur une réflexion préalable approfondie.

## Quelques éléments de réflexion

**Fait** : Les données d'une base relationnelle peuvent être représentées par un document textuel.

**Toujours se poser (au moins) les questions suivantes :**

- S'agit-il de représenter une structure régulière (p.e. une table) ?  
Dans ce cas il n'est pas nécessaire d'intégrer la structure et le contenu.

## Quelques éléments de réflexion

**Fait** : Les données d'une base relationnelle peuvent être représentées par un document textuel.

**Toujours se poser (au moins) les questions suivantes :**

- S'agit-il de représenter une structure régulière (p.e. une table) ?  
Dans ce cas il n'est pas nécessaire d'intégrer la structure et le contenu.
- Doit-on introduire des références à des entités identifiables ?  
Les modèles documentaires ne sont pas adaptés à un contenu ayant une forte densité de références à des entités.

## Quelques éléments de réflexion

**Fait** : Les données d'une base relationnelle peuvent être représentées par un document textuel.

**Toujours se poser (au moins) les questions suivantes :**

- S'agit-il de représenter une structure régulière (p.e. une table) ?  
Dans ce cas il n'est pas nécessaire d'intégrer la structure et le contenu.
- Doit-on introduire des références à des entités identifiables ?  
Les modèles documentaires ne sont pas adaptés à un contenu ayant une forte densité de références à des entités.
- La structure d'un document est-elle fixe et prévisible ?  
Contre-exemple : le rapport écrit.

Si réponse « oui » à l'une de ces questions

Bien méditer sur les avantages / inconvénients du recours à une **base de données** non conventionnelle (NoSQL).

## Ce qu'il faut retenir

Base de données documentaires = des fonctionnalités "bases de données" pour des unités d'information autonomes et peu/pas structurées.

- Valable pour les documents "multimédia" au sens larges : rapports, images, vidéos.
- Pas valable pour des données fortement structurées.
- La notion d'autonomie (pas d'association entre documents) est essentielle.
  - Autonomie ? On peut mettre en œuvre un **passage à l'échelle par distribution**. Typique des systèmes NoSQL.
  - Pas d'autonomie : un jour ou l'autre il faudra faire des jointures ; les systèmes NoSQL ne sont pas bon pour ça.
- Ne pas oublier : les schémas, le langage de requêtes, l'optimisation, la concurrence d'accès, ça compte beaucoup !

À vous de jouer...