

Bases de données
documentaires et distribuées,
<http://b3d.bdpedia.fr>

Cassandra: modélisation des données

Qu'est-ce que Cassandra ?

Cassandra, conçu à l'origine par Facebook, maintenant un projet de la fondation Apache, distribué par la société Datastax.

- Initialement basé sur le système BigTable de Google (stockage orienté colonnes)
- A fortement évolué vers un *modèle relationnel étendu*
- Un des rares systèmes NoSQL à proposer un typage fort
- Un langage de définition de schéma et de requêtes, CQL (pas de jointure)

Construit dès l'origine comme un système **scalable** et **distribué**.

Dans ce cours, nous étudions le modèle de données.

Modèle = relationnel + types complexes

Cassandra gère des **bases** (*keyspaces*), contenant des **tables** (a.k.a. *column families*).

Une table contient des **lignes** (*rows*) constituées de **valeurs simples** ou **complexes**.

Perspective A : c'est du relationnel étendu en rompant la première règle de normalisation (type atomique).

Perspective B : chaque ligne est un document structuré au sens où nous l'avons vu jusqu'ici.

Attention

Vocabulaire confus et parfois déroutant : *columns*, *column families*, etc.

Paires et documents

La structure de base est la paire (clé, valeur)

- Clé : un identifiant
- Valeur, : atomique (entier, chaîne de caractères), ou complexe (dictionnaire, ensemble, liste)

Une ligne (*row*, document) est un identifiant (*row key*) associé à un ensemble de paires (clé, valeur).

Les lignes sont **typées** par un schéma, y compris les données imbriquées.

Cassandra n'autorise pas (au moins avec CQL) l'insertion de données ne respectant pas le schéma.

Quelques aspects ignorés ici, le versionnement notamment.

Tables et base de données

Une **table** (anciennement *column family*) est un ensemble de *rows* conformes au schéma de la table.

Des notions de colonnes et super-colonnes sont (semble-t-il) en voie de disparition.

Une **base** est un ensemble de tables. On l'appelle *keyspace*. Explication ? Plus tard.

Conception d'un schéma

Cassandra ne propose pas de jointure. C'est du NoSQL après tout.

Il est donc préférable de **regrouper** les données le plus possible dans des lignes (notion de document autonome, déjà vue).

La conception devrait se baser sur les requêtes les plus fréquentes de l'application (cf. la session consacrée à la modélisation de données NoSQL).

Au pire, on représente les mêmes données sous plusieurs formes (redondance).

- Tous les films, avec leurs réalisateurs et acteurs.
- Tous les artistes, avec les films qu'ils ont tournés ou dans lesquels ils ont joué.

Application !

Création d'un *keyspace*.

```
create keyspace if not exists Movies
  with replication = { 'class' : 'SimpleStrategy',
                      'replication_factor': 3 };
```

Création d'une table (sans imbrication).

```
create table artists (id text,
                      last_name text, first_name text,
                      birth_date int, primary key (id)
                      );
```

Insertions

A la SQL

```
insert into artists (id, last_name, first_name, birth_date)
    values ('artist1', 'Depardieu', 'Gerard', 1948);
insert into artists (id, last_name, first_name, birth_date)
    values ('artist2', 'Baye', 'Nathalie', 1948);
insert into artists (id, last_name, first_name)
    values ('artist3', 'Marceau', 'Sophie');
```

Avec JSON

```
insert into artists JSON '{
    "id": 1,
    "last_name": "Coppola",
    "first_name": "Sofia",
    "birth_date": "1971"
}'
```

Avec imbrication

Création d'un type

```
create type artist (id text,  
                    last_name text,  
                    first_name text,  
                    birth_date int,
```

Table des films, avec imbrication.

```
create table movies (id text,  
                    title text,  
                    year int,  
                    genre text,  
                    country text,  
                    director frozen<artist>,  
                    primary key (id) );
```

Insertion de documents

À partir d'un document JSON

```
insert into movies JSON '{
  "id": "movie:1",
  "title": "Vertigo",
  "year": 1958,
  "genre": "drama",
  "country": "USA",
  "director": {
    "id": "artist:3",
    "last_name": "Hitchcock",
    "first_name": "Alfred",
    "birth_date": "1899"
  },
}';
```

Table des films, complète

```
create table movies (id text,  
                    title text,  
                    year int,  
                    genre text,  
                    country text,  
                    director frozen<artist>,  
                    actors set< frozen<artist>>,  
                    primary key (id) );
```

Données à récupérer sur [http ://webscope.bdpedia.fr](http://webscope.bdpedia.fr)