

Bases de données documentaires et distribuées
Cours NFE04
Installation de Solr

Auteurs : Raphaël Fournier-S'niehotta, Philippe Rigaux, Nicolas Travers
prénom.nom@cnam.fr

Département d'informatique
Conservatoire National des Arts & Métiers, Paris, France

Introduction

Systèmes d'indexation :


- Solr
 - Open Source
 - Fondation Apache
- Sphinx
- Elasticsearch

- ♠ Dans ce qui suit nous allons parler des documents Solr pour désigner la liste des champs transmise à l'index, et les distinguer des documents applicatifs de notre base de données documentaire
- ♠ Solr peut être vu comme une base de données spécialisée dans la recherche d'information : on y insère des documents (Solr), conformes à un schéma, et on peut rechercher des documents (Solr).

À quoi sert Solr ?

- Solr est une application spécialisée dans la recherche
- Repose sur l'index Lucene (Apache, auparavant projet distinct)
- Efficacité très élevée pour la recherche
- Moins pour les autres tâches de base de données (stockage, mise à jour fréquentes)
- Souvent c'est donc un **complément** d'un serveur de BDD (relationnelle ou documentaire)
- Spécialisé dans les recherches non structurées
- ex. : recherche par mot-clef dans un site Web
 - Documents gérés par MySQL
 - Extraction des textes et construction de l'index avec Solr
 - Le champ "Recherche" interroge Solr, qui répond

Architecture d'une application avec moteur de recherche



Installation

Installation très simple


- pré requis : Java 1.7 (au moins)
- télécharger l'archive de la dernière version stable (4.10.2) :
`http://lucene.apache.org/solr/downloads.html`
- la décompresser quelque part ("soldir") :

```
tar -xvzf solr-4.10.2.tgz ~/soldir
```

Démarrage

- aller dans `/soldir/example` :
`cd ~/soldir/example`
- taper la commande suivante :
`java -jar start.jar`
- laisser ce terminal ouvert
- lancer un navigateur et aller à l'adresse :
`http://localhost:8983/solr`

Admin



Insertion de documents

- Solr fournit des services REST (HTTP) pour recevoir/envoyer des instructions
- codées en JSON ou XML
- insérer de documents
- effectuer des requêtes
- accessible à l'URL `http://localhost:8983/solr/update`

Exemple pour une indexation :

- attente de document de type "Content-type :application/xml" (binaire)
- on utilise curl :
`curl http://localhost:8983/solr/update -data-binary @item.xml -H 'Content-type :application/xml'`

Indexation en pratique

- dans le dossier “soldir/example/exampledocs/”, il y a par exemple :
solr.xml
- on peut utiliser curl, mais aussi deux utilitaires fournis par Solr :
 - post.jar :
java -jar post.jar solr.xml
 - post.sh :
./post.sh *.xml
- sélectionner ensuite le core “Collection1” dans la barre de navigation

Consultation de la Collection1

The screenshot displays the Solr Admin web interface for a specific collection. The browser address bar shows the URL `localhost:8983/solr/#/collection1`. The interface is divided into several sections:

- Left Sidebar:** Contains navigation links for Dashboard, Logging, Core Admin, Java Properties, Thread Dump, and a dropdown menu for `collection1`. Below this is a list of tabs: Overview (selected), Analysis, Dataimport, Documents, Files, Ping, Plugins / Stats, Query, and Replication.
- Statistics Section:**
 - Last Modified: 11 minutes ago
 - Num Docs: 32
 - Max Doc: 38
 - Heap Memory: 889
 - Usage:
 - Deleted Docs: 6
 - Version: 14
 - Segment Count: 2
 - Optimized: (status icon)
 - Current: (status icon)
 - An `optimize now` button is available.
- Instance Section:**
 - CWD: `/Users/philippe/solr-4.7.2/example`
 - Instance: `/Users/philippe/solr-4.7.2/example/solr/collection1`
 - Data: `/Users/philippe/solr-4.7.2/example/solr/collection1/data`
 - Index: `/Users/philippe/solr-4.7.2/example/solr/collection1/data/index`
 - Impl: `org.apache.solr.core.NRTCachingDirectoryFactory`
- Replication (Master) Table:**

	Version	Gen	Size
Master (Searching)	1412609270579	5	38.09 KB
Master (Replicable)	1412609313976	6	-
- Healthcheck Section:**

Ping request handler is not configured with a healthcheck file.
- Footer:** Includes links for Documentation, Issue Tracker, IRC Channel, Community forum, and Solr Query Syntax.

Contenus des documents indexés

```
<add>
  <doc>
    <field name="id">SOLR1000</field>
    <field name="name">Solr, the Enterprise Search Server</field>
    <field name="manu">Apache Software Foundation</field>
    <field name="cat">software</field>
    <field name="cat">search</field>
    <field name="features">Advanced Full-Text Search Capabilities using Lucene</fi
    <field name="features">Optimized for High Volume Web Traffic</field>
    <field name="price">0</field>
    <field name="popularity">10</field>
    <field name="inStock">>true</field>
    <field name="incubationdate_dt">2006-01-17T00:00:00.000Z</field>
  </doc>
</add>
```

- Le document est constitué de **champs (fields)**,
- le nom du champ est indiqué par l'attribut **name**.
- il faut qu'ils aient été déclarés au préalable dans le **schéma** de l'index.
 - **price** est déclaré comme numérique
 - **features** comme chaîne de caractères

Interroger un index avec Solr

- Solr dispose d'une interface REST pour **rechercher** des documents :

```
http://localhost:8983/solr/select?q=video
```

- dans le navigateur, ou avec curl :

```
curl http://localhost:8983/solr/select?q=video
```

- La réponse est formatée en XML. On peut aussi demander un retour en JSON :

```
http://localhost:8983/solr/select?q=video&wt=json&indent=yes
```

- interface d'administration intégrée

Fenêtre d'interrogation de Solr

The screenshot displays the Solr Admin web interface. On the left is a sidebar with navigation links: Dashboard, Logging, Core Admin, Java Properties, Thread Dump, and a dropdown menu for 'collection1' containing Overview, Analysis, Dataimport, Documents, Files, Ping, Plugins / Stats, Query (selected), Replication, and Schema Browser. The main area is titled 'Request-Handler (qt)' and shows a '/select' endpoint. Below this, there are input fields for 'q' (containing 'video'), 'fq', 'sort', 'start, rows' (0 to 10), and 'fl'. The 'Raw Query Parameters' section shows 'key1=val1&key2=val2'. The 'wt' dropdown is set to 'json', and the 'indent' checkbox is checked. Other checkboxes for 'debugQuery', 'dismax', 'edismax', 'hl', 'facet', 'spatial', and 'spellcheck' are present. A blue 'Execute Query' button is at the bottom. The right pane shows the JSON response for the query 'http://localhost:8983/solr/collection1/select?q=video&wt=json&indent=true'. The response is a JSON object with a 'responseHeader' and a 'response' containing a 'docs' array with one document about an Apple 60 GB iPod.

```

{
  "responseHeader": {
    "status": 0,
    "QTime": 1,
    "params": {
      "indent": "true",
      "q": "video",
      "wt": "json"
    }
  },
  "response": {
    "numFound": 3,
    "start": 0,
    "docs": [
      {
        "id": "M4147LL/A",
        "name": "Apple 60 GB iPod with Video Playback Black",
        "manu": "Apple Computer Inc.",
        "manu_id_s": "apple",
        "cat": [
          "electronics",
          "music"
        ],
        "features": [
          "iTunes, Podcasts, Audiobooks",
          "Stores up to 15,000 songs, 25,000 photos, or 150 hours of video",
          "2.9-inch, 320x240 color TFT LCD display with LED backlight",
          "Up to 20 hours of battery life",
          "Plays AAC, MP3, WAV, AIFF, Audible, Apple Lossless, H.264 video",
          "Notes, Calendar, Phone book, Hold button, Date display, Photo wallet, Built-in games, JPEG photo playback, Up"
        ],
        "includes": "earbud headphones, USB cable",
        "weight": 5.5,
        "price": 399,
        "price_c": "399.00,USD",
        "popularity": 10,
        "inStock": true,
      }
    ]
  }
}

```

Réponse de Solr

- En-tête (propriétés sur l'exécution, dont temps de réponse)
 - Liste des **documents Solr** considérés comme satisfaisant les critères
 - constitués des valeurs de champs insérés dans l'index
 - cela ne suffira cependant souvent pas, il faudra accéder au **document applicatif** correspondant
 - importance du champ **id** (clef d'accès base documentaire)
- ♠ Certains champs (**cat** et **features** par exemple) sont multivalués (ils sont représentés par des tableaux en JSON). L'index en a tenu compte

Illustration de la puissance de Solr

- recherche par mot-clef
- **projection** (SQL) avec le paramètre **fl** (**field list**) :

```
http://localhost:8983/solr/select?q=video&fl=id, name
```

- spécifier dans quel champ on cherche :

```
http://localhost:8983/solr/select?q=name:black
```

- pagination de résultats :

```
http://localhost:8983/solr/select?q=video&start=1&rows=10
```
