

Bases de données
documentaires et distribuées,
<http://b3d.bdpedia.fr>

Introduction Ã la Recherche
d'Information

Recherche d'information

3 cours :

17 octobre : introduction générale à la RI

24 octobre : indexation

31 octobre : recherche avec classement

Travaux pratiques :

2-3 novembre : MongoDB

9-10 novembre : MongoDB MapReduce

7-8 décembre : Elasticsearch (1)

14-15 décembre : Elasticsearch (2)

11-12 janvier 2018 : calcul distribué (1)

18-19 janvier 2018 : calcul distribué (2)

Information Retrieval, définition

Une définition

La **Recherche d'Information** (*Information Retrieval*, IR) consiste à trouver des **documents** peu ou faiblement structurés, dans une grande **collection**, en fonction d'un **besoin d'information**.

Recherche sur le Web. Utilisée quotidiennement par des milliards d'utilisateurs.

Recherche dans votre boîte mail.

Recherche sur votre ordinateur (*Spotlight*).

Recherche dans une base documentaire, publique ou privée.

Information Retrieval, définition

Recherche plein texte : on cherche à examiner tous les mots de chaque document enregistré et à essayer de les faire correspondre à ceux fournis par l'utilisateur

À bien distinguer d'une recherche type "base de données" : requête structurée, données structurées, réponse « exacte ».

Contrairement à une base de données (SQL), le résultat dépend de **l'interprétation** d'un besoin. On ne peut jamais dire qu'un résultat est totalement exact (ou totalement faux).

Un exemple de besoin



Un moteur de recherche bien connu



[Tous](#) [Images](#) [Actualités](#) [Maps](#) [Vidéos](#) [Plus](#) [Paramètres](#) [Outils](#)

Environ 52 200 000 résultats (0,74 secondes)

Avocat (fruit) — Wikipédia
[https://fr.wikipedia.org/wiki/Avocat_\(fruit\)](https://fr.wikipedia.org/wiki/Avocat_(fruit)) ▼
Cet article ne cite pas suffisamment ses sources (janvier 2017). Si vous disposez d'ouvrages ou d'articles de référence ou si vous connaissez des sites web de ...
[Description](#) - [Variétés](#) - [Marché mondial](#) - [Utilisation dans l...](#)

Avocat (métier) — Wikipédia
[https://fr.wikipedia.org/wiki/Avocat_\(métier\)](https://fr.wikipedia.org/wiki/Avocat_(métier)) ▼
Représentation d'un avocat français au début du XX^e siècle. Appellation: Avocat. Secteur d'activité: Justice - Droit. Compétences requises: Bac+6, Master.
Professions voisines: [Juriste d'entreprise](#) - [Not...](#) Niveau de formation: Universitaire (Master en ...
Secteur d'activité: Justice - Droit Compétences requises: Bac+6, Master

Annuaire | Ordre des avocats de Paris
www.avocatparis.org/annuaire ▼
Accueil Annuaire. Annuaire. Voir l'annuaire international. La grande bibliothèque du droit - Barreau de Paris Solidarité - [Avocats Actions Conjointes](#) - [L'...](#)

E-barreau | Ordre des avocats de Paris
www.avocatparis.org/e-barreau ▼
1 déc. 2016 - A ce titre, il permet l'échange d'actes de procédure civile et pénale, dans le strict respect des dispositions légales. Les [avocats](#) peuvent alors, ...

Annuaire des avocats de France | Conseil national des barreaux
<https://www.cnb.avocat.fr/fr/annuaire-des-avocats-de-france> ▼
Vous êtes avocat et constatez une anomalie sur votre fiche ? Les données présentées sur cet annuaire proviennent directement des informations enregistrées ...

Virgile Amaudric du Chaffaut - Cabinet d'Avocat à Paris
[Annuaire](#) www.vadc-avocat.com/Avocat ▼
Avocat en Droit du Travail, Droit Pénal, Droit des Affaires et Droit Civil.
Information, transparence - défense, stratégie - écoute, disponibilité - conseil, anticipation
[Droit du Travail](#) - [Droit Civil et Familial](#) - [Droit Pénal](#) - [Droit des Affaires](#)
9 37 Quai des Grands Augustins, Paris

Le Bouard Avocats - Cabinet d'Avocats à Versailles
[Annuaire](#) www.lebouard-avocats.fr/ ▼
Avocats spécialisés en droit commercial, des affaires et droit du travail
Fondé En 1977 - Pro. Expérimentés - Service Performant - Gestion Electronique

Avocat fonction publique - Demandez un devis
[Annuaire](#) www.bruno-roze-avocat.com/ ▼
Intervention en conseil et contentieux pour les trois fonctions publiques

Recherches associées à avocat

avocat légume

avocat bienfaits

avocat wikipedia

avocat nutrition

avocat métier

avocat recette

Fonctionnalités avancées



WIKIPÉDIA
L'encyclopédie libre

[Accueil](#)
[Portails thématiques](#)
[Article au hasard](#)
[Contact](#)

[Contribuer](#)
[Débuter sur Wikipédia](#)
[Aide](#)
[Communauté](#)
[Modifications récentes](#)
[Faire un don](#)

[Outils](#)
[Importer un fichier](#)
[Pages spéciales](#)
[Version imprimable](#)

[Langues](#) 

Page spéciale

Rechercher

[Aide pour la recherche](#)

Rechercher

Avocat

[Avocat \(métier\)](#)

[Avocat en France](#)

[Avocat \(fruit\)](#)

[Avocatier](#)

[Avocat aux conseils](#)

[Avocats sans frontières France](#)

[Avocats et Associés](#)

[Avocat général \(France\)](#)

[Avocat général pour l'Angleterre et le pays de Galles](#)

[cookies](#) [Version mobile](#)

Wikipédia : recherche avancée



WIKIPÉDIA
L'encyclopédie libre

[Accueil](#)
[Portails thématiques](#)
[Article au hasard](#)
[Contact](#)

[Contribuer](#)
[Débuter sur Wikipédia](#)
[Aide](#)
[Communauté](#)
[Modifications récentes](#)
[Faire un don](#)

[Outils](#)
[Importer un fichier](#)
[Pages spéciales](#)
[Version imprimable](#)

[Langues](#)

Non connecté [Discussion](#) [Contributions](#) [Créer un compte](#) [Se connecter](#)

Page spéciale

Rechercher dans Wikipédia

Résultats de la recherche

[Aide pour la recherche](#)

Résultats 1 à 20 parmi 40 266

[Recherche interne](#) [Exalead](#) [Google](#) [Wikiwix](#) [Bing](#) [Yahoo!](#) [Global WP](#)

[Pages de contenu](#) [Multimédia](#) [Tout](#) [Recherche avancée](#)

Rechercher dans les espaces de noms :

Cocher :

☒ (Principal)	☐ Discussion	☐ MediaWiki	☐ Discussion MediaWiki	☐ Portail	☐ Discussion Portail
☐ Utilisateur	☐ Discussion utilisateur	☐ Modèle	☐ Discussion modèle	☐ Projet	☐ Discussion Projet
☐ Wikipédia	☐ Discussion Wikipédia	☐ Aide	☐ Discussion aide	☐ Référence	☐ Discussion Référence
☐ Fichier	☐ Discussion fichier	☐ Catégorie	☐ Discussion catégorie	☐ Module	☐ Discussion module
☐ Gadget	☐ Discussion gadget				
☐ Définition de gadget	☐ Discussion définition de gadget				

La page *Avocat* a été trouvée.

Avocat
allemande : **L'Avocat** (2011), film français de Cédric Anger. **L'Avocat**, géant de processions et de cortèges belge. **L'avocat** ou vert **avocat** est une couleur

1 Kio (146 mots) - 25 septembre 2017 à 23:57

ECommerce : recherche à facettes

Rechercher un produit

Le Marché

Produits frais

Fruits & Légumes

Boucherie

Surgelés

Epicerie

Boissons

Cave

Hygiène & Beauté

Entretien

Animaux

Bébé

Petit électro

Maison & Déco

Retour

RÉSULTAT DE MA RECHERCHE

15 résultat(s) pour "avocat"

Trier par : - cher au + cher Affichage :

J'AFFINE MA RECHERCHE :

Boutique

Hygiène & Beauté (5)

Le Marché (5)

Casher (2)

Epicerie (2)

Produits frais (1)

Prix

Moins de 5€ (10)

5 - 10€ (4)

10 - 20€ (1)

Marque

Garnier - Ultra Doux (4)

Cora (2)

Reyes Gutierrez (2)



1,99€

6,63€/Kg

Cora

Salsa saveur avocat doux 300g

- 1 +

Acheter

Epicerie > [...] > Tex-Mex



2,00€

2,00€/pièce

Avocat Hass

Reyes Gutierrez

À laisser mûrir

1 pièce à laisser mûrir

- 1 +

Acheter

Le Marché > [...] > Avocat



2,49€

2,49€/pièce

Avocat Hass

Reyes Gutierrez

Prêt à déguster

1 pièce prêt à déguster

- 1 +

Acheter

Le Marché > [...] > Avocat



2,80€

11,20€/L

Green Juices

Jus Avocat Pomme Poire Co...

250ml

DLC : dim. 26 nov. 17


- 1 +

Acheter

Produits frais > [...] > Bien être, Smoot

9

Évaluation d'un moteur de recherche



Environ 52 200 000 résultats (0,74 secondes)

Avocat (fruit) — Wikipédia

[https://fr.wikipedia.org/wiki/Avocat_\(fruit\)](https://fr.wikipedia.org/wiki/Avocat_(fruit)) ▼

Cet article ne cite pas suffisamment ses sources (janvier 2017). Si vous disposez d'ouvrages ou d'articles de référence ou si vous connaissez des sites web de ...

Description · Variétés · Marché mondial · Utilisation dans l ...

Avocat (métier) — Wikipédia

[https://fr.wikipedia.org/wiki/Avocat_\(métier\)](https://fr.wikipedia.org/wiki/Avocat_(métier)) ▼

Représentation d'un avocat français au début du XX^e siècle. Appellation. Avocat. Secteur d'activité. Justice - Droit. Compétences requises. Bac+6, Master.

Professions voisines: Juriste d'entreprise - Not... Niveau de formation: Universitaire (Master en ...
Secteur d'activité: Justice - Droit Compétences requises: Bac+6, Master

Annuaire | Ordre des avocats de Paris

www.avocatparis.org/annuaire ▼

Accueil Annuaire. Annuaire. Voir l'annuaire international. La grande bibliothèque du droit · Barreau de Paris Solidarité · Avocats Actions Conjointes · L' ...

E-barreau | Ordre des avocats de Paris

www.avocatparis.org/e-barreau ▼

1 déc. 2016 - A ce titre, il permet l'échange d'actes de procédure civile et pénale, dans le strict respect des dispositions légales. Les avocats peuvent alors, ...

Annuaire des avocats de France | Conseil national des barreaux

<https://www.cnb.avocat.fr/fr/annuaire-des-avocats-de-france> ▼

Vous êtes avocat et constatez une anomalie sur votre fiche ? Les données présentées sur cet annuaire proviennent directement des informations enregistrées ...

Virgile Amaudric du Chaffaut - Cabinet d'Avocat à Paris

(Annonce) www.vadc-avocat.com/Avocat ▼

Avocat en Droit du Travail, Droit Pénal, Droit des Affaires et Droit Civil.
Information, transparence - défense, stratégie - écoute, disponibilité - conseil, anticipation
Droit du Travail · Droit Civil et Familial · Droit Pénal · Droit des Affaires
9 37 Quai des Grands Augustins, Paris

Le Bouard Avocats - Cabinet d'Avocats à Versailles

(Annonce) www.lebouard-avocats.fr/ ▼

Avocats spécialisés en droit commercial, des affaires et droit du travail
Fondé En 1977 - Pro. Expérimentés - Service Performant - Gestion Electronique

Avocat fonction publique - Demandez un devis

(Annonce) www.bruno-roze-avocat.com/ ▼


Intervention en conseil et contentieux pour les trois fonctions publiques

Recherches associées à avocat

avocat légume avocat bienfaits

avocat wikipedia avocat nutrition

avocat métier avocat recette



Environ 52 200 000 résultats (0,74 secondes)

Avocat (fruit) — Wikipédia

[https://fr.wikipedia.org/wiki/Avocat_\(fruit\)](https://fr.wikipedia.org/wiki/Avocat_(fruit)) ▼

Cet article ne cite pas suffisamment ses sources (janvier 2017). Si vous disposez d'ouvrages ou d'articles de référence ou si vous connaissez des sites web de ...

Description · Variétés · Marché mondial · Utilisation dans l ...

Avocat (métier) — Wikipédia

[https://fr.wikipedia.org/wiki/Avocat_\(métier\)](https://fr.wikipedia.org/wiki/Avocat_(métier)) ▼

Représentation d'un avocat français au début du XX^e siècle. Appellation. Avocat. Secteur d'activité. Justice - Droit. Compétences requises. Bac+6, Master.

Professions voisines: Juriste d'entreprise - Not... Niveau de formation: Universitaire (Master en ...
Secteur d'activité: Justice - Droit Compétences requises: Bac+6, Master

Annuaire | Ordre des avocats de Paris

www.avocatparis.org/annuaire ▼

Accueil Annuaire. Annuaire. Voir l'annuaire international. La grande bibliothèque du droit · Barreau de Paris Solidarité · Avocats Actions Conjointes · L' ...

E-barreau | Ordre des avocats de Paris

www.avocatparis.org/e-barreau ▼

1 déc. 2016 - A ce titre, il permet l'échange d'actes de procédure civile et pénale, dans le strict respect des dispositions légales. Les avocats peuvent alors, ...

Annuaire des avocats de France | Conseil national des barreaux

<https://www.cnb.avocat.fr/fr/annuaire-des-avocats-de-france> ▼

Vous êtes avocat et constatez une anomalie sur votre fiche ? Les données présentées sur cet annuaire proviennent directement des informations enregistrées ...

Virgile Amaudric du Chaffaut - Cabinet d'Avocat à Paris

(Annonce) www.vadc-avocat.com/Avocat ▼

Avocat en Droit du Travail, Droit Pénal, Droit des Affaires et Droit Civil.
Information, transparence - défense, stratégie - écoute, disponibilité - conseil, anticipation
Droit du Travail · Droit Civil et Familial · Droit Pénal · Droit des Affaires
9 37 Quai des Grands Augustins, Paris

Le Bouard Avocats - Cabinet d'Avocats à Versailles

(Annonce) www.lebouard-avocats.fr/ ▼

Avocats spécialisés en droit commercial, des affaires et droit du travail
Fondé En 1977 - Pro. Expérimentés - Service Performant - Gestion Electronique

Avocat fonction publique - Demandez un devis

(Annonce) www.bruno-roze-avocat.com/ ▼

Intervention en conseil et contentieux pour les trois fonctions publiques

Recherches associées à avocat

avocat légume avocat bienfaits

avocat wikipedia avocat nutrition

avocat métier avocat recette

Évaluation d'un moteur de recherche

Deux notions importantes

Faux positifs : ce sont les documents **non pertinents** inclus dans le résultat ; ils ont été sélectionnés à tort.

Faux négatifs : ce sont les documents **pertinents** qui **ne sont pas** inclus dans le résultat.

La recherche plein texte est susceptible de récupérer beaucoup de faux positifs.

La récupération de documents non pertinents est souvent provoquée par l'ambiguïté inhérente au langage naturel ;

En général, chercher à réduire les faux positifs entraîne l'augmentation des faux négatifs, et réciproquement.

Évaluation de la pertinence : précision et rappel

La **précision** mesure la fraction des vrais positifs dans le résultat r .

Si on note $t_p(r)$ et $f_p(r)$ le nombre de vrais et de faux positifs dans r , alors


$$\text{précision} = \frac{t_p(r)}{t_p(r) + f_p(r)} = \frac{t_p(r)}{|r|}$$

Le **rappel** mesure la fraction de faux négatifs.

$$\text{rappel} = \frac{t_p}{t_p + f_n}$$

L'évaluation d'un système de RI est difficile : implique des tests rigoureux avec des utilisateurs sur un échantillon.

Illustration des faux-positifs et négatifs



How many selected items are relevant?

$$\text{Precision} = \frac{\text{true positives}}{\text{true positives} + \text{false positives}}$$

How many relevant items are selected?

$$\text{Recall} = \frac{\text{true positives}}{\text{true positives} + \text{false negatives}}$$

Performances

On peut améliorer les performances des moteurs de recherche à l'aide de plusieurs techniques :

- des requêtes plus structurées

 - requêtes booléennes,
 - expressions rationnelles,
 - proximité,
 - recherche d'expression

- des résultats classés

 - modèle vectoriel
 - PageRank
 - analyse sémantique latente

Moteurs de recherche

Moteurs libres

Apache Solr (Lucene)

ElasticSearch (Lucene)

Sphinx

Xapian

Moteurs commerciaux


Google Search Appliance

Exalead, Qwant

Amazon CloudSearch

Microsoft Azure Search, Bing

Bases documentaires et moteur de recherche



Bases documentaires et moteur de recherche

Un scénario typique :

- une recherche par mot-clé dans un site

- Les données du site sont gérées classiquement par une base documentaire (MySQL, Postgres, MongoDB)

- On extrait de la base tous les textes à **indexer** et on en fait des documents ES/Solr, à qui on les confie

- Ce dernier se charge alors de répondre quand un utilisateur emploie un champ de recherche.

Bases documentaires et moteur de recherche

Un moteur de recherche comme Elasticsearch ou Solr s'appuie sur un index

Pourquoi ne pas utiliser directement le moteur de recherche comme gestionnaire des documents ?

ElasticSearch permet des recherches puissantes, efficaces, ainsi que le stockage et l'accès aux documents.

Bases documentaires et moteur de recherche

Mais, comme Elasticsearch est entièrement consacré à la recherche, c'est-à-dire la lecture la plus efficace possible de documents.

il s'appuie pour cela sur des structures compactes, compressées, optimisées (les **index inversés**)

ce n'est pas un très bon outil pour les autres fonctionnalités d'une base de données :

Le stockage par exemple n'est ni aussi robuste ni aussi stable.

Pour des raisons qui tiennent à la structure de ces index, les mises à jour sont difficiles et s'effectuent difficilement en temps réel

Exercices simples

Exercices : fin de section 1 du chapitre 9 sur <http://b3d.bdpedia.fr>

Exemple de base

Un ensemble (modeste) de documents nous servira de guide.

- d_1 Le loup est dans la bergerie.
- d_2 Le loup et le trois petits cochons.
- d_3 Les moutons sont dans la bergerie.
- d_4 Spider Cochon, Spider Cochon, il peut marcher au plafond.
- d_5 Un loup a mangé un mouton, les autres loups sont restés dans la bergerie.
- d_6 Il y a trois moutons dans le pré, et un mouton dans la gueule du loup.
- d_7 Le cochon est à 12€ le Kg, le mouton à 10€/Kg.
- d_8 Les trois petits loups et le grand méchant cochon.

Le besoin et la solution

Besoin

On veut chercher tous les documents parlant de loups, de moutons mais pas de bergerie.

Parcourir tous les documents ? (Grep)

potentiellement long ;

critère "pas de bergerie" n'est pas facile à traiter ;

autres types de recherche ("le mot 'loup' doit être **près** du mot 'mouton'") sont difficiles ;

comment **classer** par pertinence les documents trouvés ?

Structure spécialisée : la **matrice d'incidence** et surtout son inversion.

Matrice avec documents en ligne

On sélectionne un ensemble de mots (ou **termes**), constituant notre **vocabulaire** (ou **dictionnaire**).

Documents en ligne, termes en colonnes. Dans chaque cellule : 1 si le terme est dans le document, 0 sinon.

La matrice d'incidence

	loup	mouton	cochon	bergerie	pré	gueule
d_1	1	0	0	1	0	0
d_2	1	0	1	0	0	0
d_3	0	1	0	1	0	0
d_4	0	0	1	0	0	0
d_5	1	1	0	1	0	0
d_6	1	1	0	0	1	1
d_7	0	1	1	0	0	0
d_8	1	0	1	0	0	0

Pour effectuer la recherche

(loup, mouton, et pas bergerie) On prend les vecteurs binaires des **termes** (les colonnes).

Loup : 11001101

Mouton : 00101110

Bergerie : 01010011

Puis :

ET logique sur les vecteurs de Loup et Mouton, on obtient 00001100.

ET logique avec le **complément** du vecteur de Bergerie (01010111)

On obtient 00000100, d'où on déduit que la réponse est limitée au document d_6 .

Opération binaires **très efficace**, mais...

Passons à grande échelle

Quelques hypothèses :

Un million de documents, mille mots chacun en moyenne.

Disons 6 octets par mot, soit 6 Go (ce n'est pas une si grosse base que cela)

Disons 500 000 termes **distincts**

⇒ la matrice d'incidence a :

10^6 lignes et 500 000 colonnes soit 500×10^9 bits

soit 62 Go approximativement

Ne tient pas en mémoire, ce qui va beaucoup compliquer les choses....

Comment faire mieux ?

On peut faire mieux

Il vaut mieux avoir les termes en ligne pour disposer des vecteurs dans une zone mémoire contigue.

On parle de matrice inversée, et de **liste inversée**. Une liste par terme ; dans chaque liste, 1 pour les documents contenant le terme.

Loup	➡	<table><tr><td>1</td><td>1</td><td>0</td><td>0</td><td>1</td><td>1</td><td>0</td><td>1</td></tr></table>	1	1	0	0	1	1	0	1
1	1	0	0	1	1	0	1			
Mouton	➡	<table><tr><td>0</td><td>0</td><td>1</td><td>0</td><td>1</td><td>1</td><td>1</td><td>0</td></tr></table>	0	0	1	0	1	1	1	0
0	0	1	0	1	1	1	0			
Cochon	➡	<table><tr><td>0</td><td>1</td><td>0</td><td>1</td><td>0</td><td>0</td><td>1</td><td>1</td></tr></table>	0	1	0	1	0	0	1	1
0	1	0	1	0	0	1	1			
Bergerie	➡	<table><tr><td>1</td><td>0</td><td>1</td><td>0</td><td>1</td><td>0</td><td>0</td><td>0</td></tr></table>	1	0	1	0	1	0	0	0
1	0	1	0	1	0	0	0			
Pré	➡	<table><tr><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>1</td><td>0</td><td>0</td></tr></table>	0	0	0	0	0	1	0	0
0	0	0	0	0	1	0	0			
Gueule	➡	<table><tr><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>1</td><td>0</td><td>0</td></tr></table>	0	0	0	0	0	1	0	0
0	0	0	0	0	1	0	0			

Important

Les mises à jour beaucoup plus difficiles car elles impliquent la réorganisation d'une liste compacte. Prix à payer pour l'efficacité en **lecture** (recherche).

On peut encore faire mieux

La matrice est **creuse** : il n'y a que 10^9 positions avec des 1, soit un sur 500.

Loup →

1	2	3	4	11	31	45	173	175
---	---	---	---	----	----	----	-----	-----

Mouton →

1	2	4	5	6	16	57	132
---	---	---	---	---	----	----	-----

Cochon →

2	31	54	101
---	----	----	-----

Essentiel

On place dans les cellules **l'identifiant** du document. De plus chaque liste est **triée** sur l'identifiant du document.

Index inversé

La structure utilisée dans **tous** les moteurs de recherche.

Un **répertoire** contient tous les **termes**.

Une **liste** (inversée) est associée à chaque **terme**, **triée** par docId.

Chaque élément de la liste est appelé une **entrée**.

Concept : la notion de **terme** (**token** en anglais) est différente de celle de “mot”.

Vocabulaire : le répertoire est parfois appelé *dictionnaire* ; les listes sont des *posting list* en anglais ; les entrées sont des *postings*.

Efficacité : le répertoire devrait toujours être en mémoire ; les listes, autant que possible en mémoire, sinon fichiers contigus sur le disque.


Traitement d'une recherche par *fusion* de listes triées

Recherchons les documents parlant de **loup** ET de **mouton**.

Algorithme par **fusion** : on parcourt **séquentiellement** les deux listes.

On compare à chaque étape les docId ; s'ils sont égaux : **trouvé** !

On avance sur la liste du plus petit docId.



Algorithme

```
1 // Fusion de deux listes l1 et l2
2 function Intersect($l1, $l2)
3 {
4     $résultat = [];
5     // Début de la fusion des listes
6     while ($l1 != null and $l2 != null) {
7         if ($l1.docId == $l2.docId) {
8             // On a trouvé un document contenant les deux termes
9             $résultat += $l1.docId;
10            // Avançons sur les deux listes
11            $l1 = $l1.next; $l2 = $l2.next;
12        }
13        else if ($l1.docId < $l2.docId) {
14            // Avançons sur l1
15            $l1 = $l1.next;
16        }
17        else {
18            // Avançons sur l2
19            $l2 = $l2.next;
```

Optimisation

Si l'on veut effectuer la recherche :

A AND B AND C

Quelle manière de procéder va optimiser le résultat ?

on stocke la taille des listes et l'on commence par faire l'intersection des plus petites

de nombreuses autres questions d'optimisation existent

exemple : stocker l'une des listes en mémoire et calculer les intersections à la volée, en lisant depuis le disque

Premier bilan

En résumé : index inversé, tri et compaction, parcours linéaire très rapide sont les fondements techniques de la RI.

Permet d'effectuer des recherches **puissantes** (combinaison de critères) et **flexibles**.

Garantissent une très grande efficacité.

Que reste-t-il à faire ?

Quels termes ? Quels termes indexe-t-on ? Beaucoup moins facile que ça n'en a l'air...

Quelles requêtes ? De la plus simple ("sac de mots") à plus structurée (index structuré, requêtes Booléennes, recherche de phrases).

Performance. Construction, compression, distribution, optimisation des accès, mises à jour, etc.

Classement ? Si j'ai des millions de documents dans le résultat, je veux les classer.
Comment ?