

Bases de données
documentaires et distribuées,
<http://b3d.bdpedia.fr>

Le langage Pig latin

Pig Latin

Un langage de haut niveau, type SQL, exécuté en MapReduce.

“Requête” Pig : opération qui prend une **relation** en entrée et produit une autre relation en sortie.

Les requêtes consistent en une **séquence** d'instructions

- *LOAD* charge les données d'un fichier (HDFS) sous la forme d'une **relation** (liste de n-uplets).
- Une série de transformations traite les données.
- L'instruction (optionnelle) *STORE* écrit le résultat dans le système de fichiers (HDFS); on peut aussi faire un *DUMP* pour afficher à l'écran.

Les requêtes sont évaluées par une **combinaison** de *jobs* MapReduce.

Tester Pig

Pig est un programme Java qui s'exécute en ligne de commande.

- Télécharger depuis <http://pig.apache.org>.
- Décompresser dans un répertoire, disons `pighome`
- Placer le répertoire `pighome/bin` dans le chemin d'exécution (PATH)
- Deux modes d'exécution
 - local** on lit les données sur le disque local, on évalue sans MapReduce
 - MapReduce** on exécute dans un *cluster* MapReduce, en lisant depuis HDFS.

Pour exécuter en local :

```
pig -x local  
grunt>run <script>.pig
```

Exemple de données en entrées (format tabulaire)

Un fichier texte, un n-uplet par ligne, champs séparés par des tabulations.

Fichier : publishers.txt

Fundations of Databases Addison-Wesley USA

Fundations of Databases Vuibert France

Web Data Management and Distribution CUP GB

Fichier : books.txt

1995 Fundations of Databases Abiteboul

1995 Fundations of Databases Hull

1995 Fundations of Databases Vianu

2010 Web Data Management Abiteboul

2010 Web Data Management Manolescu

2010 Web Data Management Rigaux

2010 Web Data Management Rousset

2010 Web Data Management Senellart

Premier exemple : on regroupe les auteurs par livre.

```
-- Chargement
books = load 'books.txt'
      as (year: int, title: chararray, author: chararray) ;
-- Regroupement
group_auth = group books by title;
-- Restruturation
authors = foreach group_auth generate group, books.author;
-- Affichage
dump authors;
```

Exécution

```
pig -x local
grunt>run groupby.pig
```

Modèle de données

Modèle semi-structuré, type XML/JSON. Imbrication de structures ensemblistes (“bags”) et de n-uplets.

Exemple : le *bag* group_auth.

```
(  
  Foundations of Databases,  
  { (1995,Fundations of Databases,Abiteboul),  
    (1995,Fundations of Databases,Hull),  
    (1995,Fundations of Databases,Vianu)  
  }  
)
```

Imbrication sans limite, mais pas de références ou dépendance externe : un “document” autonome.

Objectif parallélisation !

Un exemple complet : le fichier

Fichier : journal-small.txt

2005 VLDB J. Model-based approximate querying in sensor networks.
1997 VLDB J. Dictionary-Based Order-Preserving String Compression.
2003 SIGMOD Record Time management for new faculty.
2001 VLDB J. E-Services - Guest editorial.
2003 SIGMOD Record Exposing undergraduate students to system internals.
1998 VLDB J. Integrating Reliable Memory in Databases.
1996 VLDB J. Query Processing and Optimization in Oracle Rdb
1996 VLDB J. A Complete Temporal Relational Algebra.
1994 SIGMOD Record Data Modelling in the Large.
2002 SIGMOD Record Data Mining: Concepts and Techniques - Book Review.

Un exemple complet : le programme

Regroupement des publications par année.



```
-- Chargement des documents de journal-small.txt
articles = load 'journal-small.txt'
           as (year: chararray, journal:chararray, title: chararray) ;
sr_articles = filter articles by journal=='SIGMOD Record';
year_groups = group sr_articles by year;
count_by_year = foreach year_groups generate group,
                        count(sr_articles.title);
dump count_by_year;
```

À décomposer...

Principaux opérateurs Pig

Operator	Description
<i>foreach</i>	Applique une expression à chaque document
<i>filter</i>	Filtre les tuples sur certains critères
<i>distinct</i>	Elimination des doublons
<i>join</i>	Jointures de deux <i>bags</i>
<i>group</i>	Regroupement
<i>cogroup</i>	Association de n-uplets provenant de deux sources
<i>cross</i>	Produit cartésien de deux sources
<i>order</i>	Tri
<i>limit</i>	Limite la taille des données traitées
<i>union</i>	Union de deux sources (dont les schémas peuvent être très différents)
<i>split</i>	Partition d'une relation selon certains critères

Opérateur de “dégroupage”

flatten “déploie” une imbrication (flatten.pig).


```
-- Take the 'authors' bag and flatten the nested set  
flattened = foreach authors generate group, flatten($1);
```

Appliqué à la relation authors créée précédemment, on obtient :

```
(Foundations of Databases,Abiteboul)  
(Foundations of Databases,Hull)  
(Foundations of Databases,Vianu)  
(Web Data Management,Abiteboul)  
(Web Data Management,Manolescu)  
(Web Data Management,Rigaux)  
(Web Data Management,Rousset)  
(Web Data Management,Senellart)
```

L'opérateur cogroup

Permet d'assembler des n-uplets sur un ensemble de critères.



Exemple (cogroup.pig) :

```
publishers = load 'webdam-publishers.txt'
            as (title: chararray, publisher: chararray) ;
cogrouped = cogroup flattened by group,
             publishers by title;
```

Résultat (mis en forme)

Pour chaque valeur de regroupement, deux ensembles imbriqués, provenant de chacune des sources.

```
(Foundations of Databases,  
  { (Foundations of Databases,Abiteboul),  
    (Foundations of Databases,Hull),  
    (Foundations of Databases,Vianu)  
  },  
  {(Foundations of Databases,Addison-Wesley),  
    (Foundations of Databases,Vuibert)  
  }  
)
```

Une sorte de jointure, dans un état intermédiaire, permis par le modèle semim-structuré.

Jointures

Come précédemment, mais produit un résultat “mis à plat”.

On effectue le produit cartésien des n-uplets imbriqués (join.pig).

```
-- Take the 'flattened' bag, join with 'publishers'  
joined = join flattened by group, publishers by title;
```

```
(Foundations of Databases,Abiteboul,  
    Foundations of Databases,Addison-Wesley)  
(Foundations of Databases,Abiteboul,  
    Foundations of Databases,Vuibert)  
(Foundations of Databases,Hull,  
    Foundations of Databases,Addison-Wesley)  
(Foundations of Databases,Hull,  
    ...
```

Un exemple à tester

Avec ajout de filtres pour sélectionner certain n-uplets.

```
-- Chargement de books.txt
books = load 'books.txt'
      as (year: int, title: chararray, author: chararray) ;
-- On prend les livres de Victor Vianu
vianu = filter books by author == 'Vianu';
--- Chargement de publishers.txt
publishers = load 'publishers.txt'
            as (title: chararray, publisher: chararray) ;
-- Jointure sur le titre
joined = join vianu by title, publishers by title;
-- Groupement sur le nom de l'auteur
grouped = group joined by vianu::author;
-- Maintenant, comptons les editeurs (exercice: supprimer les doublons!)
count = foreach grouped generate group,
              COUNT(joined.publisher);
```

À vous de jouer.