

le **cnam**

Bases de Données Avancées

NFE204

Exercices

CNAM Paris

TABLE DES MATIÈRES

1 XML	3
1.1 Syntaxe XML	3
1.2 Arbre XML	4
1.3 Schéma DTD	4
1.4 XML et DTD	5
2 XPath	7
2.1 Évaluation XPath	7
2.2 Rédaction de requêtes XPath	7
3 Recherche d'Information	9
3.1 Modèle d'indexation textuel	9
3.1.1 Modèle Booléen	9
3.1.2 Modèle vecteur	10
3.2 Vocabulaire de termes	11
3.3 Compression et Distribution	13
3.3.1 Compression de fichiers inverse	13
3.4 Recherche par Similarité	14
3.4.1 Produit Scalaire	14
3.4.2 Cosinus	14
3.4.3 Précision / Rappel	15
3.5 PageRank	15
3.5.1 PageRank	15
3.5.2 Pertinence du contenu d'une page Web	16
4 Distribution	17
4.0.3 P2P, DHT, Chord	17

1.1 Syntaxe XML

Corrigez le document XML suivant. Vérifiez que votre document corrigé est bien formé. Pour cela, utilisez un éditeur de documents XML (Sera, Aquamacs, Xemacs, ... à vous de choisir) ou ouvrez tout simplement le document avec votre navigateur web qui intègre un parser XML.

```
<?xml version="3.0" encoding="utf-8" standalone="yes"?>
<logiciel Comptabilité>
  <version>1</version>
  <user>
    <uid>bgirot</uid>
  </user>
  <contact>
    <lastName>Giro</lastName>
    <firstName>Bernadette</FirstName>
    <email>ggirot@petites.fleurs.com</email>
  </contact>
  <author autId="ghuret" lastName="Huret" firstName="George" organism="AIDI">
    <company>
      <labId>3987</labId>
      <name>Analyse Informatique des Données & Information</name>
      <shortName>AIDI</shortName>
    </company>
  </author>
  <author autId="mgirard" lastName="Girard" firstName="Matin" firstName="Matin">
    <company>
      <labId>6670</labId>
      <name>La compta en vogue</name>
      <shortName>Vogu'la compta</shortName>
    </company>
    <company>
      <labId>4621</labId>
      <name>En avant les chiffres</name>
      <shortName>EAC</shortName>
    </company>
  </author>
</logiciel Comptabilité>
<date_mise_en_service>
  2007-09-17
</date_mise_en_service>
```

Correction :

```

<?xml version="1.0" encoding="utf-8"?>
<logicielComptabilite>
  <version>1</version>
  <user>
    <uid>bgirot</uid>
  </user>
  <contact>
    <lastName>Giro</lastName>
    <firstName>Bernadette</firstName>
    <email>ggiro<petites.fleurs.com</email>
  </contact>
  <author autId="ghuret" lastName="Huret" firstName="George" organism="">
    <company>
      <labId>3987</labId>
      <name>Analyse Informatique des Donne#es Information</name>
      <shortName></shortName>
    </company>
  </author>
  <author autId="mgirard" lastName="Girard" firstName="Matin" organism="">
    <company>
      <labId>6670</labId>
      <name>La compta en vogue</name>
      <shortName>Vogu'la compta</shortName>
    </company>
    <company>
      <labId>4621</labId>
      <name>En avant les chiffres</name>
      <shortName>EAC</shortName>
    </company>
  </author>
  <date_mise_en_service>
    2007-09-17
  </date_mise_en_service>
</logicielComptabilite>

```

1.2 Arbre XML

(Sur papier) Représentez l'arbre XML du document corrigé.

Correction : Arbre XML : balises dans des ovales et texte dans des carrés. Attributs attachés aux ovales.

Sous la plupart des éditeurs (pe. Emacs), un parseur intégré "souligne" les erreurs au fur et à mesure de l'écriture du fichier XML.

1.3 Schéma DTD

1. Créer une DTD permettant de valider ce document XML.

Correction :

```

<!DOCTYPE logicielComptabilite [
<!ELEMENT logicielComptabilite (version, user, contact, author*, date_mise_en_service)>
<!ELEMENT version (#PCDATA)>
<!ELEMENT user (uid)>
<!ELEMENT uid (#PCDATA)>
<!ELEMENT contact (lastname, firstname, email)>
<!ELEMENT lastname (#PCDATA)>
<!ELEMENT firstname (#PCDATA)>
<!ELEMENT email (#PCDATA)>
<!ELEMENT author (company)>
<!ELEMENT note (#PCDATA)>
<!ATTLIST author autId CDATA #REQUIRED>
<!ATTLIST author lastName CDATA #REQUIRED>
<!ATTLIST author firstName CDATA #REQUIRED>
<!ATTLIST author organism CDATA>
<!ELEMENT company (labId, name, shortName)>
<!ELEMENT labId (#PCDATA)>
<!ELEMENT name (#PCDATA)>
<!ELEMENT shortName (#PCDATA)> ]>

```

2. Trouvez dans la DTD suivante les erreurs :

```

<!DOCTYPE mon_annuaire [
<!ELEMENT annuaire (personne*)>
<!ELEMENT personne (nom, ?prenom, email+, equipe)>
<!ATTLIST personne type (etudiant | enseignant-chercheur | chercheur) "etudiant">
<!ATTLIST annee_naissance CDATA #REQUIRED>
<!ELEMENT nom (#CDATA)>
<!ELEMENT prenom (#PCDATA)>
<!ELEMENT equipe (nom, responsable)>
<!ELEMENT responsable (personne)>
<!ELEMENT note (#PCDATA)>
]>

```

Correction : le “?” est placé devant le prénom alors qu’il devrait être après.

Il manque le nom de l’élément pour l’attribut annee_naissance.

Le CDATA pour l’élément nom n’est pas correct (utilisable que pour les attributs).

note “tout seule” ne pose pas de soucis. Il ne sera simplement pas utilisé.

Le “bouclage” personne → equipe → personne ne pose de pb du point de vue de la syntaxe de la DTD, mais le bouclage ne satisfait aucun document XML.

1.4 XML et DTD

Pour le texte suivant, proposez un document XML et la DTD associée correspondant, et ce, sans redondance.

Le LRI, dont le directeur est Michel Beaudouin-Lafon, dispose de plusieurs équipes de recherche. Parmi elles, on trouve l’équipe Programmation (directeur Marie-Claude Gaudel), l’équipe Demonstration (directeur Christine Paulin), l’équipe Intelligence Artificielle et Systemes d’Inference (directeur Chantal Reynaud), l’équipe Inference et Apprentissage (directeur Michele Sebag) et l’équipe Bases de données (directeur Nicolas Spyrtos). Ces équipes participent à différents projets avec l’INRIA. Le projet GEMO (directeur Serge Abiteboul) implique l’équipe Intelligence Artificielle et Systemes d’Inference et l’équipe Bases de données, le projet TAO (directeur Marc Shoenauer) implique l’équipe Inference et Apprentissage, le projet InSitu (directeur Wendy Mackay) implique l’équipe Programmation et les projets Proval et Logical (directeur Gilles Dowek) impliquent l’équipe Demonstration.

Correction :

```

<?xml version="1.0" encoding="ISO-8859-1"?>
<!DOCTYPE laboratoire [
    <!ELEMENT laboratoire (directeur,equipe+,projet*)>
    <!ELEMENT directeur (#PCDATA)>
    <!ELEMENT equipe (directeur)>
    <!ATTLIST equipe
        nom CDATA #REQUIRED
        ref_projets IDREFS #REQUIRED
    >
    <!ELEMENT projet (directeur)>
    <!ATTLIST projet
        nom ID #REQUIRED
    >
]>
<laboratoire>
    <directeur>Michel Beaudouin-Lafon</directeur>
    <equipe nom="Programmation" ref_projets="InSitu">
        <directeur>Marie-Claude Gaudel</directeur>
    </equipe>
    <equipe nom="Demonstration" ref_projets="Logical Proval">
        <directeur>Christine Paulin</directeur>
    </equipe>
    <equipe nom="Intelligence Artificielle et Systemes d'Inference" ref_projets="GEMO">
        <directeur>Marie-Christine Rousset</directeur>
    </equipe>
    <equipe nom="Inference et Apprentissage" ref_projets="TAO">
        <directeur>Michele Sebag</directeur>
    </equipe>
    <equipe nom="Bases de données" ref_projets="GEMO">
        <directeur>Nicolas Spyrtos</directeur>
    </equipe>
    <projet nom="GEMO">
        <directeur>Serge Abiteboul</directeur>
    </projet>
    <projet nom="TAO">
        <directeur>Marc Shoenauer</directeur>
    </projet>
    <projet nom="InSitu">
        <directeur>Wendy Mackay</directeur>
    </projet>
    <projet nom="Logical">
        <directeur>Gilles Dowek</directeur>
    </projet>
    <projet nom="Proval">
        <directeur>Christine Paulin</directeur>
    </projet>
</laboratoire>

```

2.1 Évaluation XPath

Pour chaque expression XPath suivante, donner une phrase exprimant le résultat obtenu sur le document XML de référence¹. Vous testerez ces requêtes sur le logiciel *BaseX*².

1. `/child : :biblio/child : :book/child : :author`
Correction : Les auteurs de livres
2. `/child : :biblio/child : :book[position()=1]/child : :author[position()=1]`
Correction : Le premier auteur du premier livre
3. `/child : :biblio/child : :book/child : :title/child : :text()`
Correction : Titres des livres
4. `/child : :biblio/child : :book/attribute : :ISBN`
Correction : Les codes ISBN de livres
5. `/biblio/book/author`
Correction : Les auteurs de livres
6. `count(/biblio/book/author)`
Correction : Nombre d'auteurs de livres
7. `count(/biblio/book[1]/author)`
Correction : Nombre d'auteurs pour le premier livre
8. `biblio/book[@lang="fr"]/title`
Correction : Titre des livres écrits en français
9. `/biblio/book[not(position()=1)]/author`
Correction : Les auteurs dont les livres ne sont pas en première position

2.2 Rédaction de requêtes XPath

À partir de chaque phrase suivante, trouvez la requête XPath correspondante.

1. Livres n'ayant qu'un seul auteur
Correction : `/biblio/book[count(author)=1]`
2. Toute balise "book" ayant un fils avec un seul auteur
Correction : `/descendant-or-self : :book[count(child : :author) = 1] //book[count(author)=1]`
3. Tous les livres avant le deuxième livre
Correction : `/biblio/book[2]/preceding-sibling : :*`
4. Tous les livres après le deuxième livre
Correction : `/biblio/book[2]/following-sibling : :*`
5. Tous les auteurs de livres français
Correction : `/biblio/book[@lang='fr']/author`
6. Les titres de livres écrits en français écrit par "Knab"
Correction : `/biblio/book[@lang='fr']/author[contains(lastname,'Knab')]/parent : :book/title/text()`

1. Document de référence : <http://cedric.cnam.fr/~traversn/teaching/nfe204/bibliotheque.xml>

2. <http://basex.org/products/download/all-downloads/>

7. Nombre de livres dont le sujet est “databases”
Correction : `count(/book[@subject=“databases”])`
8. `count(//book)`
Correction : Nombre de livres
9. Premier et deuxième auteurs du premier livres
Correction : `/biblio/book[1]/author[2 or 1]`
10. Titre des livres écrit par Philippe Rigaux avec au moins un autre auteur
Correction : `//book[author[lastname = 'Philippe']][firstname = 'Rigaux']][count(author) > 1]/title`
11. Titre des livres dont le titre contient XML et publié chez Eyrolles
Correction : `//book/title[contains(title, “XML”)][contains(publisher/name, “Eyrolles”)]`
12. Auteurs ayant écrit au moins de livre
Correction : `//author[count(.[lastname = //author/lastname][firstname = //author/firstname]) > 1]`

3 RECHERCHE D'INFORMATION

3.1 Modèle d'indexation textuel

3.1.1 Modèle Booléen

Nous utiliserons ici un ensemble de document (défini par un docId) auquel nous allons associer un ensemble de mots-clés qui les caractérisent. Ci-joint les documents correspondant :

docId	terms
1	France, Récession, Ralentie, INSEE
2	USA, Finance, Paulson, Ralentie, Crise
3	Crise, Gouvernement, Ralentie, INSEE
4	PIB, France, Crise, Ralentie

1. Créer une matrice d'incidence sur les documents précédents.

Correction :

docId	France	Récession	Ralentie	INSEE	USA	Finance	Paulson	Crise	Gouvernement	PIB
1	1	1	1	1	0	0	0	0	0	0
2	0	0	1	0	1	1	1	1	0	0
3	0	0	1	1	0	0	0	1	1	0
4	1	0	1	0	0	0	0	1	0	1

2. Proposer une transformation des requêtes suivantes sous forme de requêtes booléennes :
 - "la crise ralentie"
 - "En France, selon l'Insee, le PIB"
 - "Aux USA, Paulson" mais sans le mot "crise"

Correction :

- $\text{crise} \wedge \text{ralentie}$
- $\text{France} \wedge \text{INSEE} \wedge \text{PIB}$
- $\text{USA} \wedge \text{Paulson} \wedge \neg \text{Crise}$

3. Evaluer les requêtes et donner les documents répondant à ces requêtes.

Correction :

- 2, 3, 4
- aucun document
- aucun document

4. Formaliser l'algorithme d'évaluation

Correction :

Soit la matrice M

Soit la requête de termes T (lié chacun par un opérateur o vrai ou not)

Soit L une liste de $docId$

Pour chaque terme t de la requête

$V = \text{vecteur}(M, \text{id}(t))$

```

Si (R est vide  $\wedge$  !dernier( $t$ ))
    V = R
Sinon
    Pour  $i = 1$  à nb_doc
        Si !dernier ( $t$ )
             $R[i] = (R[i] \wedge oV[i])$ 
        Sinon Si V est vide
            Si R[i]
                ajouter ( $L, i$ )
        Sinon Si  $R[i] \wedge oV[i]$ 
            ajouter ( $L, i$ )

```

3.1.2 Modèle vecteur

1. Créer, à partir des documents précédents, des fichiers inverses (*posting lists*)

Correction :

Terme	docIds
France	1, 4
Récession	1
Ralentie	1, 2, 3, 4
INSEE	1, 3
USA	2
Finance	2
Paulson	2
Crise	2, 3, 4
Gouvernement	3
PIB	4

2. Evaluer les requêtes précédentes.

Correction :

Même résultat, la méthode est différente.

3. Formaliser l'algorithme de fusion de listes par rapport à une requête.

Correction :

Intersection¹ (p_1, p_2)

$L = ()$

Tant que p_1 et p_2 ne sont pas vides

 Si docId (p_1) == docId (p_2)

 Ajouter docId(p_1) à L

$p_1 = \text{suivant}(p_1)$

$p_2 = \text{suivant}(p_2)$

 Sinon Si docId (p_1) < docId (p_2)

$p_1 = \text{suivant}(p_1)$

 Sinon $p_2 = \text{suivant}(p_2)$

Retourner L

Evaluation (*terms*)

$p_1 = \text{posting_list}(\text{terms}[1])$

 Pour chaque i de 2 à taille(*terms*)

1. p_1 et p_2 sont deux *Posting lists* correspondant à chaque terme

$p_2 = \text{posting_list}(\text{terms}[i])$

$p_1 = \text{Intersection}(p_1, p_2)$

Retourner p_1

4. Dans quel ordre doit-on choisir les mots de la requête pour l'évaluation ?

Correction : En choisissant les termes par ordre de fréquence croissante, nous pourrions être plus sélectif sur le terme le plus fréquent.

5. Quelle optimisation peut-on faire sur le modèle pour accélérer les gros vecteurs (plusieurs millions d'occurrences pour le mot 'crise') ? Modifier l'algorithme avec cette optimisation.

Correction : En ajoutant des pointeurs appelés *Skip Lists*, nous allons pouvoir sauter un ensemble de documents s'ils sont inutiles. Celui-ci se pose tous les X documents et pointe sur la série suivante. Ainsi, tous les X documents nous avons le docId et le docId pointé. Cela nous permet, lorsque nous cherchons un docId trop grand de passer au docId pointé sans analyser les docId intermédiaires.

3.2 Vocabulaire de termes

Pour les exercices suivant, nous allons nous reposer sur des textes extraits du web parlant d'un même sujet. Le but est d'en extraire les mots pour constituer un vocabulaire et un index de termes.

docID 1 (66 mots) : On ne parle plus de ralentissement de la croissance, mais de récession véritable. En France, selon l'Insee, le PIB va diminuer de 0,8 points. Il en est de même au niveau de l'ensemble des pays industrialisés : pour la première fois depuis 1945, leurs PIB diminueront sur toute une année. Quant aux économies du Sud, si elles vont continuer à croître c'est de façon ralentie.

docID 2 (68 mots) : Devant ces mauvais chiffres de la croissance, le gouvernement ne mesure pas ce que cela signifie pour des dizaines de millions de Français en terme de difficultés pour vivre. Pas de récession mais une croissance ralentie, disent-ils... Le gouvernement refuse d'engager un plan de relance de l'économie et veut s'en prendre aux déficits publics en réduisant les dépenses. Pour le gouffre des financiers, les sommes elles sont débloquées !

docID 3 (97 mots) : Le gouvernement a revu en nette baisse ses prévisions. De son côté, l'INSEE prend acte du fait que "la croissance cale en zone euro" et que la France n'est pas épargnée par la crise. Même si l'INSEE juge pour l'instant prématuré d'employer le terme de "récession", le PIB de la France devrait continuer à diminuer, perdant 0,1 point aux troisième et quatrième trimestres après une baisse de 0,3 point au deuxième trimestre. La récession est le plus souvent définie par au moins deux trimestres consécutifs de recul du PIB.

docID 4 (93 mots) : Il n'est pas encore certain que la crise immobilière et financière provoque une récession, c'est-à-dire un recul de la production durant au moins deux semestres consécutifs et pas seulement un ralentissement de sa croissance. Selon le secrétaire d'Etat américain aux finances, Henri Paulson, même si les USA connaissent une récession, celle-ci sera faible dans son ampleur et sa durée, suivie d'une reprise qui ne serait lente que pendant un an ou deux. C'est le temps qu'il faudra pour absorber le choc et réaliser les ajustements nécessaires.

1. Soit le vocabulaire extrait des textes précédents préliminaire suivant :

On, Il, ils, elles, un, une, ne, parle, plus, pas, Pas, à, de, De, des, du, n', c', C', d', l', s', qu', le, Le, la, ce, ces, ses, son, leurs, en, au, aux, est-à-dire, celle-ci, et, que, qui, mais, si, même, Même, Devant, après, pour, Pour, Quant, sur, depuis, a, est, sera, serait, sont, va, vont, faudra, dans, devrait, encore, durant, pendant, selon, Selon, toute, certain, souvent, moins, seulement, lente, ralentie, ralentissement, croissance, recession, récession, véritable, France, Français, Insee, INSEE, PIB, diminuer, diminueront, point, points, niveau, ensemble, pays, industrialisés, première, fois, an, année, économie, économies, Sud, continuer, croître, façon, mauvais, chiffres, gouvernement, mesure, signifie, dizaines, millions, terme, difficultés, vivre, disent, refuse, engager, plan, relance, veut, prendre, prend, déficits, publics, réduisant, dépenses, gouffre, finances, financiers, sommes, débloquées, revu, nette, baisse, prévisions, côté, acte, fait, cale, zone, euro, épargnée, crise, juge, instant, prématuré, employer, perdant, deux, deuxième, troisième, quatrième, trimestre, trimestres, semestres, définie, consécutifs, recul, immobilière, provoque, production, secrétaire, Etat, américain, Henri, Paulson, USA, connaissent, faible, ampleur, durée, suivie, reprise, temps, absorber, choc, réaliser, ajustements, nécessaires

2. La taille de ce vocabulaire est de 176 termes (*Tous les mots sont pris*)

3. Quelles sont les conséquences de la non prise en compte de la casse et de la suppression des accents et caractères spéciaux ? (*tout le texte est alors mise en minuscules*)

Correction : Les mots tels que Insee et INSEE seront alors reconnu comme un seul et même mot. De même pour tous les mots de début de phrases : De/de, Même/même. De plus, les erreurs d'accents comme "récession/recession" seront alors supprimées. Par contre, un des problèmes qui peut arriver est de transformer le *USA* en *usa* qui devient alors un verbe en français.

4. Constituer une liste de "Stop Words". Quelle est alors la taille de l'index après la suppression des Stop Words ?

Correction : Attention, dans la liste de stop words, doit-on prendre des termes comme 'un' qui correspond aussi à un nombre ?

116 termes, avec une liste de Stop Words :

on, il, ils, elles, une, ne, plus, pas, à, de, des, du, n', c', d', l', s', qu', le, la, ce, ces, ses, son, leurs, en, au, aux, est-à-dire, celle-ci, et, que, qui, mais, si, même, devant, après, pour, quant, sur, depuis, a, est, sera, serait, sont, va, vont, dans, encore, durant, pendant, selon, toute, certain, souvent, moins, seulement

5. Quelles sont les conséquences d'une lemmatisation des mots du vocabulaire ? Donner plusieurs exemples dans les documents proposés.

Correction : Grâce à la lemmatisation, nous allons pouvoir mettre tous les verbes à l'infinitif, tous les déclinaisons des mots vont revenir à leur racine.

Exemple de 'lente/ralentie/ralentissement' Par contre, certains mots vont être dénaturés alors qu'ils ne le devraient pas : insee (si le lemmatiseur est mauvais, il considérera que c'est le verbe inser au passé simple féminin.). En effet, les noms de famille et d'organisations ne sont plus reconnues.

6. Quelle est la nouvelle taille du vocabulaire ? (*hors stop words et avec lemmatisation*)

Correction : 103 termes

parler, avoir, être, aller, falloir, devoir, plus, moins, seul, lent, croissance, recession, vrai, france, inser, pib, diminuer, point, point, niveau, ensemble, pays, industrialiser, premier, fois, an, année, économie, sud, continuer, croître, façon, mauvais, chiffre, gouvernement, mesurer, signifier, dizaine, million, terme, difficulté, vivre, dire, refuser, engager, plan, relance, vouloir, prendre, déficit, public, réduire, dépense, gouffre, finance, somme, débloquent, revu, net, baisse, prévision, cote, act, faire, cale, zone, euro, épargner, crise, juge, instant, prématurer, employer, perdre, deux, trois, quatre, trimestre, semestre, définir, consécutif, recul, immobilier, provoquer, production, secrétaire, Etat, amérique, henri, paulson, usa, connaître, faible, ampleur, durer, suivre, repris, temps, absorber, choc, réaliser, ajustement, nécessaire

7. Créer un fichier inverse avec les termes du document (nous prendrons le sous-ensemble suivant : crise, croissance, finance, france, insee, lent, gouvernement, pib). Vous y associez les valeurs de TF et DF.

Correction :

Terme	df	docIds (tf)
crise	2/4	3 (1/97) , 4 (1/93)
croissance	4/4	1 (1/66), 2 (2/68), 3 (1/97), 4 (1/93)
finance	2/4	2 (1/68), 4 (2/93)
france	3/4	1 (1/66), 2 (1/68), 3 (2/97)
gouvernement	2/4	2 (2/68), 3 (2/97)
insee	2/4	1 (3/66), 3 (2/97)
lent	3/4	1 (2/66), 2 (1/68), 4 (2/93)
pib	2/4	1 (2/66), 3 (2/97)

3.3 Compression et Distribution

3.3.1 Compression de fichiers inverse

Soit un fichier inverse contenant 100 000 termes différents, et 100 millions de documents. Chaque terme contient en moyenne 500 000 documents (peut varier de 10 000 à 5 millions). Nous nous intéressons maintenant à la taille prise par cet index, et la manière de le compresser.

Pour cela, il faut savoir que :

- Un terme est codé maximum sur 20 octets (avec une moyenne de 8 octets)
- Un pointeur sur 8 octets
- Un nombre est codé sur 4 octets

Un index contient un *terme*, la *fréquence* du terme et un pointeur sur la *posting list*.

Compression de l'index de termes

1. Quelle est la taille de l'index des termes ? (sans les *posting lists*)
Correction : $100\,000 \times (20 + 4 + 8) = 3\,200\,000 \text{ o} = 3,20 \text{ Mo}$
2. Proposer une technique de compression des termes. Donner la taille de cet index.
Correction : En codant tous les termes sur leur taille moyenne, puis en rajoutant un pointeur sur la chaîne entière à part (si besoin), nous pouvons réduire la taille à $80 + 80$ pour chaque terme. Ce qui nous fait descendre à 2,4 Mo.
3. Remplacer le codage du terme par un *termId* (identifiant de terme dans le dictionnaire). Donner la taille de cet index.
Correction : Chaque triplet est alors codé sur : $(4 + 4 + 8)$.
 Ce qui nous fait une taille totale de 1,6 Mo.
4. Que pourra-t-on utiliser pour retrouver le terme en fonction de son *termId* ??
Correction : On pourra utiliser un BTree pour retrouver chaque terme.

Compression de la *Posting List*

1. Compte tenu du nombre de documents, donner la taille d'encodage d'un *docId*.
Correction : $\log_2(10^8) \approx 26,57 \Rightarrow 4 \text{ octets}$
2. Donner, à partir de la taille moyenne des *posting lists* et de la taille d'un *docId*, la taille d'un vecteur de l'index. Puis la taille de l'index global.
Correction : $500\,000 \times 4 = 2 \text{ Mo} / \text{vecteur}$
 $100\,000 \times 2\text{M} = 200 \text{ Go}$

3. Proposer une solution pour encoder les docId d'une manière différente. Donner le principe de l'encodage.

Correction : Une solution est de calculer les distances entre chaque docId avec des encodages à taille variable. Pour cela, à chaque docId, on calcul la différence avec le précédent et on l'encode sur le nombre de bits nécessaire. Le premier bit de chaque octet permet de dire si c'est la fin de l'encodage, s'il est à 1 c'est que c'est la fin du calcul, sinon on ajoute avec la suite.

4. Donner la transformation, puis l'encodage de la *posting list* suivante : 105, 117, 222, 702, 3002

Correction : Transformation : 105, 2, 115, 480, 2300

Pour chaque différence : 1101001, 10, 1110011, 11 1100000, 10001 1111100

Encodage : 1110100110000010111100110000001111000000001000111111100

5. Donner la taille moyenne de l'index, en supposant que les 2/5° des docIds sont sur 1 octet, 2/5° sur 2 octets, et le reste en moyenne à 4 octets.

Correction : $1 \times 200\ 000 + 2 \times 200\ 000 + 4 \times 100\ 000 = 1\ \text{Mo} / \text{vecteur}$.

$100\ 000 \times 900\text{k} = 100\ \text{Go}$

3.4 Recherche par Similarité

Nous reprendrons les listes inverses créées dans la section 3.2, question 7.

3.4.1 Produit Scalaire

1. Calculer le produit scalaire de la requête suivante : "France Ralentie PIB"

Correction :

$$- \text{doc}_1 = \frac{1}{66} \times \log \frac{4}{3} \times \frac{1}{3} + \frac{2}{66} \times \log \frac{4}{3} \times \frac{1}{3} + \frac{2}{66} \times \log \frac{4}{2} \times \frac{1}{3} = 4,934 \times 10^{-3}$$

$$- \text{doc}_2 = \frac{1}{68} \times \log \frac{4}{3} \times \frac{1}{3} + \frac{1}{68} \times \log \frac{4}{3} \times \frac{1}{3} + \frac{0}{68} \times \log \frac{4}{2} \times \frac{1}{3} = 1,225 \times 10^{-3}$$

$$- \text{doc}_3 = \frac{2}{97} \times \log \frac{4}{3} \times \frac{1}{3} + \frac{0}{97} \times \log \frac{4}{3} \times \frac{1}{3} + \frac{2}{97} \times \log \frac{4}{2} \times \frac{1}{3} = 2,928 \times 10^{-3}$$

$$- \text{doc}_4 = \frac{0}{93} \times \log \frac{4}{3} \times \frac{1}{3} + \frac{2}{93} \times \log \frac{4}{3} \times \frac{1}{3} + \frac{0}{93} \times \log \frac{4}{2} \times \frac{1}{3} = 0,895 \times 10^{-3}$$

2. Trier le résultat par ordre de pertinence décroissante

Correction : $\text{doc}_1, \text{doc}_3, \text{doc}_2, \text{doc}_4$

3.4.2 Cosinus

1. Donner le calcul de la norme d'un document et de la requête

Correction : $\sqrt{\sum t f_i^2}$

2. Les normes des documents sont respectivement : 0.0392, 0.0336, 0.0310, 0.0421

3. Calculer le cosinus de la requête suivante : "France Ralentie PIB"

Correction :

$$- \text{doc}_1 = \frac{4,934 \times 10^{-3}}{0,0392} = 0,126$$

$$- \text{doc}_2 = \frac{1,225 \times 10^{-3}}{0,0336} = 0,036$$

$$- \text{doc}_3 = \frac{2,928 \times 10^{-3}}{0,0310} = 0,094$$

$$- \text{doc}_4 = \frac{0,895 \times 10^{-3}}{0,0421} = 0,021$$

4. Trier le résultat par ordre de pertinence décroissante

Correction : $R_1 : \text{doc}_1, \text{doc}_3, \text{doc}_2, \text{doc}_4$

3.4.3 Précision / Rappel

Nous nous attendions à l'ensemble résultat suivant : $R_2 : doc_1, doc_4$

1. Donner la précision et le rappel du résultat obtenu par Cosinus

Correction :

$$- \frac{R_1 \cap R_2}{R_1} = \frac{2}{4}$$

$$- \frac{R_1 \cap R_2}{R_2} = \frac{2}{2}$$

2. Donner la précision et le rappel du résultat obtenu par Cosinus avec un score supérieur à 0,03

Correction :

$$- \frac{R_1 \cap R_2}{R_1} = \frac{1}{3}$$

$$- \frac{R_1 \cap R_2}{R_2} = \frac{1}{2}$$

3.5 PageRank

3.5.1 PageRank

Voici un graphe représentant les hyperliens entre les pages d'un site web :




FIGURE 3.1 – Graphe d'hyperliens entre des pages

1. Rappeler la loi de probabilité de passer d'une page i à une page j .

Correction : $P_{ij} = \frac{\alpha}{N} + \frac{I(1-\alpha)}{K}$

Où N est le nombre de pages, K le nombre d'hyperliens de la page i .

I est égal 1 si j est une des cibles des hyperliens, 0 sinon.

2. Construire la matrice $N \times N$ de probabilités de passages d'une page à une autre, avec $\alpha = \frac{1}{2}$

Correction : Nous avons $N=4$, $K_A=2$, $K_B=2$, $K_C=2$, $K_D=1$

1/8	3/8	1/8	3/8
1/8	1/8	3/8	3/8
1/8	3/8	1/8	3/8
5/8	1/8	1/8	1/8

3. Calculer le PageRank de la matrice à l'aide du vecteur (1 0 0 0). Vous arrondirez chaque calcul avec 3 chiffres après la virgule.

Correction : Etapes :

1	1	0	0	0
1	0,125	0,375	0,125	0,375
2	0,313	0,188	0,219	0,281
3	0,266	0,258	0,172	0,305
4	0,278	0,235	0,190	0,299
5	0,275	0,242	0,184	0,301
6	0,276	0,240	0,186	0,301
7	0,276	0,241	0,185	0,301
8	0,276	0,241	0,186	0,301
9	0,276	0,241	0,186	0,301

3.5.2 Pertinence du contenu d'une page Web

1. En reprenant le résultat de la recherche par cosinus (section 3.4.2, question 4) sur les documents doc_1 (site A), doc_2 (site B), doc_3 (site C), doc_4 (site D), et en multipliant le score de cosinus par le pageRank du site hébergeant ce texte, donner l'ordre final de votre recherche.

Correction : Nous obtenons ainsi un PageRank pour chaque page de :

- doc_1 : $0,276 \times 0,126 = 0,035$
- doc_3 : $0,186 \times 0,094 = 0,018$
- doc_2 : $0,241 \times 0,036 = 0,009$
- doc_4 : $0,301 \times 0,021 = 0,006$

4 DISTRIBUTION

4.0.3 P2P, DHT, Chord

Lorsque l'index prend encore trop de place, il est utile de le répartir sur un ensemble de serveur qui répartiront ainsi la charge. Chaque terme, associé à sa *posting list* est envoyé sur un serveur. Pour cela, nous utiliserons un réseau P2P Chord avec une DHT.

Notre DHT utilisera comme fonction de hachage, sur le *docId*, **modulo (N)**. N étant le nombre de noeuds du réseau pair-à-pair. Chaque noeud relié à deux autres noeuds, formant un anneau complet. Afin de parcourir l'anneau, chaque noeud N_i a une partie de la table de hachage globale (d'où le *Distributed Hash Table*). La table de N_i contient un certain nombre de pointeurs vers des noeuds suivants dont les identifiants sont :

$N_i+2^0, N_i+2^1, N_i+2^2, N_i+2^3, N_i+2^4, N_i+2^5$.

Ainsi, lorsqu'à un noeud N_i on cherche une clé j (recherche ou insertion), si j est supérieure à N_i+2^5 on sautera les 2^5 noeuds suivants. S'il est inférieur, on test N_i+2^4 . Et ceci récursivement jusqu'à atteindre le noeud N_j .

1. Construire un réseau Chord de 18 noeuds.
2. Placer les *Postings List* de la section 3.2, question 7 dans le réseau. Le *termId* de chaque terme correspond à son ordre d'apparition.
France : 1, Récession : 2, Ralentie : 3, INSEE : 4, USA : 5, Finance : 6, Paulson : 7, Crise : 8, Gouvernement : 9, PIB : 10
3. Le noeud 1 souhaite ajouter le document 5 contenant les mots suivants (Récession, Gouvernement). Décrire le déroulement de l'insertion.
4. Une requête est posée au niveau du noeud 14. Décrire les étapes de l'évaluation de la requête suivante : *crise* $\wedge$ *ralentie*.